IMPLEMENTASI *TRANSFER LEARNING* DAN *LLM* UNTUK IDENTIFIKASI PERMASALAHAN KULIT WAJAH DAN REKOMENDASI *SKINCARE*

SKRIPSI

Diajukan Kepada
Fakultas Ilmu Komputer Universitas Klabat
Untuk Memenuhi Tuntutan Memperoleh Gelar Sarjana Komputer (S-1)
Program Studi Informatika

Disusun oleh:

NIM: 105022210095

Bindosano, Grace Allyn

NIM: 105022210062

Mandolang, Faithza Azalia

FAKULTAS ILMU KOMPUTER

UNIVERSITAS KLABAT

OKTOBER 2025

UNIVERSITAS KLABAT
AIRMADIDI, MANADO 95371 Sulawesi Utara, Indonesia
Phone: +62(431)891035; 891041; 891842; 892124 Fax: +62(431)891036
E-mail: email@unklab.ac.id; universitas_klabat@yahoo.com
Website: http://www.unklab.ac.id

LEMBAR PERNYATAAN PERSETUJUAN PUBLIKASI

Yang bertanda tangan di bawah ini, saya:

Nama	: Faithza Azalia Mandolang
NIM	: 105022210062
Program Studi	: Informatika
Alamat Kampus	: Airmadidi, Manado, Sulawesi Utara, Indonesia
Alamat Rumah	: Tomohon Selatan, Tomohon, Sulawesi Utara

Nama	: Grace Allyn Bindosano
NIM	: 105022210095
Program Studi	: Informatika
Alamat Kampus	: Airmadidi, Manado, Sulawesi Utara, Indonesia
Alamat Rumah	: Dendengan Luar, Manado, Sulawesi Utara

Dengan ini menyetujui untuk memberikan izin kepada Pembimbing Skripsi, Hak Bebas Royalti Non-Ekslusif (Non-exclusive Royalti Free Right) atas skripsi saya yang berjudul: "IMPLEMENTASI *TRANSER LEARNING* DAN LLM UNTUK IDENTIFIKASI PERMASALAHAN KULIT WAJAH DAN REKOMENDASI *SKINCARE*", beserta perangkat yang diperlukan (apabila ada).
Dengan Hak Bebas Royalti Non-Ekslusif ini pihak Pembimbing Skripsi berhak menyimpan, mengalih mediakan, mengelola dalam pangkalan data (database), mendistribusikannya dan menampilkan atau mempublikasikan untuk kepentingan akademis tanpa perlu meminta izin dari saya selama tetap mencantumkan nama saya.
Saya bersedia untuk menanggung secara pribadi, tanpa melibatkan pihak Pembimbing, segala bentuk tuntutan hukum yang timbul atas pelanggaran Hak Cipta dalam skripsi ini.
Demikianlah pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Airmadidi
Pada tanggal : 21 November 2025

Yang menyatakan,



Faithza Azalia Mandolang

Yang menyatakan,



Grace Allyn Bindosano

UNIVERSITAS KLABAT
AIRMADIDI, MANADO 95371 Sulawesi Utara, Indonesia
Phone: +62(431)891035; 891041; 891842; 892124 Fax: +62(431)891036
E-mail: email@unklab.ac.id; universitas_klabat@yahoo.com
Website: http://www.unklab.ac.id

LEMBAR PENGESAHAN

Judul Skripsi :

"IMPLEMENTASI *TRANSER LEARNING* DAN LLM UNTUK IDENTIFIKASI PERMASALAHAN KULIT WAJAH DAN REKOMENDASI *SKINCARE*"

Dibuat dan diserahkan oleh **Bindosano, Grace Allyn** dan **Mandolang, Faithza Azalia** telah disetujui dan diterima untuk memenuhi tuntutan memperoleh gelar Sarjana Komputer.

Dosen Pembimbing I	Dosen Pembimbing II
Green A. Sandag, S.Kom., M.S.	**Argha O. Silitonga, S.Kom., M.S.**

DEWAN PENGUJI SKRIPSI

Disetujui oleh Dewan Penguji dalam Ujian Skripsi 9, November, 2025, Semester Ganjil, Tahun Ajaran 2025/2026.

Ketua

Debby E. Sondakh, S.Kom., M.T., Ph.D.
0926128001

Anggota

Raisa C. Maringka, S.Kom., M.Kom.
1623019501

Anggota

Green A. Sandag, S.Kom., M.S.
0907129001

MENGETAHUI
Dekan

Stenly R. Pungus, S.Kom., MT., MM., Ph.D.
0922098101

UNIVERSITAS KLABAT
AIRMADIDI, MANADO 95371 Sulawesi Utara, Indonesia
Phone: +62(431)891035; 891041; 891842; 892124 Fax: +62(431)891036
E-mail: email@unklab.ac.id; universitas_klabat@yahoo.com
*Web*site: http://www.unklab.ac.id

LEMBAR PERNYATAAN KEASLIAN

Dengan ini penulis yang bertanda tangan di bawah ini menyatakan bahwa Proposal Skripsi dengan judul:

"IMPLEMENTASI TRANSFER LEARNING DAN LLM UNTUK IDENTIFIKASI PERMASALAHAN KULIT WAJAH DAN REKOMENDASI SKINCARE"

Merupakan keaslian dari hasil penelitian penulis sendiri, adapun terdapat kutipan yang diambil dari penulisan orang lain sebagai referensi yang sudah dicantumkan ke dalam daftar pustaka.

Demikianlah surat pernyataan ini saya buat dengan sebenar-benarnya tanpa ada paksaan dari pihak manapun juga. Apabila dikemudian hari ternyata saya memberikan keterangan palsu dan atau ada pihak lain yang mengklaim skripsi yang telah saya buat sebagai hasil karya milik seseorang atau badan tertentu, saya bersedia menerima konsekuensi apapun yang akan diberikan secara akademik dan secara hukum

Airmadidi, 26 November 2025

Penulis 1	Penulis 2
Faithza Azalia Mandolang	Grace Allyn Bindosano

KATA PENGANTAR

Puji dan hormat penulis panjatkan kepada Tuhan Yesus Kristus yang senantiasa memberikan kekuatan, hikmat, serta penyertaan-Nya sepanjang proses penyusunan skripsi ini yang berjudul:

"IMPLEMENTASI *TRANSFER LEARNING* DAN *LLM* UNTUK IDENTIFIKASI PERMASALAHAN KULIT WAJAH DAN REKOMENDASI *SKINCARE*".

Atas kasih karunia Tuhan, penulis akhirnya dapat menyelesaikan penelitian ini dengan baik dan sesuai dengan waktu yang telah ditetapkan.

Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Informatika, Fakultas Ilmu Komputer, Universitas Klabat. Proses penyelesaian penelitian ini tidaklah mudah dan memerlukan banyak bimbingan, dukungan, serta doa dari berbagai pihak. Untuk itu, penulis ingin menyampaikan rasa terima kasih yang tulus kepada:

1. Tuhan Yesus Kristus, yang selalu memberikan hikmat, kesabaran, kekuatan, penyertaan dan tuntunan kepada penulis dalam menyelesaikan skripsi ini dari awal hingga akhir.
2. Sir Stenly Richard Pungus, S.kom., M.T., M.M., Ph.D dan Sir Semmy Wellem Taju, S.kom., M.S., Ph.D, selaku Dekan Fakultas Ilmu Komputer dan Ketua Program Studi Informatika, atas dukungan dan bimbingan selama masa perkuliahan hingga penyusunan tugas akhir ini.
3. Sir Green Arther Sandag, S.kom., M.S, selaku Dosen Pembimbing I, yang telah dengan sabar memberikan arahan, masukan, dan motivasi selama proses penelitian.

4. Sir Argha Orion Silitonga, S.kom., M.S, selaku Dosen Pembimbing II, atas waktu, dukungan, serta saran berharga yang sangat membantu dalam penyusunan skripsi ini.
5. Keluarga besar penulis, orang tua, oma, opa, adik dan kakak – keluarga Grace dan Faithza – yang senantiasa menjadi sumber dukungan moral, kasih, dan doa yang tidak pernah berhenti bagi penulis.
6. Seluruh dosen dan staf Fakultas Ilmu Komputer Universitas Klabat, yang telah memberikan banyak ilmu, pengalaman, dan inspirasi selama masa studi.
7. Teman-teman seperjuangan, khususnya mahasiswa angkatan 2022, atas kebersamaan, semangat, dan dukungan yang telah diberikan selama masa perkuliahan hingga proses penyusunan skripsi ini.
8. Semua pihak yang tidak dapat disebutkan satu per satu, namun turut berperan dalam membantu penyelesaian penelitian ini – penulis menyampaikan rasa terima kasih yang sebesar-besarnya.

Secara khusus juga peneliti Bindosano, Grace Allyn ingin menyampaikan terima kasih sebesar-besarnya kepada:

1. Kedua orang tua saya, Mom and Dad, yang selalu mendorong dan memberi semangat. Kakak-kakak saya yang selalu bersedia untuk membantu saya. Terima kasih atas kata-kata dorongan ataupun semangat yang selalu diberikan kepada saya.
2. Partner skripsi saya, Faithza Azalia Mandolang, yang selalu ada dalam perjuangan kami. Terima kasih atas kerjasama dan kesabaran selalu

diberikan selama perjuangan kita hingga menyelesaikan skripsi kita. Terima kasih telah menjadi partner saya yang dapat saya andalkan dan kita dapat menyelesaikan skripsi yang kita mulai.

3. Teman-teman angkatan 2022, seluruh rekan prodi Informatika, juga Group Konspirasi Dunia dan KB. Terima kasih sudah hadir dan membawa tawa dan kenangan yang tidak akan terlupakan.
4. Untuk sahabat saya, Aiko, terima kasih telah hadir dan terima kasih telah menjadi pendengar yang baik akan keluh kesah saya. Terima kasih untuk selalu mengingatkan saya untuk selalu maju.
5. Untuk saya, terima kasih sudah berjuang sampai akhir dan tidak menyerah.

Secara khusus juga peneliti Mandolang, Faithza Azalia ingin menyampaikan terima kasih sebesar-besarnya kepada:

1. Kedua orang tua saya, mommy dengan nasihat, semangat dan daddy, tidak hanya ayah tetapi juga sahabat dan "teman" diskusi, serta adik saya yang selalu menjadi penyemangat dalam setiap langkah. Terima kasih atas kasih sayang, doa, dan dukungan tanpa henti yang menjadi sumber kekuatan terbesar dalam perjalanan ini. Tidak lupa juga untuk seluruh keluarga besar, yang selalu mendoakan dan memberi dorongan moral selama perkuliahan.
2. Partner skripsi saya, Grace yang telah menjadi rekan seperjuangan selama proses penelitian dan penulisan ini. Terima kasih atas kerja sama, kesabaran, dan semangat yang selalu diberikan di tengah berbagai tantangan yang kita hadapi bersama. Dukungan dan kebersamaanmu membuat proses ini terasa lebih ringan dan bermakna.

3. Teman-teman Angkatan 2022 GENXXII, seluruh rekan di Program Studi Informatika, serta teman-teman dari Grup Konspirasi Dunia dan KB. Terima kasih atas kebersamaan, tawa, dukungan, dan semangat yang kalian berikan selama masa kuliah hingga penyusunan skripsi ini. Setiap pertemuan, diskusi bahkan candaan kecil menjadi bagian berharga yang memberi warna dalam perjalanan ini.
4. Untuk diri saya sendiri, terima kasih telah bertahan, berjuang, dan terus melangkah meskipun dihadapkan pada banyak tantangan. Terima kasih karena tidak pernah menyerah dan tetap percaya bahwa setiap proses memiliki arti dan hasilnya akan indah pada waktunya. Keep fighting.

ABSTRAK

Kulit merupakan organ terbesar manusia dan kondisi kulit dapat mencerminkan kesehatan tubuh. Masalah kulit wajah seperti jerawat, dark spot, kerutan, kemerahan, kulit berminyak, dan kulit kering sering terjadi akibat faktor seperti sinar matahari, perawatan tidak tepat, dan gaya hidup. Pemeriksaan oleh dokter kulit masih terbatas sehingga penelitian ini mengusulkan sistem klasifikasi masalah kulit wajah dan rekomendasi skincare berbasis Transfer Learning dan LLM. Empat model dilatih, yaitu VGG16, ResNet50, EfficientNetB0, dan MobileNetV3Small. Hasil menunjukkan ResNet50 dengan RMSprop memberikan akurasi terbaik sebesar 87,70%, kemudian diintegrasikan ke sistem berbasis Flask. Sistem mampu mengklasifikasi enam jenis masalah kulit, menampilkan visualisasi Grad-CAM, serta menghasilkan penjelasan dan rekomendasi skincare, membantu pengguna memahami serta menangani kondisi kulit secara awal.

Kata kunci: Kulit Wajah, Grad-CAM, Transfer Learing, Large Language Models (LLM), Klasifikasi.

ABSTRACT

This study proposes a classification system for facial skin problems and skincare recommendations using Transfer Learning and LLM. The system is trained to learn features of acne, dark spots, wrinkles, redness, oily skin, and dry skin. Four models, including VGG16, ResNet50, EfficientNetB0, and MobileNetV3Small, were trained, along with optimizers Adamax, SGD, and RMSprop. The model with the best performance will be implemented into a Flask-developed system. The ResNet50 model with the RMSprop optimizer achieved an accuracy of 87.70%. The system can classify facial skin problems into six categories, with Grad-CAM visualizing how the model learns. LLM generates textual explanations and skincare recommendations based on the classification results. This system could be a first step in understanding why skin problems occur and how to treat them.

Keywords: Facial skin, Grad-CAM, Transfer Learning, Large Language Models (LLM), Classification.

DAFTAR ISI

KATA PENGANTAR i
ABSTRAK v
ABSTRACT vi
DAFTAR ISI vii
DAFTAR GAMBAR x
DAFTAR TABEL xiii
BAB 1 PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Masalah 8
1.3. Tujuan Penelitian 8
1.4. Manfaat Penelitian 9
1.5. Ruang Lingkup Penelitian 10
1.5.1. Cakupan Penelitian 10
1.5.2. Batasan Penelitian 11
1.6. Daftar Istilah 12
BAB 2 TINJAUAN LITERATUR 14
2.1. Permasalahan Kulit Wajah 14
2.2. Skincare 16
2.3. Neural Network 20
2.4. Deep Learning 21
2.5. Convolutional Neural Networks (CNN) 22
2.5.1. Convolutional Layer 23
2.5.2. Pooling Layer 24
2.5.3. Fully Connected Layer 25
2.5.4. Activation Functions 26
2.6. Softmax 27
2.7. Transfer Learning 27
2.7.1. VGG 29
2.7.2. ResNet 29
2.7.3. EfficientNet 30
2.7.4. MobileNet 31
2.8. Optimizers 31
2.8.1. Stochastic Gradient Descent (SGD) 32
2.8.2. RMSprop 33

2.8.3. Adamax 34
2.9. Explainable AI 35
2.9.1. Grad-CAM 35
2.10. Large Language Model (LLM) 35
2.10.1. Gemini 36
2.11. CRISP-DM 37
2.12. Python 38
2.13. Kaggle 39
2.15. TensorFlow 40
2.16. Keras 41
2.17. Kerangka Konseptual 42
2.18. Penelitian Terkait 44
BAB 3 METODOLOGI PENELITIAN 49
3.1. Desain Penelitian 49
3.2. Metode Penelitian 52
3.2.1. Pengumpulan dan Pemahaman Data 53
3.2.1.1. Pengumpulan Data 53
3.2.2. Modelling 55
3.2.3. Deployment 60
3.3. Teknik Pengumpulan Data 61
3.3.1. Studi Literatur 61
3.4. Lingkungan Pengembangan 62
3.4.1. Software 62
3.4.2. Hardware 62
BAB 4 HASIL DAN PEMBAHASAN 64
4.1. Pengumpulan Data & Pemahaman 64
4.2. Data Preprocessing 65
4.3. Modeling 66
4.4. XAI menggunakan Grad-CAM 69
4.5. Evaluasi 71
4.5.1. Perbandingan algoritma transfer learning 71
4.5.2. Training and validation loss and accuracy 72
4.5.3. Confusion Matrix 77
4.5.4. Perbandingan model dengan penelitian terkait 82
4.6. Analisis dan Desain 85
4.6.1. Use Case Diagram 85

4.6.2. Activity Diagram....92
4.6.3. Sequence Diagram....95
4.6.4. Class Diagram....97
BAB 5 IMPLEMENTASI....99
5.1. Implementasi Aplikasi Web....99
5.2. Pengujian Fungsionalitas Aplikasi Web....108
BAB 6 KESIMPULAN DAN SARAN....112
6.1. Kesimpulan....112
6.2. Saran....114
DAFTAR PUSTAKA....116
DAFTAR LAMPIRAN....132

DAFTAR GAMBAR

Gambar 1.1 Perbandingan jenis kulit 2

Gambar 1.2 Contoh permasalahan kulit. Kiri atas: Dark-spot. Kanan atas: Kemerahan. Kiri tengah: Kulit berminyak. Kanan tengah: Jerawat. Kiri bawah: Kerutan. Kanan bawah: Kulit kering 3

Gambar 1.3 Ilustrasi cara kerja sistem identifikasi permasalahan kulit wajah dan rekomendasi skincare. 7

Gambar 2.1 Ilustrasi perbedaan Machine Learning dan Deep Learning 21

Gambar 2.2 Komponen CNN 23

Gambar 2.3 Convolutional Layer 24

Gambar 2.4 Pooling Layer 24

Gambar 2.5 Fully Connected Layer 25

Gambar 2.6 Classical/Traditional Machine Learning vs. Transfer Learning 28

Gambar 2.7 Architecture VGG16 29

Gambar 2.8 Architecture ResNet-50. 30

Gambar 2.9 Architecture EfficientNet-B0 31

Gambar 2.10 Architecture MobileNet V2 31

Gambar 2.11 CRISP-DM Life Cycle 38

Gambar 2.12 Keras 41

Gambar 2.13 Kerangka Konseptual Sistem. 42

Gambar 3.1 Desain Penelitian. 49

Gambar 3.2 Metode Penelitian. 52

Gambar 3.3 Pembagian Dataset. 54

Gambar 3.4 Additional Layer Model. 56

Gambar 4.1 Jenis-jenis permasalahan kulit wajah. 65
Gambar 4.2 Visualisasi Grad-CAM pada gambar wajah. 70
Gambar 4.3 Graph Training dan Validation Loss/Accuracy EfficientNetB0. 73
Gambar 4.4 Graph Training dan Validation Loss/Accuracy ResNet50. 74
Gambar 4.5 Graph Training dan Validation Loss/Accuracy VGG16. 75
Gambar 4.6 Graph Training dan Validation Loss/AccuracyMobileNetV3Small. 76
Gambar 4.7 Confusion Matrix EfficientNetB0. 78
Gambar 4.8 Confusion Matrix ResNet50. 79
Gambar 4.9 Confusion Matrix VGG16. 80
Gambar 4.10 Confusion Matrix MobileNetV3Small. 81
Gambar 4.11 Use Case Diagram 85
Gambar 4.12 Activity Diagram Melakukan Identifikasi Kulit Wajah. 93
Gambar 4.13 Activity Diagram Melihat History. 94
Gambar 4.14 Sequence Diagram melakukan Identifikasi Permasalahan Kulit Wajah. 95
Gambar 4.15 Sequence Diagram melihat History 96
Gambar 4.16 Class Diagram. 98
Gambar 5.1 Tampilan Home Page bagian Upload Gambar. 101
Gambar 5.2 Tampilan Home Page bagian Jenis permasalahan kulit wajah. 103
Gambar 5.3 Tampilan Home Page bagian Keunggulan. 104
Gambar 5.4 Tampilan Home Page bagian Tutorial. 105
Gambar 5.5 Tampilan Home Page bagian Footer. 105
Gambar 5.6 Tampilan Halaman Hasil. 106
Gambar 5.7 Tampilan Halaman History. 107

Gambar 5. 8 Tampilan Halaman History Detail. 107

Gambar 5.9 Validasi input data dengan Dokter Kulit. 109

DAFTAR TABEL

Tabel 2.1 Hasil akurasi perbandingan beberapa model 44

Tabel 2.2 Hasil evaluasi eksperimen beberapa model 45

Tabel 2.3 Hasil pengujian model menggunakan optimizer..... 45

Tabel 2.4 Hasil pengujian MobileNet 46

Tabel 2.5 Hasil pengujian keseluruhan model 47

Tabel 2.6 Kontribusi Penelitian..... 47

Tabel 4.1 Best Result from Each Model. 67

Tabel 4.2 Hasil Evaluasi Model. 71

Tabel 4.3 Perbandingan Model dengan Penelitian Terkait. 83

Tabel 4.4 Deskripsi Use Case Melakukan identifikasi kulit wajah. 86

Tabel 4.5 Deskripsi Use Case Validasi identitas & gambar. 87

Tabel 4.6 Deskripsi Use Case Generate rekomendasi & penjelasan. 88

Tabel 4.7 Deskripsi Use Case Mencari tautan E-commerce.. 89

Tabel 4.8 Deskripsi Use Case Melihat history.. 90

Tabel 4.9 Deskripsi Use Case Mencari history analisis.. 91

Tabel 5.1 Pengujian Fungsionalitas Aplikasi Web. 110

BAB 1

PENDAHULUAN

Pada bab ini akan membahas tentang latar belakang penelitian, rumusan masalah, tujuan penelitian, manfaat penelitian dan ruang lingkup penelitian.

1.1. Latar Belakang

Kulit adalah organ terbesar pada tubuh manusia dan berfungsi sebagai pertahanan utama terhadap berbagai ancaman dari luar, seperti bakteri, virus, polusi, dan sinar ultraviolet[1]. Selain itu, kondisi kulit juga mencerminkan kesehatan tubuh secara keseluruhan, sehingga menjadi salah satu indikator penting bagi kesejahteraan[2]. Dari seluruh area kulit, wajah merupakan bagian tubuh yang paling diperhatikan dan sangat berperan dalam membentuk kesan penampilan serta rasa percaya diri seseorang[3]. Hal ini karena wajah adalah titik fokus utama dalam interaksi sosial, memungkinkan untuk mengenali ekspresi, memahami isyarat, dan membentuk kesan mengenai identitas, kesehatan, atau kesuksesan seseorang[4][3]. Karena peran pentingnya, gangguan atau masalah pada wajah dapat menarik perhatian secara negatif dan berdampak pada kualitas hidup seseorang[3].

Meskipun memiliki fungsi perlindungan, kulit wajah juga sangat rentan terhadap berbagai permasalahan. Letaknya yang terpapar langsung dengan lingkungan luar, ditambah dengan faktor internal seperti genetik, hormon, dan gaya hidup, membuat kulit wajah lebih mudah mengalami gangguan. Berbagai masalah kulit wajah seperti jerawat (acne), dark-spot (hyperpigmentation), kulit kering (xerosis), kulit berminyak (seborrhea), kemerahan (erythema), kerutan (rhytids) hingga iritasi sering menjadi keluhan umum yang dapat mempengaruhi kenyamanan hidup[2]. Kondisi ini dapat sangat mengganggu, tidak hanya dari segi

penampilan, tetapi juga dapat menyebabkan gangguan emosional, termasuk rendahnya harga diri, rasa malu, kesedihan, dan isolasi sosial. Perubahan emosional ini bahkan berpotensi mempengaruhi kesehatan mental[5].

Melihat dampak yang cukup luas dari permasalahan kulit wajah, banyak individu mulai menyadari pentingnya merawat kulit wajah, tidak hanya untuk alasan estetika tetapi juga demi keseimbangan emosional dan kesehatan mental. Kesadaran ini terus meningkat di masyarakat, seiring dengan berkembangnya informasi dan perhatian terhadap kesehatan kulit. Hal ini mendorong munculnya kebutuhan akan solusi perawatan kulit yang cepat, mudah diakses, dan sesuai dengan kondisi kulit masing-masing individu [6]. Oleh karena itu, menjaga kesehatan kulit wajah kini telah menjadi bagian dari gaya hidup sehat dan upaya menyeluruh untuk meningkatkan kualitas hidup.



Gambar 1.1 Perbandingan jenis kulit[18].



Gambar 1.2 Contoh permasalahan kulit. Kiri atas: Dark-spot[85]. Kanan atas: Kemerahan[86]. Kiri tengah: Kulit berminyak[87]. Kanan tengah: Jerawat[88]. Kiri bawah: Kerutan[89]. Kanan bawah: Kulit kering[90].

Meskipun kesadaran masyarakat mengenai perawatan kulit wajah meningkat, tidak semua orang memiliki akses yang mudah untuk konsultasi ke dermatolog, terutama di kota-kota kecil[7]. Pada umumnya, diagnosis permasalahan kulit wajah masih dilakukan secara manual melalui observasi, baik secara langsung maupun via aplikasi daring[8]. Di Tengah keterbatasan akses terhadap layanan dermatolog, antusiasme masyarakat terhadap perawatan kulit justru mendorong pertumbuhan industri skincare secara signifikan. Menurut Kementerian Koordinator Bidang Perekonomian Republik Indonesia (2024), dengan meningkatnya populasi penduduk Indonesia berusia muda dan minat untuk perawatan kulit wajah, industri skincare juga semakin meningkat. Dampaknya adalah pemilihan skincare yang sesuai dengan kondisi kulit mereka menjadi lebih kompleks dengan banyaknya pilihan yang ada di pasar[9].

Dalam menjawab kompleksitas pemilihan skincare dan keterbatasan akses terhadap dermatolog, teknologi Artificial Intelligence (AI) telah banyak

dimanfaatkan dalam berbagai bidang termasuk bidang kesehatan dan kecantikan, khususnya dalam pengenalan pola gambar. Beberapa pendekatan utama yang digunakan dalam implementasi AI adalah Machine Learning dan Deep Learning, di mana keduanya sering diterapkan untuk mengidentifikasi dan mengklasifikasikan objek visual, termasuk pada kulit wajah[10]. Dibandingkan dengan Machine Learning, algoritma Deep Learning memiliki keunggulan dalam hal performa dan kecepatan karena mampu mengekstrak informasi penting langsung dari data mentah tanpa memerlukan tahap ekstraksi fitur secara manual. Salah satu arsitektur Deep Learning yang paling umum digunakan dalam pemrosesan gambar adalah Convolutional Neural Network (CNN). CNN dirancang khusus untuk mengolah data visual dan mengenali pola dalam gambar seperti gambar wajah[11]. Namun, membangun model CNN dari awal membutuhkan waktu pelatihan yang lama dan dataset dengan jumlah besar[12]. Pengembangan model CNN dengan pendekatan Transfer Learning memberikan solusi dalam memanfaatkan model CNN yang sudah dilatih sebelumnya pada dataset besar, kemudian disesuaikan ke dataset yang lebih spesifik seperti gambar wajah, sehingga proses pelatihan dataset baru menjadi lebih cepat[13][14]. Transfer Learning tidak hanya mempercepat proses pelatihan, tetapi juga membantu mengatasi keterbatasan dataset[15].

Namun, kemampuan klasifikasi visual saja belum cukup untuk memberikan pemahaman yang utuh bagi pengguna. Oleh karena itu, dibutuhkan teknologi pendukung yang mampu menjembatani hasil klasifikasi gambar dengan penjelasan serta rekomendasi yang mudah dipahami, salah satunya melalui pemanfaatan Large Language Model (LLM) guna memberikan interpretasi dan rekomendasi berbasis

teks. LLM merupakan kecerdasan buatan yang dibuat dan dilatih dengan data yang besar, sehingga model ini dapat memahami, menganalisis, dan menghasilkan teks secara otomatis[16]. Walaupun model klasifikasi berbasis gambar mampu mendeteksi permasalahan kulit wajah, itu saja belum cukup jika pengguna tidak bisa memahami hasilnya. Dengan LLM dan hasil klasifikasi, pengguna tidak hanya akan tahu apa masalah kulit wajahnya, tetapi juga mengapa dan bagaimana mengatasi masalah tersebut. Dalam konteks ini, LLM seperti Gemini digunakan untuk menyusun rekomendasi skincare yang bersifat personal. Dengan menggabungkan data visual dan tekstual, pengguna mendapatkan informasi mulai dari hasil deteksi sampai panduan rekomendasi perawatan skincare.

Untuk mendukung pengembangan sistem, beberapa penelitian sebelumnya telah dilakukan untuk mengembangkan sistem klasifikasi gambar dengan memanfaatkan CNN. Penggunaan CNN memungkinkan sistem untuk melakukan klasifikasi dengan akurasi tinggi, sehingga menjadi dasar penting dalam pengembangan teknologi analisis gambar kulit wajah yang lebih cerdas.

Penelitian yang dilakukan oleh Nukhasanah dan Murinto mengembangkan sistem klasifikasi penyakit kulit wajah menggunakan metode CNN dengan arsitektur VGG16. Penelitian ini menggunakan 500 data gambar penyakit kulit wajah. Hasil penelitian menunjukan bahwa arsitektur VGG16 memberikan akurasi pelatihan sebesar 100%, akurasi validasi sebesar 88% dan akurasi pengujian data baru sebesar 90%. Dalam penelitian ini, VGG16 menunjukan performa yang baik dalam klasifikasi gambar penyakit kulit wajah[17].

Penelitian yang dilakukan oleh Saiwaeo dan tim, mereka mengembangkan model klasifikasi untuk jenis kulit menggunakan CNN. Arsitektur CNN seperti

MobileNet-V2, EfficientNetV2, InceptionV2, dan ResNet-V1 dioptimasikan dan dievaluasi. Hasil dari penelitian ini, arsitektur EfficientNetV2 menunjukkan performa yang baik dibanding arsitektur lain. Dengan hasil akurasi 91.55% dan nilai kerugian (*loss*) 21.68%, model berhasil mengklasifikasi jenis kulit dengan benar dan model mampu menangkap pola yang relevan untuk membedakan antara jenis kulit [18].

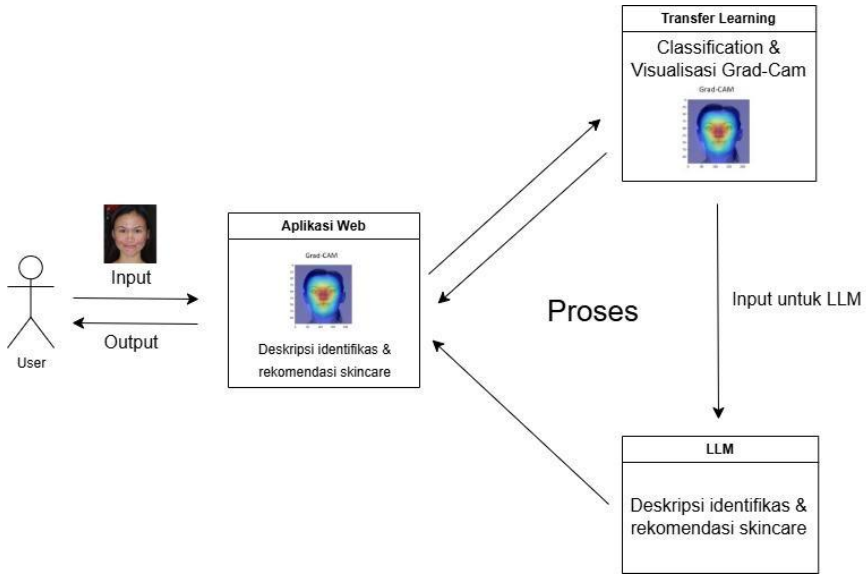
Penelitian lain juga dilakukan oleh Sundari dan tim menggunakan metode CNN dengan arsitektur EfficientNet-B0 untuk klasifikasi jenis kulit wajah dengan 1.550 data gambar. Hasilnya menunjukan akurasi, precision, recall, dan F1-score sebesar 100%, serta *loss* sebesar 0.001[19].

Wiguna dan tim melakukan penelitian mengenai masalah pada kulit wajah menggunakan metode CNN. Arsitektur CNN seperti MobileNet, VGG16, dan ResNet50 digunakan untuk klasifikasi masalah kulit wajah. Dari hasil penelitian, ditemukan arsitektur MobileNet unggul dibanding dua arsitektur lain dengan akurasi 76% [20].

Penelitian yang dilakukan oleh Futri dan tim mengimplementasikan arsitektur MobileNet untuk klasifikasi jenis kulit wajah menjadi tiga kelas, yaitu kulit normal, kering, dan berminyak. *dataset* yang digunakan terdiri dari 450 gambar. Hasil uji menunjukan akurasi sebesar 99%, *loss* 3.73%, serta nilai precision, recall, dan F1-score sebesar 100% pada kelas kulit kering[21].

Berdasarkan permasalahan yang telah diuraikan dan didukung oleh hasil-hasil penelitian yang sudah dilakukan sebelumnya, maka penelitian ini mengusulkan pengembangan sistem identifikasi permasalahan kulit wajah dengan menggabungkan model CNN menggunakan pendekatan Transfer Learning dan

LLM untuk memberikan solusi inovatif dalam identifikasi permasalahan kulit wajah dan pemberian rekomendasi skincare. Dengan menggunakan Transfer Learning, keterbatasan dataset dapat diatasi, sementara LLM dimanfaatkan untuk menghasilkan deskripsi masalah kulit wajah serta memberikan rekomendasi skincare yang sesuai. Dengan demikian, penelitian ini bertujuan untuk menghadirkan solusi inovatif berbasis AI yang mampu membantu pengguna mengenali masalah kulit wajah dan memperoleh rekomendasi skincare yang tepat dan mudah dipahami.



Gambar 1.3 Ilustrasi cara kerja sistem identifikasi permasalahan kulit wajah dan rekomendasi skincare.

Sistem ini beroperasi dengan alur kerja seperti, *user* mengunggah gambar wajah melalui *interface* aplikasi web. Gambar yang diterima kemudian diproses ke modul *transfer learning.* Modul ini bertugas melakukan klasifikasi dan menghasilkan visualisasi menggunakan teknik Grad-CAM. Visualisasi dari Grad-CAM yang menyoroti area wajah yang bermasalah, diteruskan sebagai *input* untuk LLM. LLM akan mengolah informasi dari *input* tersebut dan menghasilkan deskripsi mengenai masalah kulit wajah yang teridentifikasi, serta rekomendasi

produk *skincare* yang sesuai. Hasil akhir ini dikirim kembali ke aplikasi web untuk ditampilkan kepada pengguna. Selain itu, aplikasi web juga menerima langsung hasil visualisasi Grad-CAM dari modul *transfer learning* untuk ditampilkan sebagai output.

1.2. Rumusan Masalah

Berdasarkan uraian pada latar belakang, penelitian ini berfokus pada pengembangan dan implementasi solusi berbasis kecerdasan buatan untuk identifikasi permasalahan kulit wajah serta rekomendasi skincare yang bersifat personal. Berdasarkan hal tersebut, rumusan masalah yang akan dibahas dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membuat dan melakukan komparasi model Transfer Learning untuk identifikasi permasalahan kulit wajah?
2. Bagaimana mengimplementasikan Transfer Learning untuk mengidentifikasi permasalahan kulit wajah ke aplikasi web?
3. Bagaimana mengimplementasi LLM untuk memberikan rekomendasi skincare yang sesuai dan personal ke aplikasi web?

1.3. Tujuan Penelitian

Berdasarkan yang telah diuraikan pada latar belakang, maka rumusan masalah yang ditemukan adalah sebagai berikut:

1. Membangun dan membandingkan performa beberapa model Transfer Learning untuk identifikasi permasalahan kulit wajah.
2. Mengembangkan sistem klasifikasi permasalahan kulit wajah dengan memanfaatkan Transfer Learning ke aplikasi web.

3. Mengimplementasikan LLM, seperti Gemini, ke dalam aplikasi web untuk memberikan rekomendasi perawatan yang sesuai dan personal.

1.4. Manfaat Penelitian

Manfaat penelitian ini diharapkan dapat:

1. Bagi pengguna

   Penelitian ini memberikan manfaat langsung bagi pengguna, khususnya pengguna yang kesulitan mengenali masalah wajah secara mandiri. Membantu pengguna untuk lebih tahu mengapa dan bagaimana mengatasi permasalahan kulit wajah. Penelitian ini membantu menyediakan solusi alternatif yang inovatif bagi pengguna yang kesulitan mengakses dermatolog dengan memanfaatkan teknologi yang ada. Membantu pengguna dengan memberi saran pemilihan produk dan perawatan skincare yang sesuai dengan kondisi kulit wajah mereka.

2. Bagi Peneliti

   Penelitian ini memberikan kesempatan untuk mendalami dan menerapkan teknologi terkini dalam bidang kecerdasan buatan, khususnya pada transfer learning dan LLM. Peneliti juga memperoleh pengalaman dalam merancang sistem AI yang bersifat multimodal, yaitu memproses data visual dan menghasilkan output berbasis teks.

3. Bagi Penelitian Lain

   Penelitian ini dapat menjadi referensi dan pijakan awal bagi penelitian selanjutnya yang ingin mengembangkan sistem berbasis AI untuk analisis permasalahan kulit wajah atau bidang lain yang melibatkan kombinasi data gambar dan teks..

1.5. Ruang Lingkup Penelitian

Ruang lingkup penelitian bertujuan untuk menentukan cakupan dan batasan dari penelitian ini, supaya membantu peneliti fokus kepada topik yang akan diteliti.

1.5.1. Cakupan Penelitian

1. Penelitian ini menerapkan metode *Transfer Learning* dengan empat *pre-trained* model, yaitu VGG, ResNet, EfficientNet, dan MobileNet.
2. LLM yang akan digunakan yaitu Gemini 2.5 Flash untuk memberikan deskripsi dari hasil Grad-CAM dan menyusun rekomendasi skincare.
3. Teknik Grad-CAM digunakan untuk visualisasi model dengan menampilkan area kulit wajah yang terdeteksi memiliki masalah.
4. Penulisan kode menggunakan Kaggle Notebook dengan bahasa pemrograman Python.
5. LLM akan memvalidasi jenis gambar yang diinput oleh user. Jika gambar teridentifikasi sebagai kulit wajah, gambar akan diteruskan ke proses klasifikasi. Jika tidak, sistem akan menampilkan pesan bahwa gambar tidak sesuai.
6. Sistem klasifikasi difokuskan pada enam jenis permasalahan kulit wajah, yaitu jerawat, dark-spot, kulit kering, kulit berminyak, kemerahan, dan kerutan.
7. Dataset yang akan digunakan untuk membangun model akan melalui proses validasi oleh pakar untuk memastikan label jenis permasalahan kulit wajah pada gambar sesuai.
8. Optimasi model hanya menggunakan tiga metode yaitu hanya Adamax, RMSprop, dan SGD.

9. Pengaturan *hyperparameter* seperti *batch size, learning rate,* dan *epoch* untuk mengoptimalkan performa model dalam identifikasi permasalahan kulit wajah.
10. Evaluasi model dilakukan dengan confusion matrix seperti akurasi, presisi, recall, dan F1-score untuk menilai performa klasifikasi.
11. *Framework* Flask digunakan dalam membangun aplikasi web yang memungkinkan pengguna mengunggah gambar wajah dan mendapatkan hasil analisis serta rekomendasi skincare.
12. Sistem dapat menghasilkan tautan langsung ke produk skincare yang direkomendasikan agar pengguna dapat terhubung dengan platform e-commerce.

1.5.2. Batasan Penelitian

1. Sistem ini berfungsi sebagai alat bantu awal untuk mengenali masalah pada kulit dan memberikan saran perawatan skincare secara non-medis. Sistem ini tidak menggantikan peran dokter, melainkan memberikan alternatif awal bagi masyarakat yang kesulitan mengakses konsultasi langsung, tanpa memberikan diagnosis klinis.
2. Penelitian ini hanya mengidentifikasi gambar yang berasal dari user yang telah atau sedang mengalami permasalahan kulit wajah.
3. Data input dari end-user dibatasi pada gambar wajah dalam posisi frontal dengan pencahayaan yang cukup.
4. Format data yang digunakan hanya mendukung JPEG dan PNG.
5. Permasalahan kulit yang dapat dikenali hanya terbatas pada enam kategori yang telah ditentukan.

6. Penelitian ini berfokus pada pengembangan dan pelatihan model kecerdasan buatan untuk mengidentifikasi permasalahan kulit wajah berdasarkan gambar wajah.
7. Dataset yang digunakan hanya mencakup label jenis permasalahan kulit wajah. Faktor-faktor seperti ras, usia, dan jenis kelamin tidak dilibatkan dalam proses pengembangan maupun evaluasi model.
8. Integrasi e-commerce dalam sistem ini hanya mencakup 6 platform yang telah ditentukan.

1.6. Daftar Istilah

1. *Artificial Intelligence* (AI) : Cabang ilmu komputer yang berfokus pada pembuatan sistem yang dapat meniru kecerdasan manusia.
2. *Dataset* : Kumpulan data yang digunakan untuk melatih model.
3. *Machine Learning* : Cabang dari AI yang dimana komputer dapat belajar dari data.
4. *Deep Learning* : Cabang dari *Machine Learning* yang menggunakan saraf tiruan untuk memproses data.
5. *Hyperparameter* : parameter yang ditentukan sebelum pelatihan untuk mengatur cara model belajar.
6. *Convolutional Neural Network* (CNN) : Arsitektur *Deep Learning* yang dirancang untuk mengenali pola dalam data visual seperti gambar.
7. *Transfer Learning:* Mempercepat proses pelatihan dan mengurangi kebutuhan data yang besar.
8. *Large Language Model* (LLM) : Model bahasa berskala besar yang mampu memahami dan menghasilkan teks secara otomatis.

9. *Train* : Proses melatih model dengan memberikan dataset sehingga model dapat belajar mengenali pola dan membuat prediksi.
10. *Pre-trained* : Model yang sudah dilatih sebelumnya menggunakan dataset besar.
11. *Framework* : Kerangka kerja yang mempermudah pengembangan aplikasi web.
12. Pengguna : Pihak yang menggunakan sistem. Dalam penelitian ini, Pengguna adalah masyarakat umum yang ingin mencari tahu masalah kulit wajah yang dialami.

BAB 2

TINJAUAN LITERATUR

Pada bab ini peneliti akan membahas landasan teori ini serta penelitian yang terkait, metode, konsep dan definisi yang berkaitan dengan masalah yang diteliti.

2.1. Permasalahan Kulit Wajah

Permasalahan kulit wajah merupakan isu umum yang dapat mempengaruhi penampilan, rasa percaya diri dan bahkan kesehatan mental seorang[17]. Berbagai permasalahan kulit wajah memiliki penyebab dan cara penanganan yang berbeda-beda. Oleh karena itu dibutuhkan pendekatan identifikasi dan penanganan spesifik. Untuk memberikan gambaran yang lebih jelas, berikut dijelaskan beberapa permasalahan kulit wajah yang menjadi fokus pada penelitian ini.

a. Jerawat

Salah satu permasalahan kulit wajah yang paling sering ditemui adalah jerawat. Jerawat atau Acne adalah jenis permasalahan kulit yang sering terjadi dikalangan remaja dan orang dewasa. Jerawat terjadi ketika folikel rambut tersumbat oleh minyak(sebum) dan sel kulit mati yang menyebabkan peradangan. Dengan munculnya benjolan kecil karena pori-pori yang tersumbat, dapat memicu aktivitas bakteri yang berkontribusi pada peradangan[22]. Dalam penelitian ini, jerawat dipilih menjadi salah satu permasalahan kulit wajah yang dipilih karena tampilan visualnya yang khas. Peneliti mengambil karakteristik visual dari kondisi ini dan melatih model sehingga model dapat mengidentifikasi permasalahan kulit wajah ini.

b. Dark-Spot

Dark-spot atau *Hyperpigmentation* merupakan kondisi kulit wajah yang umum terjadi, dimana warna kulit menjadi lebih gelap. Perubahan pada warna kulit ini merupakan hasil dari berbagai faktor internal dan eksternal termasuk perubahan hormonal, peradangan, luka, jerawat, eksim, pengobatan tertentu atau paparan sinar UV. Kondisi ini terjadi ketika produksi pigmen kulit yang disebut melanin yang diproduksi oleh melanosit di berbagai lapisan kulit[23]. Peneliti memilih dark-spot sebagai salah satu jenis permasalahan yang diklasifikasi. Karena kontras warna dengan kulit normal yang jelas, maka dapat diolah sebagai fitur dalam model klasifikasi.

c. Kulit Kering

Kulit Kering atau *Xerosis cutis* adalah kondisi kulit seperti sisik kecil hingga besar, retakan, dan peradangan yang disebabkan oleh kurangnya hidrasi. Selain penyebab eksternal dan pemicu internal, seperti penuaan, kondisi kesehatan internal, penyakit dermatologis atau kejiwaan, pola makan, dan obat-obatan. Pada kondisi ini, stratum korneum (SC) gagal mempertahankan gradien konsentrasi air yang cukup antara sel epidermis yang hidup dan permukaan kulit[24]. Karakteristik-karakteristik dari kondisi ini digunakan sebagai pelatihan model CNN. Maka dari itu, peneliti memilih permasalahan kulit ini karena tampilan visual dan tekstur berbeda dari kulit normal sehingga model dapat mengidentifikasinya.

d. Kulit Berminyak

Kulit Berminyak atau *Seborrhea* dikarakteristikan dengan aktivitas berlebihan dari kelenjar sebaceous yang menghasilkan sekresi sebum berlebihan. Seborrhea lebih sering terjadi pada orang kulit berwarna dan pria. Lapisan lipid

permukaan kulit, yang dihasilkan oleh kelenjar sebaceous, merupakan bagian penting dari pelindung kulit. Perubahan yang terjadi pada lapisan lipid ini dapat berkontribusi pada timbulnya penyakit inflamasi kulit yang umum terjadi, seperti acne vulgaris (jerawat), rosacea (kemerahan), atau dermatitis seboroik[25]. Dalam penelitian ini, permasalah kulit wajah ini dipilih karena tampilan visualnya yang mengkilap sehingga dapat menjadi fitur yang digunakan untuk model klasifikasi.

e. Kemerahan

Kemerahan atau *Erythema* adalah reaksi kemerahan kulit oleh kulit wajah yang dihasilkan oleh stimulus eksternal atau infeksi virus . Kondisi ini merupakan hasil dari reaksi inflamasi kulit yang berhubungan dengan penyakit seperti jerawat, psoriasis, demam akibat penyakit sistemik, serta iritasi akibat sinar matahari[26]. Pada penelitian ini, peneliti menggunakan karakteristik dari kemerahan untuk mengidentifikasinya dengan model CNN yang telah dilatih.

f. Kerutan

Kerutan atau *Rhytids* adalah perubahan pada tekstur kulit yang dihasilkan oleh kombinasi beberapa faktor seperti penuaan, kerusakan akibat sinar matahari, dan kendur nya kulit. Selain dari itu, perulangan ekspresi wajah dapat menyebabkan kerutan. Jenis-jenis kerutan berupa garis-garis halus, kerutan dinamis, dan kerutan statis[27]. Kerutan memiliki bentuk dan pola tertentu yang dapat dikenali dari gambar. Peneliti mengambil karakteristik tersebut dan menggunakannya sebagai pelatihan model CNN.

2.2. Skincare

Skincare adalah serangkaian perawatan kulit yang dilakukan menggunakan produk tertentu untuk menjaga kesehatan, kebersihan, dan penampilan kulit,

khususnya pada area wajah. Produk *skincare* berperan penting dalam melindungi kulit dari kerusakan, menjaga kelembapan, serta mencegah dan mengatasi berbagai masalah kulit wajah[28][29]. Saat ini, skincare juga menjadi bagian dari gaya hidup karena tidak hanya menjaga kesehatan kulit, tetapi juga meningkatkan rasa percaya diri, baik bagi perempuan maupun laki-laki[30]. Maka dari itu, berbagai jenis produk *skincare* telah dikembangkan dan digunakan dalam rutinitas perawatan kulit.

Jenis-jenis *skincare* cukup beragam dan biasanya dilakukan dalam beberapa tahap. Beberapa produk yang umum digunakan antara lain pembersih wajah (*cleanser*), *toner*, pelembap (*moisturizer*), dan *sunscreen*. Selain itu, ada juga produk tambahan seperti serum, masker wajah, dan produk lainnya. Setiap jenis memiliki manfaat tersendiri, mulai dari membersihkan pori-pori, menutrisi, hingga melindungi kulit dari paparan sinar matahari[29][30]. Pemilihan produk *skincare* sebaiknya disesuaikan dengan jenis dan kebutuhan kulit individu.

Untuk itu, mengenal berbagai jenis produk *skincare* menjadi langkah penting dalam membangun sistem rekomendasi yang akurat. Berikut adalah beberapa produk skincare utama yang digunakan dalam rutinitas perawatan kulit wajah.

a. Cleanser

Cleanser adalah produk perawatan kulit yang dirancang untuk membersihkan kotoran, minyak berlebih, dan residu kosmetik dari permukaan kulit. Fungsi utama *cleanser* adalah menjaga kebersihan kulit dan mencegah penyumbatan pori yang bisa menyebabkan jerawat dan iritasi. Pembersih wajah

memainkan peran penting dalam menghilangkan partikel lingkungan dan mikroorganisme yang menempel di kulit, terutama pada kulit yang sensitif[31].

Penggunaan *cleanser* yang tepat juga membantu menjaga keseimbangan pH kulit dan mempersiapkan kulit untuk tahap perawatan selanjutnya seperti toner atau pelembab. Namun, tidak semua *cleanser* dibuat sama. Ada yang terlalu keras dan justru merusak lapisan pelindung kulit. Oleh karena itu sangat penting memilih produk dengan kandungan lembut dan sesuai dengan tipe kulit[31][32]. Informasi mengenai karakteristik cleanser akan digunakan untuk merekomendasikan produk yang sesuai berdasarkan jenis kulit dan masalah yang teridentifikasi dari gambar wajah user.

b. Toner

Toner adalah cairan yang digunakan setelah pembersihan wajah, toner membantu mengangkat sisa kotoran dan minyak yang mungkin masih tertinggal. Toner juga membantu menyeimbangkan pH kulit dan menyegarkan wajah, sehingga siap untuk menyerap serum dan pelembab. Meski terlihat ringan, toner bisa mengandung bahan aktif. Toner yang diformulasikan dengan tepat mampu membantu memperkuat fungsi pelindung kulit dan mengurangi risiko iritasi[33]. Rekomendasi toner akan disesuaikan dengan tingkat sensitivitas kulit yang teridentifikasi melalui analisis gambar wajah, sehingga user mendapatkan produk yang sesuai dengan kondisi kulit.

c. Moisturizer

Moisturizer adalah produk yang berfungsi menjaga kelembaban kulit dengan memperkuat fungsi penghalang kulit dan mencegah kehilangan air berlebih. Pelembab dibagi menjadi tiga jenis utama yaitu occlusive, humectant, dan

emollient. Setiap jenis memiliki mekanisme kerja yang berbeda namun saling melengkapi dalam menjaga hidrasi kulit. Moisturizer sangat penting dalam perawatan kulit karena berfungsi memperbaiki dan menjaga struktur lapisan luar kulit. Moisturizer tidak hanya meningkatkan kenyamanan kulit kering, tetapi juga mampu mencegah gejala iritasi seperti gatal, kemerahan, dan rasa terbakar[34]. Hasil identifikasi kulit wajah seperti kekeringan akan digunakan sebagai dasar dalam merekomendasikan jenis moisturizer yang sesuai.

d. Serum

Serum wajah merupakan produk yang mengandung bahan aktif dengan konsentrasi yang tinggi. Serum memiliki tekstur ringan dan molekul kecil yang memungkinkannya menyerap lebih dalam ke lapisan kulit. Inilah yang membuat serum mampu untuk mengatasi masalah kulit tertentu seperti noda hitam, kerutan, dan kulit kering. Serum bisa mengandung hingga 70% bahan aktif seperti asam hialuronat yang menjaga kelembapan, atau vitamin C yang bekerja sebagai antioksidan dan membantu mencerahkan kulit. Karena tingkat penetrasinya tinggi, pemilihan serum yang tepat sangat penting agar hasilnya maksimal dan tetap aman bagi kulit[35]. Identifikasi permasalahan spesifik seperti hiperpigmentasi atau kerutan akan diarahkan pada rekomendasi serum dengan kandungan bahan aktif yang sesuai.

e. Sunscreen

Paparan sinar matahari adalah salah satu faktor utama yang mempercepat penuaan kulit. Di sinilah peran sunscreen menjadi sangat penting. Sunscreen bekerja dengan menyerap atau memantulkan sinar ultraviolet (UV) agar tidak menembus ke dalam kulit. Di negara tropis seperti Indonesia, sunscreen dengan

SPF 30 ke atas sangat direkomendasikan untuk perlindungan optimal. Sunscreen dengan SPF 15 mampu memberikan perlindungan sekitar 93%, sementara SPF 30 memberikan perlindungan 96,7%. Selain mencegah kulit terbakar, sunscreen juga berperan besar dalam menurunkan risiko kanker kulit dan mencegah munculnya flek hitam[36]. Pada penelitian ini, sistem akan merekomendasikan sunscreen dengan tingkat SPF yang sesuai berdasarkan identifikasi intensitas noda hitam pada wajah yang dideteksi oleh model.

f. Masker Wajah

Masker wajah adalah produk perawatan kulit yang digunakan secara berkala untuk memberikan nutrisi tambahan, membersihkan secara mendalam, dan memperbaiki kondisi kulit. Masker dapat berupa gel, krim, lembaran, atau bubuk yang dicampur air. Pemakaian rutin masker wajah dapat meningkatkan kelembaban kulit, merangsang regenerasi sel, dan membantu menjaga elastisitas kulit seiring bertambahnya usia[37][38]. Rekomendasi jenis masker akan dikaitkan pada kebutuhan kulit user seperti hidrasi atau peremajaan, berdasarkan hasil identifikasi kondisi kulit wajah.

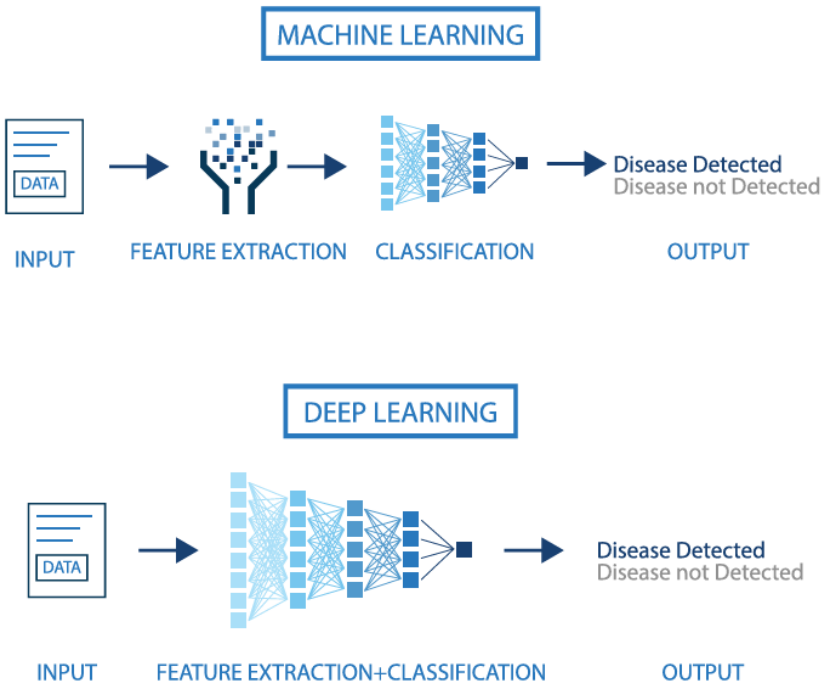
2.3. Neural Network

Neural Network merupakan model pemrosesan data yang didasari oleh jaringan saraf manusia seperti otak untuk memproses data. *Neural Network* digunakan dalam berbagai pengenalan pola, klasifikasi gambar, prediksi dan lainnya karena kemampuan dalam menangkap pola kompleks dari data. *Neural Network* terdiri dari unit-unit pemrosesan yang disebut neuron yang saling terhubung. *Neural Network* terdiri dari tiga jenis lapisan yaitu Input Layer, Hidden Layer dan Output Layer. Lapisan-lapisan ini bekerjasama untuk memproses

informasi dari data dan menghasilkan output yang relevan. Melalui proses pembelajaran, *Neural Network* dapat menyesuaikan respons yang konsisten dari berbagai masukan[39]. Maka dari itu, peneliti memilih model ini untuk melakukan pengenalan permasalahan kulit wajah dan melakukan klasifikasi dari gambar.

2.4. Deep Learning

Deep learning merupakan cabang dari *Machine Learning* yang memanfaatkan jaringan saraf tiruan dengan banyak lapisan (*deep neural networks*) untuk mempelajari representasi data secara otomatis. Teknologi ini dirancang untuk meniru cara kerja otak manusia dalam mengenali pola dan membuat keputusan[40][41]. Berbeda dengan *Machine Learning* yang memerlukan ekstraksi fitur secara manual, *deep learning* memungkinkan model untuk belajar langsung dari data mentah. Hal ini membuat *deep Learning* mampu mengolah data yang kompleks dan tidak terstruktur seperti gambar, teks, serta suara[42].



Gambar 2.1 Ilustrasi perbedaan Machine Learning dan Deep Learning[43].

Deep learning bekerja dengan mengubah input melalui beberapa lapisan neuron. Setiap neuron memproses informasi menggunakan fungsi aktivasi, kemudian hasilnya diteruskan ke lapisan berikutnya. Model melakukan pembelajaran dengan menyesuaikan bobot antar *neuron* melalui mekanisme *backpropagation*, yaitu proses evaluasi kesalahan prediksi dan penyesuaian parameter agar tingkat akurasi meningkat[44]. Dengan memahami cara kerja *deep learning*, penting juga untuk mengenal berbagai arsitektur yang dikembangkan untuk menangani jenis data dan permasalahan tertentu.

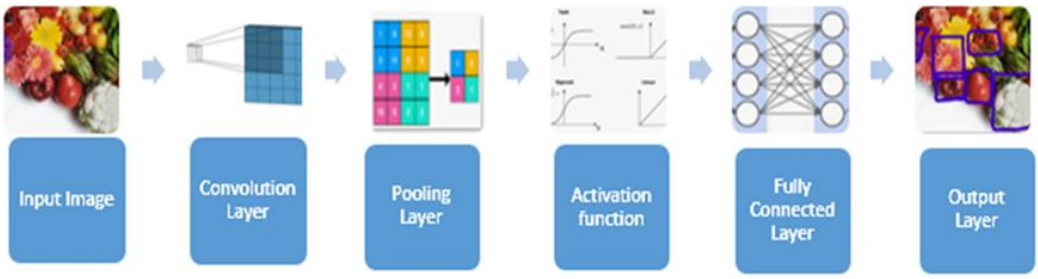
Beberapa arsitektur utama dalam *deep learning* meliputi *Convolutional Neural Networks* (CNN) yang digunakan untuk pengolahan data visual, *Recurrent Neural Networks* (RNN) yang cocok untuk data berurutan seperti teks dan audio, serta *Autoencoders* yang berfungsi untuk kompresi data dan deteksi anomali. Selain itu, *Generative Adversarial Networks* (GANs) dipakai untuk menghasilkan data baru yang menyerupai data asli[44][41]. Arsitektur-arsitektur tersebut menjadi dasar penting dalam berbagai aplikasi kecerdasan buatan saat ini. Penelitian ini menggunakan *deep learning* khususnya model arsitektur CNN, karena memiliki kelebihan dalam mendeteksi objek dan klasifikasi gambar kulit wajah.

2.5. Convolutional Neural Networks (CNN)

Convolutional Neural Networks (CNN) merupakan salah satu arsitektur jaringan saraf tiruan yang termasuk dalam kategori Deep Learning. CNN dirancang khusus untuk pemrosesan data berdimensi grid, seperti gambar, dan telah menunjukan kinerja yang baik dalam berbagai tugas computer vision seperti klasifikasi gambar, segmentasi gambar, deteksi objek, serta pengenalan suara dan

teks[45]. Untuk memahami alasan dibalik efektifitas CNN, penting untuk melihat bagaimana arsitektur ini bekerja dalam memproses data visual.

CNN bekerja dengan mengekstraksi fitur-fitur penting dari input gambar secara otomatis melalui serangkaian lapisan yang berfungsi untuk menyaring, mengurangi dimensi dan mengklasifikasikan informasi yang ada pada inputan gambar. Seperti cara kerja sistem visual manusia, CNN memproses informasi visual secara bertingkat dari fitur sederhana seperti garis, hingga menjadi representasi kompleks seperti wajah atau objek[46]. Peneliti memilih CNN karena kemampuannya dalam mengekstrak fitur-fitur penting dari gambar dan kinerjanya yang baik dalam *computer vision.*



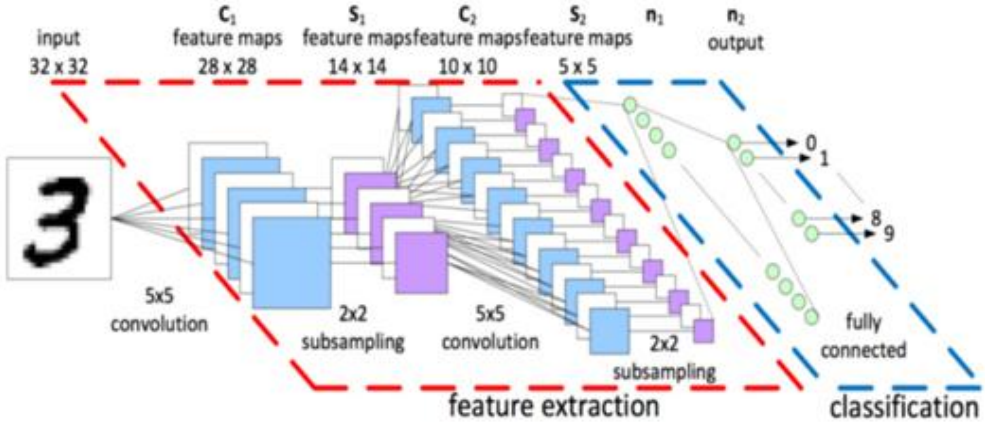
Gambar 2.2 Komponen CNN [46].

2.5.1. Convolutional Layer

Convolutional Layer merupakan komponen dalam CNN yang bekerja untuk mengekstraksi fitur-fitur penting dari citra input[45]. Proses ini dilakukan menggunakan filter atau kernel yang bergerak melintasi gambar dan melakukan operasi konvolusi. Setiap filter memiliki bobot yang akan dilatih selama proses pembelajaran untuk mengenali pola tertentu, seperti tepi, sudut atau tekstur[46].

Setiap filter akan bergerak (sliding) melintasi gambar input dengan langkah (stride) tertentu dan menghitung hasil perkalian elemen sepadan antara nilai piksel gambar dan bobot filter. Hasilnya berupa *feature map* atau *activation map* yang

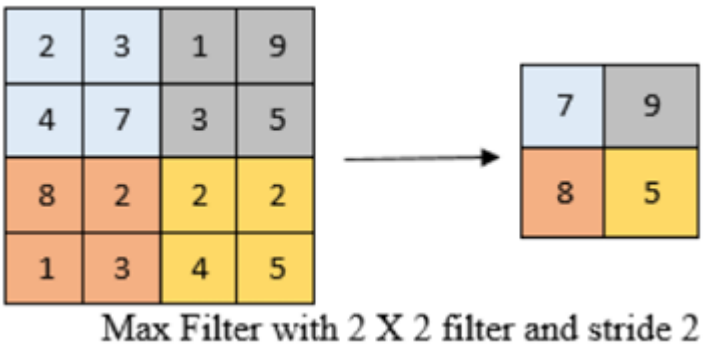
merepresentasikan kehadiran fitur tertentu pada lokasi spesifik[46]. Peneliti menggunakan lapisan ini untuk menangkap fitur-fitur penting yang ada pada gambar.



Gambar 2.3 Convolutional Layer[46].

2.5.2. Pooling Layer

Pooling Layer berfungsi untuk mengurangi dimensi dari feature map sekaligus mempertahankan informasi fitur penting. Pooling bertujuan untuk mengurangi ukuran representasi tanpa kehilangan informasi utama, juga membuat model lebih tahan terhadap translasi kecil pada input.



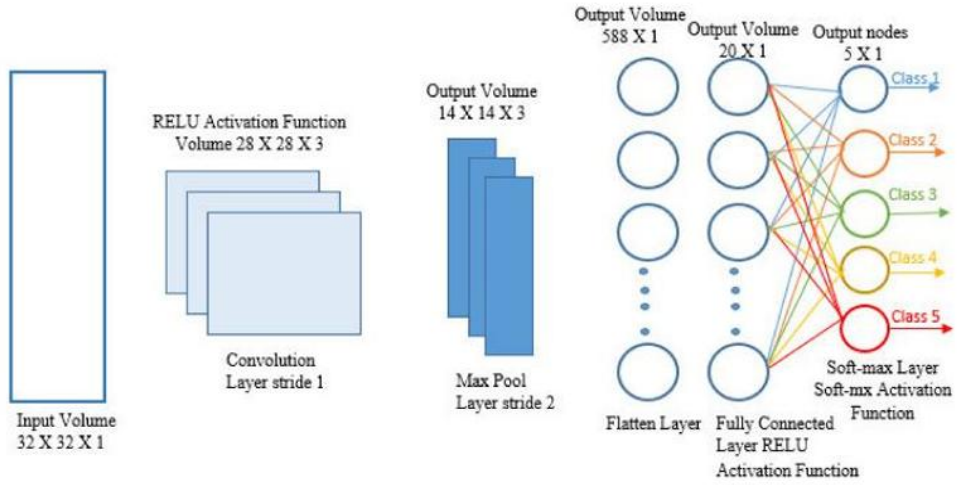
Gambar 2.4 Pooling Layer[46].

Gambar diatas adalah contoh terapan dari max pooling 2x2 dengan stride 2 pada feature map 4x4. Dimana hasilnya adalah feature map baru berukuran 2x2.

Pooling juga membantu mengurangi overfitting dan beban komputasi [45]. Dengan lapisan ini, peneliti dapat mengurangi kompleksitas komputasi tanpa menghilangkan data penting.

2.5.3. Fully Connected Layer

Fully Connected Layer adalah salah satu dari lapisan yang ada pada CNN. Setelah melewati lapisan konvolusi dan pooling, output yang berupa fitur yang diekstraksi akan dialirkan ke *Fully Connected Layer*. Sebelum memasuki lapisan Fully Connect, fitur map dari lapisan sebelumnya akan diratakan menjadi vektor satu dimensi dan proses ini disebut *flattening*. Dengan begitu lapisan ini mengembalikan probabilitas dari prediksi kelas dengan membangun kombinasi fitur non-linear. Fungsi non-linear memiliki beberapa fungsi seperti Activation Function, ReLu, dan Softmax[47]. Lapisan ini bekerja sebagai penggolongan akhir dengan menghubungkan neuron di satu lapisan dengan seluruh neuron di lapisan berikutnya. Peneliti menggunakan lapisan ini untuk menggabungkan informasi dari lapisan sebelumnya dan mempelajari jika ada korelasi antar fitur.



Gambar 2.5 Fully Connected Layer[45].

2.5.4. Activation Functions

Activation Functions menjadi komponen dasar dalam CNN, dengan memperkenalkan non-linearitas ke dalam jaringan. Non-linearitas ini sangatlah krusial untuk kemampuan CNN untuk memodelkan pola dan hubungan yang kompleks yang ada di dalam data. Ini juga memungkinkan untuk menyelesaikan tugas-tugas di luar klasifikasi atau regresi linear sederhana[48]. Tanpa nonlinear activation functions, CNN akan terbatas pada operasi linear. Hal ini secara signifikan membatasi kemampuannya untuk secara akurat merepresentasikan perilaku non linear yang rumit, yang merupakan fenomena dunia nyata[49]. Banyak fenomena dunia nyata menunjukan perilaku non-linear yang kompleks dan model yang menggunakan operasi linear tidak dapat memahami fenomena ini secara akurat. Dengan begitu, Activation Function dapat membantu CNN untuk menjadi lebih ekspresif dan dapat menghasilkan berbagai fungsi yang lebih luas [49]. Dengan begitu, peneliti menggunakan activation function agar model lebih fleksibel terhadap data-data non-linear. Salah satu jenis activation function yang paling umum digunakan dalam arsitektur CNN adalah Rectified Linear Unit (ReLU).

2.5.4.1. Rectified Linear Unit (ReLU)

Rectified Linear Unit (ReLu) merupakan salah satu activation function yang paling sering digunakan di CNN modern karena kemampuannya dalam mengatasi masalah hilangnya gradien saat latihan [48]. Secara matematis, ReLu didefinisikan sebagai:

$$f(x) = max(0, x)$$

dimana x adalah input ke neuron. Fungsi ini mengembalikan maximum dari 0 dan x. Secara otomatis “mematikan” nilai negatif sementara nilai positif tetap sama. Fungsi non-linear simpel ini memungkinkan pembelajaran fitur kompleks di CNN dan membantu mencegah saturasi pada neuron saat pelatihan [49]. Peneliti menggunakan fungsi ini sehingga model mampu menangkap karakteristik visual dari dari kondisi kulit.

2.6. Softmax

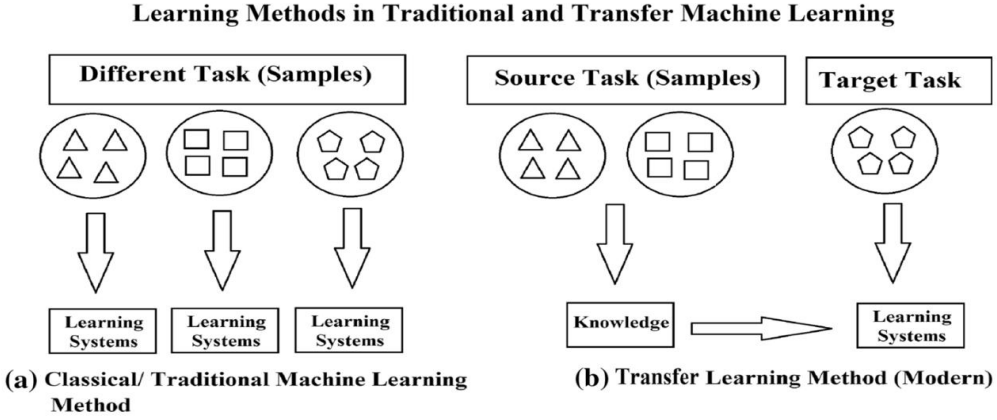
Softmax adalah fungsi aktivasi yang banyak digunakan dalam model *deep learning*, khususnya pada lapisan output untuk tugas klasifikasi dengan banyak kelas. Fungsi ini mengubah sekumpulan nilai input yang bisa berupa angka berapapun menjadi distribusi probabilitas yang totalnya selalu satu. Dengan begitu, hasil dari softmax bisa diartikan sebagai probabilitas bahwa suatu input termasuk ke dalam kelas tertentu[50]. Pada penelitian ini, Softmax membantu klasifikasi apakah hasil *output* tersebut masuk ke dalam kelas jerawat, *dark-spot*, kulit kering, kulit berminyak, kemerahan, atau kerutan. Probabilitas tertinggi akan menjadi *output* dari hasil klasifikasi.

2.7. Transfer Learning

Transfer Learning (TL) adalah paradigma Machine Learning (ML) yang bertujuan untuk meningkatkan kinerja pada tugas baru dengan memanfaatkan pengetahuan dari tugas serupa. Konsep ini didasari dari gagasan bahwa manusia dapat menyelesaikan tugas serupa dengan memanfaatkan pengetahuan yang diperoleh sebelumnya[51]. Dalam konteks ML, model tidak perlu dilatih dari awal untuk setiap tugas baru, melainkan dapat menggunakan model pre-trained sebagai

titik awal. Pendekatan ini menjadi semakin penting dalam pengembangan model deep learning, terutama ketika dihadapkan pada keterbatasan data pelatihan.

Salah satu kelebihan TL dalam konteks Deep Learning (DL), adalah kemampuan untuk menyelesaikan masalah keterbatasan data yang sering terjadi, terutama dibidang gambar medis[52]. Melatih model DL dari awal membutuhkan data terlabel dalam jumlah yang besar, dimana itu bisa jadi sangat mahal dan sulit didapat[53]. TL mengurangi ketergantungan ini dengan memungkinkan penggunaan pengetahuan sebelumnya dari kumpulan data yang luas[54]. Selain itu, TL secara signifikan mengurangi waktu dan biaya yang dibutuhkan untuk latihan[55]. Dengan menggunakan TL, peneliti dapat mengurangi waktu pelatihan model dan mengatasi keterbatasan data.

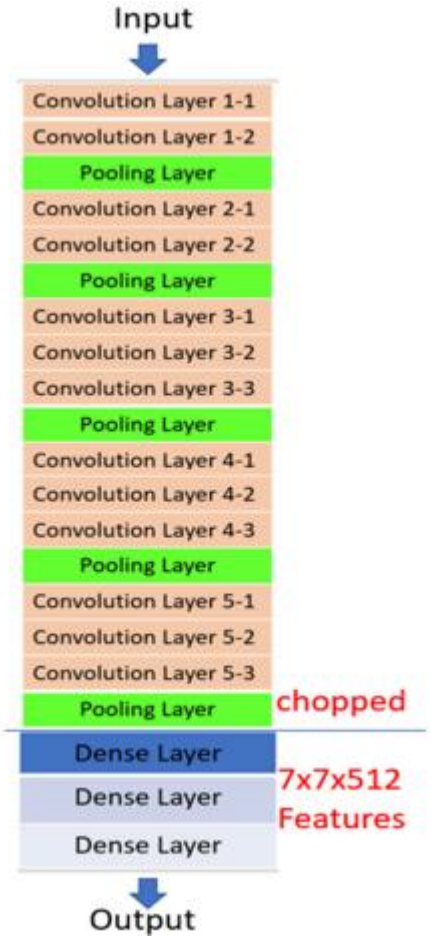


Gambar 2.6 Classical/Traditional Machine Learning vs. Transfer Learning[54].

Dalam penerapan TL, terdapat berbagai arsitektur CNN yang umum digunakan sebagai model dasar. Setiap arsitektur memiliki keunggulan dan karakteristik tersendiri yang dapat disesuaikan dengan kebutuhan tugas klasifikasi tertentu. Berikut beberapa arsitektur CNN yang akan digunakan dalam penelitian ini.

2.7.1. VGG

VGG atau Visual Geometry Group merupakan salah satu arsitektur dari CNN. VGG memiliki beberapa versi seperti VGG-16 dan VGG-19 yang masing-masing versi memiliki 16 lapisan konvolusional dan 19 lapisan konvolusional. Kelebihan dari arsitektur ini ada pada kesederhanaan dan pada kemampuan menangkap pola pada gambar[56]. Kesederhanaan arsitektur ini menjadi alasan peneliti memilih model ini untuk penelitian ini.

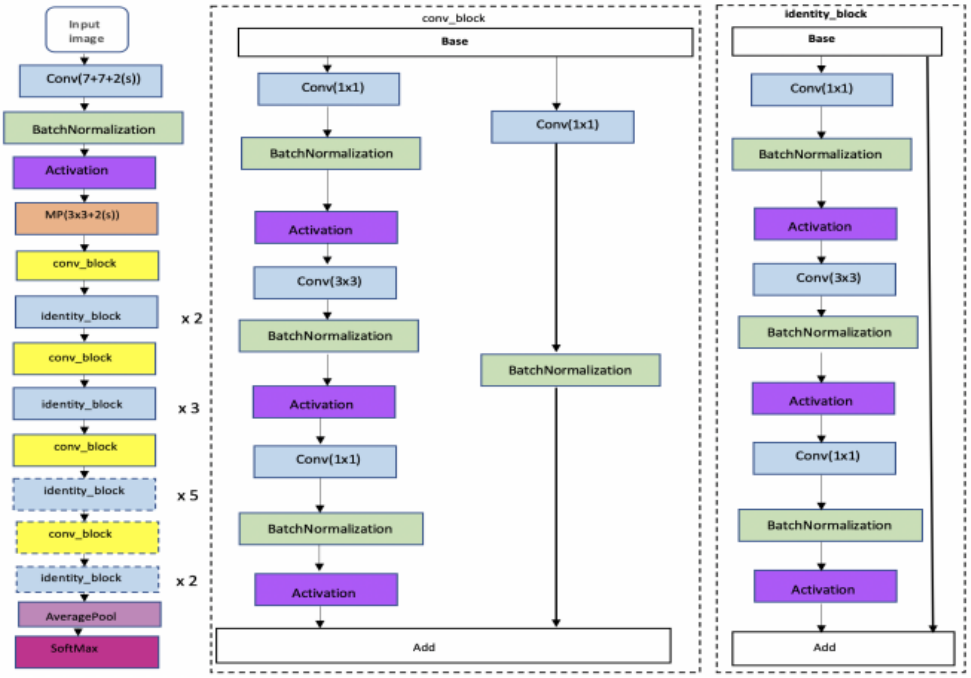


Gambar 2.7 Architecture VGG16[57].

2.7.2. ResNet

Residual Neural Network (ResNet) adalah arsitektur CNN yang digunakan di Deep Learning dan dibidang gambar medis. Struktur model ini dioptimalkan

untuk menganalisis gambar medis beresolusi tinggi. ResNet memiliki keunggulan untuk memproses gambar medis dikarenakan kemampuan mengekstrak dan mengkategorikan elemen-elemen rumit yang ada dari gambar medis[58]. Peneliti memilih arsitektur ini karena kelebihannya yang dapat melatih jaringan yang sangat dalam walaupun dengan sumber daya terbatas.

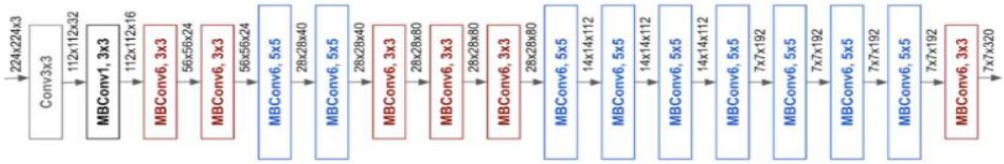


Gambar 2.8 Architecture ResNet-50[59].

2.7.3. EfficientNet

EfficientNet merupakan salah satu arsitektur CNN. EfficientNet memiliki 8 model dari B0 sampai B7, dengan setiap nomor model mengindikasikan pada varian dengan lebih banyak parameter dan akurasi lebih tinggi. EfficientNet menggunakan transfer learning untuk menghemat waktu dan daya komputasi. Oleh karena itu, EfficientNet memberikan nilai akurasi yang lebih tinggi daripada model kompetitor yang dikenal[60]. EfficientNet dimanfaatkan dalam penelitian ini

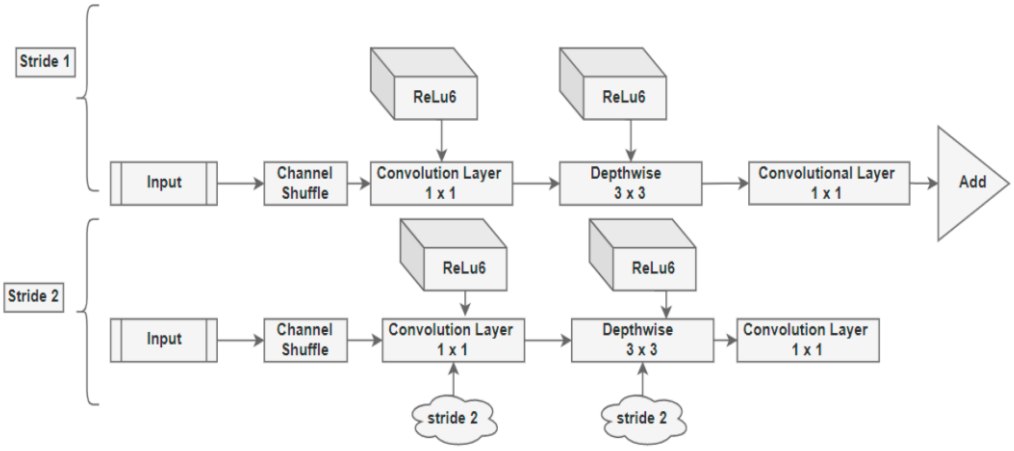
karena kelebihannya dalam keseimbangan kompleksitas model dan efisiensi pelatihan.



Gambar 2.9 Architecture EfficientNet-B0[61].

2.7.4. MobileNet

MobileNet merupakan arsitektur CNN yang ringan dan dirancang untuk aplikasi mobile dan perangkat embedded. MobileNet memiliki beberapa versi yaitu MobileNetV1, MobileNetV2, dan MobileNetv3. Model-model ini telah meraih akurasi yang tinggi di dataset ImageNet. Maka dari itu, series model MobileNet sudah terbiasa untuk mengenali wajah manusia dan ekspresinya[62]. Peneliti memilih model ini karena model ini kompatibel dengan *Transfer Learning*.



Gambar 2.10 Architecture MobileNet V2[63].

2.8. Optimizers

Optimizer merupakan komponen penting yang berfungsi untuk meminimalkam fungsi *loss* dan mempercepat konvergensi model melalui

pembaruan bobot secara iteratif. *Optimizer* bekerja berdasarkan nilai gradien dari fungsi *loss* terhadap parameter model, kemudian memilih langkah terbaik untuk menuju titik minimum. Mekanisme ini sangat penting untuk mempercepat pelatihan dan meningkatkan akurasi model dalam berbagai jenis arsitektur jaringan saraf[64][65]. Pada penelitian ini, pemilihan dan penggunaan *optimizer* yang tepat berperan penting dalam melatih model yang digunakan untuk mengidentifikasikan kondisi kulit wajah. *Optimizer* membantu sistem belajar dari data gambar dengan lebih stabil dan cepat, sehingga hasil identifikasi dapat mendekati performa optimal. Terdapat beberapa *optimizer* yang umum digunakan dalam pelatihan model *deep learning*, masing-masing dengan keunggulan dan cara kerja yang berbeda. Berikut adalah beberapa *optimizer* yang akan digunakan pada penelitian ini.

2.8.1. Stochastic Gradient Descent (SGD)

SGD adalah salah satu algoritma optimisasi paling dasar dan paling banyak digunakan dalam pelatihan model *deep learning.* SGD bekerja dengan memperbarui parameter model menggunakan gradien dari satu sampel acak atau subset kecil data pada setiap iterasi. Keunggulan utama dari SGD adalah kesederhanaan dan kemampuannya untuk bekerja dengan baik dalam menangani *dataset* berskala besar[66][67].

$$\theta = \theta - \eta . \nabla\theta J(\theta; x^{(i)} y^{(i)})$$

SGD melakukan pembaruan parameter secara langsung pada setiap data pelatihan $x^{(i)}$ dan $y^{(i)}$ menggunakan rumus di atas. Dalam hal ini, η merepresentasikan laju pembelajaran (*learning rate*), sedangkan θ adalah

parameter model yang sedang disesuaikan[68]. Peneliti menggunakan SGD sebagai baseline *optimizer* dalam proses pelatihan model CNN dalam identifikasi masalah kulit wajah. Meski sederhana, kemampuannya dalam menangani *dataset* besar menjadikannya relevan untuk digunakan pada tahap awal eksperimen.

2.8.2. RMSprop

RMSProp adalah *optimizer* berbasis adaptive *learning rate* yang mengatasi kelemahan Adagrad dalam penurunan *learning rate* terlalu cepat. RMSProp bekerja dengan menyimpan rata-rata eksponensial dari kuadrat gradien sebelumnya untuk memperbarui parameter, sehingga memungkinkan pembelajaran stabil pada data non-stasioner. Algoritma ini populer dalam berbagai aplikasi *deep learning* karena kemampuannya menjaga kestabilan dan konvergensi meskipun menggunakan data bervariasi[65][64].

$$E[g^2]t \;=\; 0.9E[g^2]t{+}1 + 0.1g^2$$

$$\theta_{t+1} \;=\; \theta_t - \frac{\eta}{\sqrt{E[g^2]_t + \epsilon}}$$

θ merupakan parameter yang sedang disesuaikan, sedangkan g_t adalah gradien dari fungsi *loss* terhadap θ pada waktu *t.* Algoritma RMSProp memperbarui parameter dengan menggunakan rumus khusus yang melibatkan $E[g^2]t$, yaitu rata-rata eksponensial dari kuadrat gradien sebelumnya. Komponen penting lainnya dalam algoritma ini termasuk η atau *learning rate,* yang mengatur besarnya langkah pembaruan parameter, serta ϵ, merupakan konstanta kecil yang ditambahkan untuk menghindari pembagian dengan nol dan meningkatkan stabilitas perhitungan secara numerik[68]. Penggunaan RMSProp dalam penelitian ini dapat membantu menghasilkan pelatihan model yang lebih stabil dan terkontrol, terutama pada *dataset* gambar kulit wajah yang memiliki distribusi dan pola bervariasi.

2.8.3. Adamax

Adamax adalah versi turunan dari algoritma optimasi Adam yang menargetkan *norm* L-infinity (*maximum norm*) dalam proses pembaruan bobot model. Adamax menghitung rata-rata pergerakan dari momen pertama dan estimasi dari *maximum norm* dari gradien. Keuntungan utama dari algoritma Adamax terletak pada kemampuannya mengatasi *noise data*, menangani gradien berukuran besar, serta menggunakan memori dalam jumlah yang relatif rendah. Selain itu, Adamax dikenal stabil dan mampu mempercepat proses pelatihan model, terutama saat digunakan pada dataset yang besar dan kompleks[68].

$$\theta_{t+1} = \theta_t - \frac{\eta}{u_t} \cdot m_t$$

$$u_t = max(\beta_2 \cdot v_{t-1}, |g_t|)$$

t merupakan indeks iterasi saat ini, sementara θ adalah parameter yang sedang dioptimasi. Nilai g_t adalah gradien dari fungsi kerugian terhadap θ pada waktu *t*. Parameter m_t mewakili rata-rata bergerak dari gradien (momen pertama), dan u_t adalah *maximum norm* dari gradien yang digunakan untuk stabilitas pembaruan. Nilai β_2 digunakan sebagai faktor peluruhan untuk menghitung nilai *maximum norm* gradien, dan η adalah *learning rate* yang mengontrol besar langkah pembaruan parameter di setiap iterasi[68]. Dalam penelitian ini, penggunaan Adamax memberikan opsi tambahan optimizer yang mampu dalam pengelolaan memori serta andal mengoptimalkan model CNN secara stabil meskipun data pelatihan memiliki kompleksitas tinggi.

2.9. Explainable AI

Explainable AI (XAI) merupakan metode yang dikembangkan untuk memberikan penjelasan mengenai output. XAI dimanfaatkan dengan memberikan penjelasan metode-metode, prosedur dan output yang dapat dimengerti oleh user[69]. Tujuan dari XAI adalah untuk mendapatkan model yang dapat diinterpretasikan oleh manusia, khususnya untuk di sektor sensitif seperti militer, perbankan dan layanan kesehatan[70]. Peneliti menggunakan XAI untuk memberi penjelasan terkait output yang dihasilkan oleh model. Salah satu teknik yang umum digunakan dalam penerapan XAI, terutama pada model CNN, adalah Grad-CAM.

2.9.1. Grad-CAM

Grad-CAM (Gradien-weighted Class Activation Mapping) merupakan salah satu teknik *Explainable AI* (XAI) yang digunakan untuk menghasilkan penjelasan visual dari klasifikasi CNN[71]. *Grad-CAM* menggunakan *heatmap* untuk memvisualisasikan hasil klasifikasi pada gambar dengan area yang paling berkontribusi. Peneliti menggunakan *Grad-CAM* untuk menunjukkan alasan model mengeluarkan hasil klasifikasi tersebut.

2.10. Large Language Model (LLM)

Large Language Model (LLM) merupakan model kecerdasan buatan berbasis arsitektur *transfomer* yang memiliki kemampuan luar biasa dalam memahami dan menghasilkan bahasa alami. LLM dilatih menggunakan data dalam jumlah besar dan terdiri dari miliaran parameter, memungkinkan model ini untuk meniru cara manusia berbahasa dengan sangat baik. Perkembangan LLM telah mengubah bidang NLP dengan kemampuannya dalam menyelesaikan berbagai tugas seperti penerjemahan, ringkasan teks, tanya jawab, hingga pembuatan kode

program secara otomatis[72]. Keunggulan utama LLM adalah kemampuannya dalam menyelesaikan tugas baru tanpa pelatihan ulang secara eksplisit hanya dengan instruksi dalam bentuk teks, menjadikan LLM sangat fleksibel dan mudah diadaptasikan ke berbagai domain seperti pendidikan, kesehatan, hukum, hingga RPL[73][74]. Penelitian ini, LLM berperan penting sebagai komponen utama dalam proses pemahaman hasil Grad-CAM dan dengan kemampuannya menghasilkan teks, digunakan untuk merekomendasikan skincare yang sesuai. Salah satu contoh penerapan LLM yang paling canggih dan relevan dalam penelitian ini adalah Gemini.

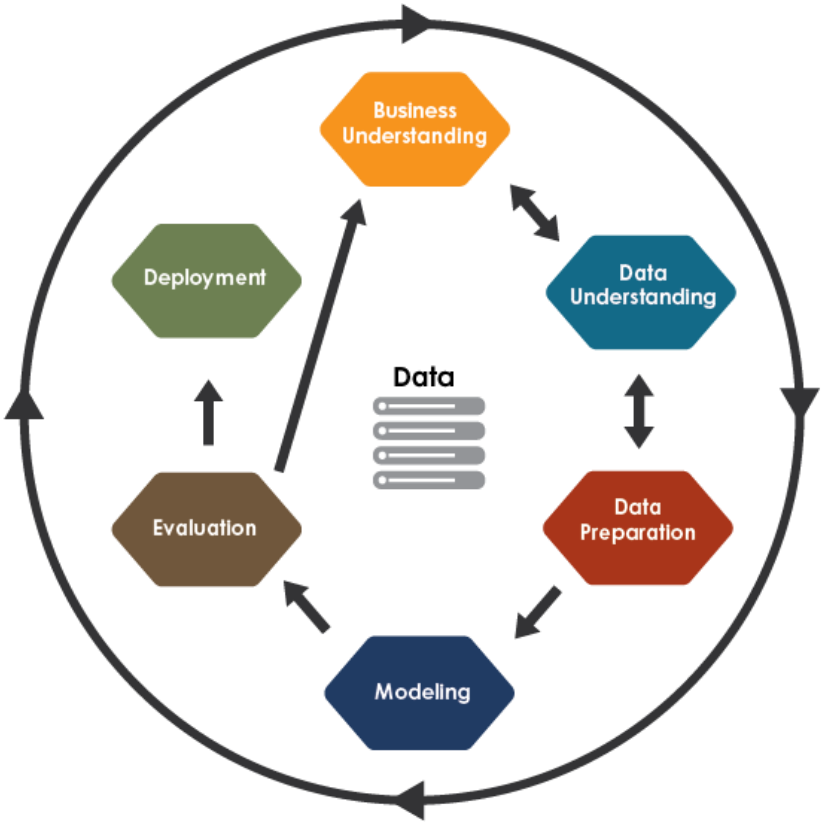
2.10.1. Gemini

Gemini adalah model AI yang dikembangkan oleh Google DeepMind dan diluncurkan pada Desember 2023 sebagai bagian dari evolusi LLM. Tidak seperti model LLM tradisional yang hanya memproses teks, Gemini mampu memahami dan menghasilkan respons dari berbagai jenis input seperti teks, gambar, audio, video, dan dokumen. Fleksibilitas ini membuat Gemini cocok untuk berbagai aplikasi di bidang pendidikan, kesehatan, dan penelitian. Selain pemanfaatannya dalam berbagai bidang, Gemini juga unggul dalam reasoning multimodal, pemecahan masalah kompleks, dan penggunaan data dunia nyata melalui integrasi dengan Google Search[75]. peneliti menggunakan Gemini karena kemampuannya dalam menganalisis dan menghasilkan teks dari input visual sangat berguna untuk memberikan penjelasan terhadap hasil identifikasi kulit wajah. Tidak hanya memberikan pemahaman terhadap permasalahan kulit wajah, Gemini juga digunakan untuk merekomendasikan produk skincare yang sesuai dengan hasil analisis tersebut, sehingga dapat memberikan solusi yang lebih personal dan relevan

bagi pengguna. Pada penelitian ini, Gemini dimanfaatkan sebagai alat bantu dalam menghasilkan deskripsi naratif terhadap hasil visualisasi Grad-CAM dan memberikan rekomendasi *skincare.* Gemini juga telah menyediakan akses bebas kepada pengguna dengan API yang ada.

2.11. CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) merupakan model proses terstruktur yang digunakan dalam data mining. Model ini memiliki enam fase utama yaitu Pemahaman Bisnis (Business Understanding), Pemahaman Data (Data Understanding), Persiapan Data (Data Preparation), Pemodelan (Modelling), Evaluasi (Evaluation), dan Penerapan (Deployment)[76]. Peneliti menggunakan model ini sebagai dasar untuk mengembangkan metode penelitian.



Gambar 2.11 CRISP-DM Life Cycle[76].

2.12. Python

Python adalah bahasa pemrograman yang dibuat oleh Guido van Rossum pada tahun 1991. Python berkembang pesat dan menjadi salah satu bahasa favorit di dunia teknologi[77]. Salah satu alasan adalah karena sintaksnya yang sederhana dan mudah dipahami, sehingga cocok digunakan oleh pemula maupun profesional[78]. Python juga bersifat interpreted, jadi program bisa langsung dijalankan tanpa perlu dikompilasi terlebih dahulu.

Salah satu kelebihan utama Python adalah banyaknya library yang tersedia yang membuatnya sangat fleksibel. Python dapat digunakan ke berbagai keperluan seperti pengembangan web, machine learning, analisis data dan komputasi ilmiah[77]. Contohnya seperti Numpy dan Pandas yang sangat membantu dalam

pengolahan data, dan Flask yang memudahkan pembuatan aplikasi web. Peneliti memilih bahasa pemrograman Python untuk melakukan pelatihan model, karena mendukung library seperti TensorFlow dan Keras untuk *transfer learning*. Juga memudahkan pengolahan data dan pengembangan sistem berbasis aplikasi web.

2.13. Kaggle

Kaggle adalah platform daring yang dikembangkan oleh Google dan berfungsi sebagai komunitas global bagi para data scientist dan praktisi *machine learning.* Platform ini menyediakan berbagai fasilitas seperti kompetisi data sains, publikasi *dataset*, notebook interaktif berbasis *Jupyter*, serta forum diskusi. Melalui Kaggle, pengguna dapat mengembangkan, menjalankan, dan membagikan kode analisis secara langsung melalui layanan cloud, sehingga platform ini menjadi ekosistem yang lengkap untuk kegiatan eksplorasi data dan pengembangan model prediktif[79]. Sebagai sumber data dan eksperimen, Kaggle telah digunakan dalam berbagai penelitian untuk mengevaluasi metode prediksi, kualitas kode dalam notebook, dan praktik pengembangan model dalam komunitas data sains[80][79]. Oleh karena itu, peneliti memilih Kaggle untuk membantu peneliti mendapatkan *dataset* dan menulis kode.

Kaggle menyediakan lingkungan komputasi berbasis cloud yang mendukung penggunaan GPU untuk mempercepat proses pelatihan model *deep learning*. Pada penelitian ini, proses pelatihan model akan dilakukan menggunakan GPU NVIDIA Tesla P100-PCIE dengan kapasitas memori sebesar 16 GB. Penggunaan GPU Tesla P100 memungkinkan proses pelatihan model berlangsung lebih cepat dan efisien dibandingkan dengan penggunaan CPU konvensional, terutama dalam pengolahan gambar beresolusi tinggi serta proses fine-tuning pada arsitektur *transfer learning*

seperti ResNet50, VGG16, EfficientNetB0, dan MobileNetV3Small. Dukungan perangkat keras ini memberikan kontribusi signifikan terhadap peningkatan performa komputasi dan efisiensi waktu dalam pelaksanaan eksperimen penelitian.

2.14. Flask

Flask merupakan micro web framework yang ditulis dalam python. Flask menyediakan library dan kumpulan kode program yang dapat digunakan untuk membangun website, tanpa harus melakukannya dari awal. Framework ini juga menyediakan fungsionalitas dasar dimana user dapat menambahkan modul sesuai dengan kebutuhan[81]. Framework ini dimanfaatkan karena kesederhanaan dan fleksibilitasnya. Beberapa contoh website yang dikembangkan dengan framework ini, seperti LinkedIn dan Pinterest[82]. Karena kemudahan dalam menggunakan framework ini, peneliti memilih untuk menggunakannya dalam pengembangan website dengan Transfer Learning.

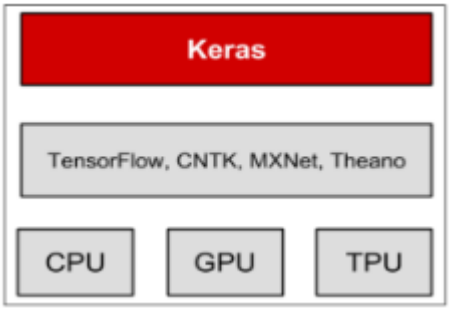
2.15. TensorFlow

TensorFlow adalah *framework machine learning open-source* yang dirancang untuk menyatukan berbagai *library* guna memecahkan berbagai masalah *machine learning.* TensorFlow menawarkan fleksibilitas tinggi dalam membangun dan melatih model *neural network*, dengan komponen seperti Contrib dan Keras yang dapat digunakan untuk mendefinisikan lapisan, yang kemudian dapat diterapkan pada beragam masalah komputasi[83]. TensorFlow digunakan dalam penelitian ini untuk menerapkan *transfer learning* dalam identifikasi masalah kulit wajah. Dengan memanfaatkan model *pre-trained* di TensorFlow, proses pelatihan dapat dilakukan dengan lebih cepat dan akurat. TensorFlow juga mendukung

integrasi dengan LLM untuk menghasilkan deskripsi hasil Grad-CAM dan rekomendasi *skincare* berbasis teks secara otomatis.

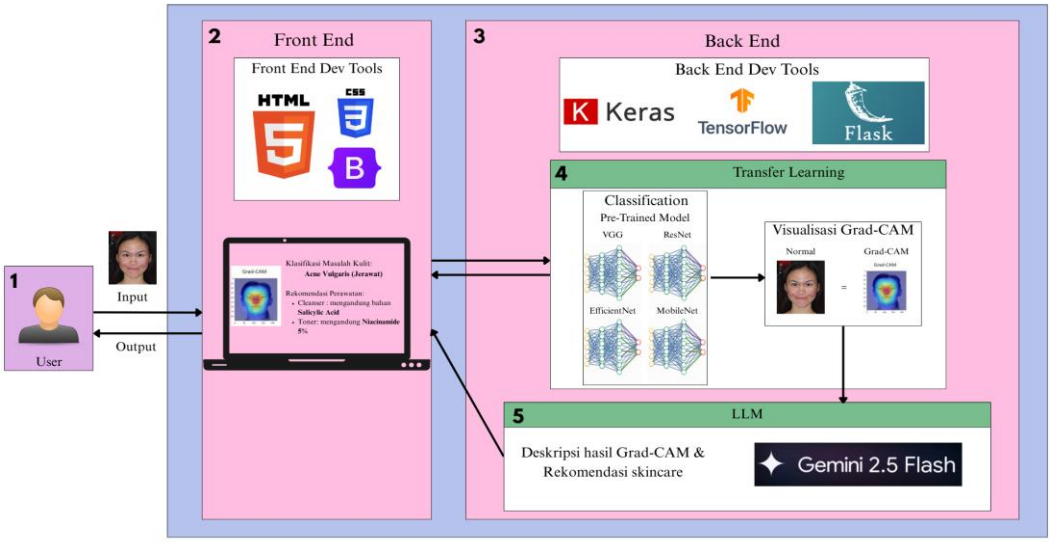
2.16. Keras

Keras adalah API yang ditulis dalam Python yang dapat dijalankan di atas TensorFlow dan framework lain seperti CNTK, MXNet, dan Theano. Keras memungkinkan user untuk memperkenalkan, melatih, dan menganalisis *neural network* (NN) secara sederhana. Keras dapat digunakan sebagai *deep learning library* yang memungkinkan peneliti untuk membangun dan melatih model secara cepat[84]. Dengan begitu, peneliti dapat lebih fokus pada pengembangan algoritma deep learning yang lebih baik.



Gambar 2.12 Keras[84].

2.17. Kerangka Konseptual



Gambar 2.13 Kerangka Konseptual Sistem.

Sistem yang kami kembangkan merupakan aplikasi web berbasis kecerdasan buatan yang memiliki fungsi identifikasi permasalahan kulit wajah melalui gambar, serta dirancang dengan kemampuan interpretasi visual menggunakan Grad-CAM. Sistem ini juga terintegrasi dengan LLM menggunakan Gemini 2.5 Flash untuk menghasilkan deskripsi visualisasi Grad-CAM dan rekomendasi *skincare.* Berikut adalah komponen dan sistem yang terintegrasi:

1. User

   User menggunakan aplikasi tersebut melalui web untuk menunjang beberapa aktivitas seperti proses autentikasi melalui halaman web. mengupload gambar wajah untuk diidentifikasi.

2. Frontend

   Frontend dibangun menggunakan HTML, CSS, dan framework Bootstrap yang bertugas menyediakan tampilan informatif dan responsive. Komponen ini mencakup halaman login, fitur upload gambar wajah, hasil

klasifikasi, visualisasi hasil Grad-CAM, deskripsi hasil Grad-CAM dan rekomendasi *skincare* berdasarkan LLM.

3. Backend

Pengembangan backend menggunakan bahasa pemrograman Python dengan *framework* Flask yang bertanggung jawab terhadap seluruh kinerja backend yang menerima input dari frontend. Backend juga menggunakan Keras dan TensorFlow sebagai kerangka kerja untuk menjalankan model *transfer learning*. TensorFlow menangani proses komputasi dan optimisasi, sedangkan Keras menyediakan antarmuka tingkat tinggi untuk membangun dan mengelola arsitektur model. Pada backend terdapat proses identifikasi dan klasifikasi dengan *transfer learning,* serta LLM untuk menghasilkan deskripsi Grad-CAM dan rekomendasi *skincare.*

4. Transfer Learning

Gambar wajah diproses menggunakan model *pre-trained* seperti VGG, ResNet, MobileNet, atau EfficientNet yang diimplementasikan melalui Keras dan TensorFlow. Model ini melakukan klasifikasi otomatis terhadap permasalahan kulit wajah berdasarkan data gambar. Untuk memberikan interpretasi dari hasil klasifikasi, digunakan teknik Grad-CAM yang menghasilkan visualisasi area wajah yang menjadi fokus perhatian model saat melakukan identifikasi.

5. LLM

Hasil klasifikasi dan visualisasi Grad-CAM dikirim ke LLM yang menggunakan Gemini 2.5 Flash, yang bertugas menghasilkan deskripsi

kondisi kulit wajah serta memberikan rekomendasi produk *skincare* dan bahan aktif yang sesuai dengan kondisi kulit user.

2.18. Penelitian Terkait

Sebagai bahan tinjauan dalam penelitian ini dan untuk mengetahui perbandingan dari penelitian terdahulu, beberapa penelitian yang berkaitan adalah sebagai berikut:

2.18.1. Klasifikasi Penyakit Kulit Wajah Menggunakan Metode Convolutional Neural Network[17]

Pada penelitian ini, peneliti mengembangkan sistem klasifikasi penyakit kulit wajah menggunakan metode CNN dengan arsitektur VGG16. data yang digunakan terdiri dari 500 sample gambar dengan 5 jenis penyakit kulit wajah, seperti jerawat, eksim, milia, herpes, dan melasma. Peneliti juga membandingkan VGG16 dengan model yang lain yaitu MobileNetV2 dan ResNet50. Berdasarkan hasil penelitian, arsitektur VGG16 memperoleh hasil paling baik.

Tabel 2.1 Hasil akurasi perbandingan beberapa model[17].

Model	Epoch	Akurasi	Akurasi Matrik Konfusi
MobileNetV2	500	80%	12%
ResNet50	1000	80%	64%
VGG16	**100**	**88%**	**90%**

2.18.2. Human skin type classification using image processing and deep learning approaches[9]

Peneliti mengembangkan model klasifikasi jenis kulit menggunakan algoritma *deep learning* CNN. *Dataset* terdiri dari 112 gambar untuk kulit normal,

120 gambar untuk kulit berminyak, dan 97 gambar untuk kulit kering. Arsitektur CNN yang dievaluasi meliputi MobileNetV2, EfficientNet-V2, InceptionV2, dan ResNet-V1. Hasil penelitian menunjukan Arsitektur EfficientNetV2 memiliki kinerja terbaik dengan mencapai akurasi 91.55% dan *loss* rata-rata 22.74%.

Tabel 2.2 Hasil evaluasi eksperimen beberapa model[9].

Model	Accuracy	Precision	Recall	F1-score	Loss
MobileNetV2	89.52%	89.47%	88.41%	88.66%	26.69%
EfficientNetV2	**91.55%**	**91.24%**	**91.09%**	**91.15%**	**22.74%**
InceptionV2	92.22%	92.27%	92.08%	92.16%	33.65%
ResNetV1	72.94%	72.31%	69.59%	70.89%	56.27%

2.18.3. Klasifikasi Jenis Kulit Wajah Menggunakan Metode Covolutional Neural Network (CNN) EfficientNet-B0[19]

Peneliti merancang sistem klasifikasi jenis kulit wajah (normal, kering, berminyak, dan kombinasi) menggunakan metode CNN dengan arsitektur EfficientNet-B0. *Dataset* berjumlah 1.550 gambar, yang kemudian dibagi menjadi 310 data uji dan 1.240 data latih. Peneliti melakukan optimasi pada model EfficientNet-B0 dengan menggunakan tiga *optimizer* yaitu Adam, SGD, dan RMSProp. Dari pengujian ini, *optimizer* Adam terbukti menjadi yang terbaik dan paling optimal.

Tabel 2.3 Hasil pengujian model menggunakan optimizer[19].

Optimizer	Akurasi	Loss	Precision	Recall	F1-score
Adam	**100%**	**0.0002**	**100%**	**100%**	**100%**
SGD	95.16%	0.0307	99.5%	99.5%	99.25%
RMSProp	100%	0.0013	100%	100%	100%

2.18.4. Implementasi MobileNet dalam Klasifikasi Jenis Kulit Wajah untuk Penentuan Kandungan Skincare[21]

Peneliti bertujuan mengimplementasikan arsitektur MobileNet dalam klasifikasi jenis kulit wajah (normal, kering, dan berminyak) untuk menentukan kandungan *skincare* yang sesuai. *Dataset* terdiri dari 450 gambar yang dibagi menjadi tiga jenis kulit. Model dilatih menggunakan MobileNet dengan 50 *epoch*, ukuran gambar 224x224 piksel, dan *optimizer* Adam. Evaluasi menggunakan data uji menghasilkan akurasi keseluruhan model 99% dan *loss* 3.73%.

Tabel 2.4 Hasil pengujian MobileNet[21].

Class	Precision	Recall	F1-score	Accuracy
Kering	**1.00**	**1.00**	**1.00**	99%
Normal	0.98	0.99	0.99	
Berminyak	0.99	0.98	0.99	

2.18.5. KLASIFIKASI MASALAH PADA KULIT WAJAH MENGGUNAKAN METODE CNN[20]

Peneliti menggunakan metode CNN dengan 3 arsitektur yaitu MobileNet, VGG16, dan ResNet50 untuk mengklasifikasikan masalah kulit, khususnya bopeng, jerawat, dan komedo. *Dataset* berjumlah 225 gambar. Masing-masing 75 gambar untuk setiap kelas masalah kulit. Dari 225 gambar, 150 gambar digunakan sebagai data pelatihan dan 75 gambar sebagai data uji. Hasil terbaik diperoleh model VGG16 dengan akurasi 75% pada pengujian gambar 224x224 dan warna

RGB. Pada ukuran gambar 128x128 dan warna RGB, MobileNet lebih unggul dengan akurasi 76%.

Tabel 2.5 Hasil pengujian keseluruhan model[20].

Model	Akurasi (%)				Rata-rata
	224x224 RGB	224x224 Grayscale	128x128 RGB	128x128 Grayscale	
MobileNet	69	**68**	**76**	63	69
VGG16	**75**	64	72	**65**	**69**
ResNet50	51	40	48	47	46.5

Tabel 2.6 Kontribusi Penelitian.

Peneliti	Contributions	Approach	Gap
Nurkhasanah dan Murinto[17]	Mengembangkan sistem klasifikasi penyakit kulit wajah dan membandingkan beberapa arsitektur CNN.	Menggunakan VGG16, MobileNetV2, dan ResNet50 pada 500 gambar dengan 5 jenis penyakit kulit wajah.	Overfitting pada model tertentu; kualitas gambar rendah, mempengaruhi ekstraksi fitur.
Saiwaeo dan tim[9]	Klasifikasi jenis kulit wajah menggunakan pendekatan *deep learning* dan evaluasi beberapa model CNN.	Menerapkan MobileNetV2, EfficientNetV2, InceptionV2, dan ResNetV1 pada *dataset* kulit normal, kering, dan berminyak.	ketidakseimbangan data, bias pada kulit kering, dan sensitivitas CNN terhadap variasi *input* (rotasi).
Sundari dan tim[19]	Klasifikasi 4 jenis kulit wajah dengan optimasi tiga jenis optimizer pada arsitektur EfficientNet-B0.	Menggunakan *dataset* 1.550 gambar, dengan uji terhadap Adam, SGD, dan RMSProp.	Potensi overfitting karena akurasi sangat tinggi (100%) bisa menunjukkan kurangnya generalisasi.
Futri dan tim[21]	Implementasi MobileNet untuk	*Dataset* 450 gambar, 3 kelas	*Dataset* kecil; membatasi

	klasifikasi jenis kulit wajah yang berkaitan dengan pemilihan *skincare.*	kulit; pelatihan MobileNet dengan 50 *epoch* dan optimizer Adam.	kemampuan generalisasi model terhadap variasi data dunia nyata.
Wiguna dan tim[20]	Klasifikasi bopeng, jerawat, dan komedo menggunakan tiga arsitektur CNN dan variasi resolusi serta warna gambar.	Menggunakan MobileNet, VGG16, dan ResNet50 pada 225 gambar, dengan variasi ukuran dan skema warna.	*Dataset* kecil dan kurang variatif; performa model menurun saat menggunakan grayscale; ResNet50 tidak optimal pada *dataset* terbatas.
Faithza Mandolang dan Grace Bindosano	Mengembangkan sistem identifikasi permasalahan kulit wajah menggunakan *transfer learning* dan rekomendasi *skincare* menggunakan LLM. Mengevaluasi 4 arsitektur CNN dan menggunakan Grad-CAM untuk visualisasi hasil identifikasi masalah.	*Transfer Learning* (VGG, ResNet, EfficientNet, MobileNet), Grad-CAM, LLM (Gemini 2.5 Flash); aplikasi web menggunakan Flask; optimasi dengan Adamax, RMSProp, dan SGD.	Hanya mengklasifikasi 6 kategori masalah kulit; data input terbatas pada wajah fronta;, bukan untuk diagnosis medis.

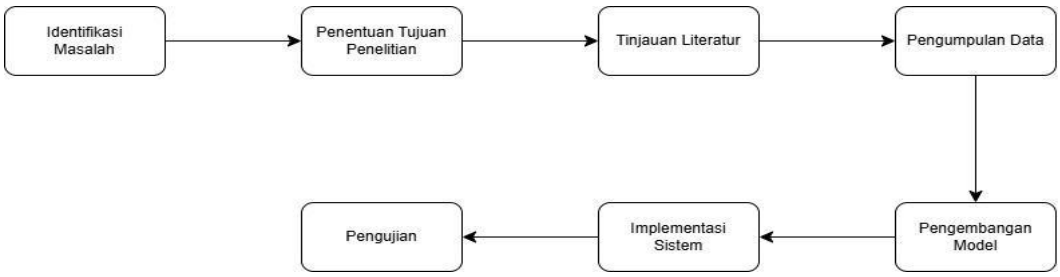
BAB 3

METODOLOGI PENELITIAN

Pada bab ini, peneliti akan menguraikan hal-hal yang berkaitan dengan metodologi penelitian yang mencakup desain penelitian, metode penelitian, teknik pengumpulan data dan lingkungan pengembangan.

3.1. Desain Penelitian

Dalam melakukan penelitian, sangat perlu dilakukan perencanaan dan perancangan penelitian, ini bertujuan untuk agar penelitian dapat berjalan dengan sistematis. Desain penelitian dapat dilihat pada gambar dibawah ini.



Gambar 3.1 Desain Penelitian.

1. Identifikasi Masalah

Tahap awal pada penelitian ini yaitu mengidentifikasi masalah yang sering dihadapi oleh masyarakat seperti kurangnya akses terhadap ahli dermatolog karena faktor biaya, lokasi, dan waktu. Selain itu, kurangnya pemahaman dalam memilih produk *skincare* yang menyebabkan masalah kulit sering tidak tertangani dengan baik. Oleh karena itu, peneliti merancang sebuah sistem berbasis AI dengan pendekatan *transfer learning* dan LLM untuk membantu mengidentifikasi permasalahan kulit wajah dari gambar dan memberikan rekomendasi *skincare* yang sesuai.

2. Penentuan Tujuan Penelitian

Pada tahap ini, peneliti merumuskan tujuan utama dari penelitian yaitu membangun dan membandingkan performa beberapa model *transfer learning* untuk mengidentifikasi permasalahan kulit wajah dari gambar. Setelah model terbaik diperoleh, tujuan selanjutnya adalah mengimplementasi model *transfer learning* dan LLM ke dalam aplikasi web untuk mengidentifikasi permasalahan kulit wajah serta memberikan deskripsi dan rekomendasi *skincare*. Tujuan penelitian ditentukan agar penelitian memiliki arah yang jelas sehingga memastikan hasil penelitian sesuai dengan objektif yang dimiliki oleh peneliti dalam penelitian ini.

3. Tinjauan Literatur

Peneliti mengumpulkan teori-teori yang berhubungan tentang penelitian ini seperti permasalahan kulit wajah, *skincare*, *Transfer Learning*, Grad-CAM, LLM, dan teori lain yang terkait dengan penelitian ini. Hal tersebut bertujuan untuk mendukung penelitian ini dengan mempelajari teori tersebut agar dapat membantu dalam penelitian dan pengembangan sistem ini. Dengan begitu, peneliti dapat memahami metode yang telah digunakan dari penelitian sebelumnya dan menentukan pendekatan yang tepat untuk diterapkan pada penelitian ini.

4. Pengumpulan Data

Pada tahap pengumpulan data, peneliti tidak melakukan teknik pengumpulan data primer seperti wawancara, observasi, atau kuesioner. Sebagai gantinya, peneliti melakukan pengumpulan data sekunder dengan memanfaatkan Kaggle sebagai platform yang menyediakan *dataset* yang besar. Data yang dikumpulkan berupa gambar wajah dari beberapa jenis permasalahan kulit wajah,

seperti jerawat, *dark-spot*, kulit kering, kulit berminyak, kemerahan, dan kerutan. Data ini digunakan untuk keperluan pelatihan dan pengujian model..

5. Pengembangan Model

Peneliti akan memulai mengembangkan model menggunakan arsitektur deep learning seperti VGG, EffiecientNet, ResNet, dan MobileNet. Selanjutnya *pre-processing* data, dimana data akan di *normalization*, *resizing*. Model-model akan dilatih menggunakan metode transfer learning dengan dataset yang sudah di *pre-process*. Tujuan dari pelatihan, untuk mengklasifikasi gambar input dari pengguna ke dalam enam kelas yang berbeda. Setelah pelatihan model, evaluasi akan diterapkan ke model. Model akan dievaluasi menggunakan metrik *accuracy*, *recall*, *precision*, dan *F1-Score*. Metrik ini digunakan untuk mengukur kinerja model dalam melakukan klasifikasi dengan benar.

6. Implementasi Sistem

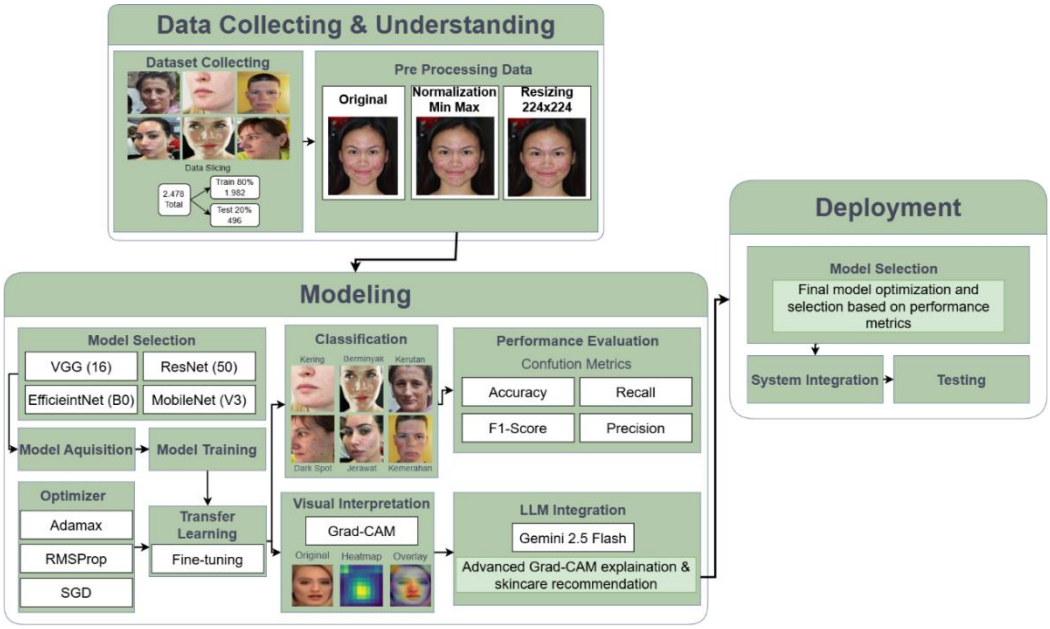
Pada tahap ini, peneliti akan mengintegrasikan komponen-komponen yang telah dibuat, yaitu model yang telah dikembangkan diintegrasikan ke sistem berbasis aplikasi web menggunakan *framework* Flask. User dapat mengunggah gambar wajah melalui antarmuka web, yang kemudian diproses oleh model untuk mengidentifikasi jenis permasalahan kulit wajah. Hasil klasifikasi divisualisasikan menggunakan Grad-CAM dan dikirim ke LLM untuk menghasilkan deskripsi hasil Grad-CAM serta rekomendasi *skincare* yang sesuai. Seluruh hasil akan ditampilkan melalui web, sehingga user dapat memahami kondisi kulit dan mendapatkan saran perawatan yang sesuai.

7. Testing

Pada tahap testing, pengujian akan dilakukan untuk memastikan sistem berjalan dengan baik. Sistem mampu memberikan hasil klasifikasi dari gambar, deskripsi dari hasil klasifikasi serta rekomendasi dari LLM. Pada pengujian ini, validasi model dilakukan dengan menggunakan gambar yang belum pernah digunakan dalam pelatihan. Dengan begitu, peneliti dapat memastikan bahwa model tetap bekerja dengan baik dengan data baru.

3.2. Metode Penelitian

Metode penelitian ini mencakup serangkaian langkah sistematis dalam membangun model yang memungkinkan proses pengembangan yang dilaksanakan secara terstruktur dengan melalui tahapan yang jelas. Penelitian ini mengadopsi metode dari *CRISP-DM* (Cross Industry Standard Process for Data Mining) yang terdiri dari tahapan pemahaman masalah, pemahaman dan persiapan data, pemodelan, evaluasi, hingga implementasi sistem. Pendekatan ini dipilih karena sesuai dengan kebutuhan pengembangan sistem.



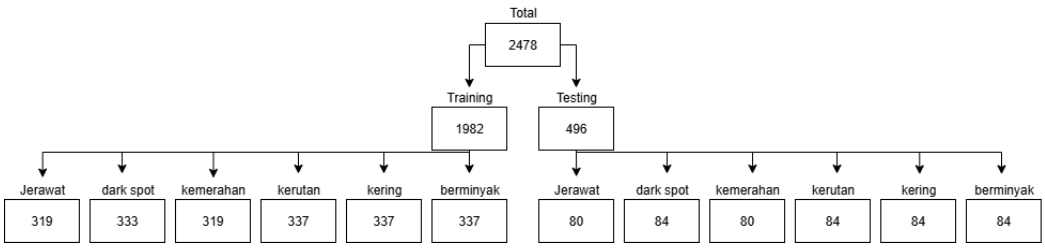
Gambar 3.2 Metode Penelitian.

3.2.1. Pengumpulan dan Pemahaman Data

3.2.1.1. Pengumpulan Data

Pada tahap ini, peneliti mengumpulkan dataset gambar wajah yang menunjukan berbagai permasalahan kulit dari Kaggle. Dalam memilih permasalahan kulit yang akan digunakan dalam penelitian ini, peneliti memilih enam tipe permasalahan kulit berdasarkan label yang ada pada dataset yang akan digunakan. Dataset yang digunakan berisi gambar wajah asli. Gambar-gambar tersebut memiliki variasi kondisi kulit, pencahayaan, sudut pandang yang cukup beragam, serta mencakup kulit terang dan kulit gelap. Variasi ini penting agar model tidak hanya belajar dari satu jenis tampilan wajah, tetapi juga mampu mengenali permasalahan kulit pada kondisi yang menyerupai situasi nyata saat digunakan oleh pengguna dari latar belakang berbeda. Model yang dikembangkan dalam penelitian ini difokuskan pada identifikasi pola visual dari permasalahan kulit wajah seperti jerawat, komedo, dark-spot, dan sebagainya, tanpa mempertimbangkan atribut demografis seperti ras. Permasalahan kulit wajah bersifat universal secara medis maupun visual, sehingga selama pola visual dari kondisi tersebut terekam dengan jelas dalam data, model tetap dapat melakukan klasifikasi secara efektif. Selain itu, pendekatan serupa juga banyak diterapkan dalam penelitian sebelumnya, Dimana model dilatih menggunakan dataset internasional dan tetap dapat diterapkan secara valid pada kelompok populasi lokal. Hal ini dimungkinkan karena performa model lebih bergantung pada keberagaman representasi visual dari kondisi kulit yang dilatihkan, dibandingkan pada atribut identitas demografis pengguna.

Untuk memastikan data yang digunakan benar-benar sesuai, proses validasi juga akan dilakukan bersama dermatolog sebelum digunakan dalam pelatihan model. Total dataset adalah 2.478 gambar wajah yang mewakili enam jenis permasalahan kulit wajah yang menjadi fokus penelitian yaitu, jerawat, dark-spot, kulit kering, kulit berminyak, kemerahan, dan kerutan. Dataset ini dibagi menjadi data testing yang berisi 496 gambar wajah dan data training berisi 1.982 gambar wajah. Pembagian ini dilakukan untuk memastikan bahwa model dapat belajar dengan baik dan dapat dievaluasi kinerja yang telah dilatih.



Gambar 3.3 Pembagian Dataset.

3.2.1.2. Pre-processing Data

Tahap selanjutnya adalah *pre-processing* data, yang bertujuan untuk menyiapkan *dataset* untuk pelatihan model. Proses pertama yaitu normalisasi, di mana skala nilai piksel dari gambar diubah agar berada pada rentang tertentu, seperti 0 hingga 1. Kemudian, gambar wajah akan di *resizing* menjadi ukuran standar, misalnya 224x224 piksel, untuk mempercepat pelatihan tanpa kehilangan detail visual penting untuk klasifikasi permasalahan kulit wajah. Setelah melewati tahap *pre-processing* data, *dataset* siap untuk digunakan dalam tahap berikutnya yaitu tahap modeling.

3.2.2. Modelling

Pada tahap modelling ini mencakup beberapa proses seperti pengembangan model, pelatihan dataset yang telah di pre-proses serta evaluasi model untuk menangkap pola yang ada dan melakukan klasifikasi.

3.2.2.1. Pemilihan Model

Pada penelitian ini, peneliti memilih empat model yaitu VGG16, ResNet-50, EfficientNet-B0, dan MobileNetV3-Small. Dari empat model tersebut, performa masing-masing akan dibandingkan dan menentukan model yang memiliki performa terbaik. Setiap model memiliki karakteristik yang berbeda-beda dalam melakukan klasifikasi. VGG unggul dalam menangkap pola pada gambar dan kesederhanaan arsitekturnya. ResNet mampu melatih jaringan dengan dalam walaupun sumberdaya terbatas. EfficientNet menawarkan keseimbangan antara kompleksitas model dan pelatihan. MobileNet untuk perangkat yang sumberdaya terbatas.

3.2.2.2. Model Acquisition

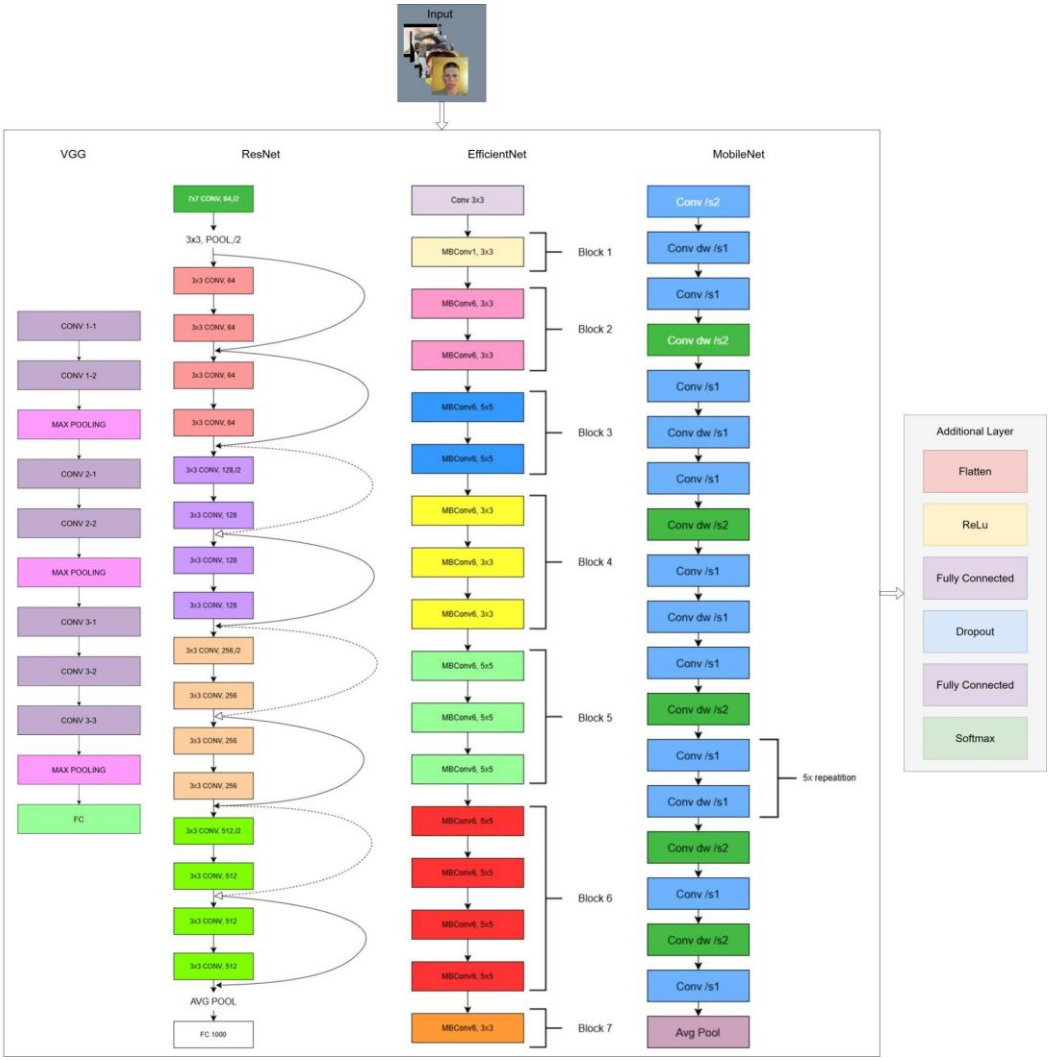
Setelah model dipilih, peneliti memperoleh model-model *pre-trained* tersebut dari repositori publik atau memanfaatkan model yang telah dilatih pada penelitian sebelumnya. Model-model ini akan digunakan sebagai dasar untuk melakukan *transfer learning* pada *dataset* gambar wajah dengan permasalahan kulit.

3.2.2.3. Pre-trained Models

Model yang telah dilatih sebelumnya digunakan sebagai dasar untuk *Transfer Learning*. Model ini sudah memiliki bobot dan parameter yang telah disesuaikan melalui pelatihan awal menggunakan dataset berukuran besar,

sehingga dapat dimanfaatkan kembali untuk menyelesaikan berbagai jenis tugas lain tanpa perlu melatih dari awal.

3.2.2.4. Transfer Learning



Gambar 3.4 Additional Layer Model.

Transfer Learning memanfaatkan pengetahuan dari model yang telah dilatih, model *pre-trained* yang telah di akuisisi akan diinisialisasi dan dimodifikasi untuk digunakan mengklasifikasi permasalahan kulit wajah. *Transfer Learning* memanfaatkan bobot dan parameter dari model yang telah dilatih pada *dataset* yang besar sehingga mempercepat untuk melatih model dengan *dataset* yang baru. Arsitektur dari model EfficienNet, ResNet, VGG, dan MobileNet dikustomisasi

dengan mempertahankan lapisan convolution dan pooling serta menambahkan layer Flatten, ReLU, Fully Connected, Dropout dan Softmax. Pada arsitektur tersebut juga akan di *fine-tuning* artinya, beberapa lapisan dari arsitektur tidak akan digunakan. Dengan Adamax, RMSprop, dan SGD sebagai *optimizer* yang menyesuaikan parameter model dan mengoptimalkan nilai bobot dalam jaringan saraf. masing-masing memiliki karakteristik dalam mengoptimalkan proses pembelajaran.

Tahapan dari setiap layer adalah sebagai berikut.

1. Convolutional layer

   Layer ini bertugas untuk mengekstrak fitur-fitur atau vektor numerik yang diproses dengan kernel untuk mengenali pola dari gambar yang diinput.

2. ReLU

   Fungsi aktivasi ini memberikan transformasi non-linear yang memungkinkan jaringan saraf mendeteksi pola kompleks dengan kebutuhan komputasi yang lebih ringan.

3. Pooling layer

   Pooling layer bertugas mengurangi dimensi fitur dengan cara mengambil nilai maksimum dari setiap blok dengan *max pooling* 2x2 pada map input. Teknik ini membantu mengurangi kompleksitas komputasi tanpa kehilangan fitur penting yang merepresentasikan permasalahan kulit.

4. Flatten

Layer ini mengubah matriks kompleks menjadi vektor 1D tanpa mengubah nilai elemen didalamnya yang akan diproses pada layer selanjutnya.

5. Fully connected

   Pada layer ini, setiap neuron terhubung ke semua neuron di lapisan sebelumnya. Lapisan ini berfungsi sebagai pengklasifikasi untuk membuat prediksi mengenai jenis permasalahan kulit wajah.

6. Dropout

   Layer ini bertugas untuk menghindari *overfitting* dengan menonaktifkan neuron secara acak pada *neural network.*

7. Softmax

   Layer softmax mengkonversi *output* numerik menjadi probabilitas kelas. Probabilitas tertinggi akan menjadi *output* dari hasil klasifikasi, menunjukan permasalahan kulit wajah yang paling mungkin.

Pada proses pelatihan model, peneliti melakukan pengaturan *hyperparameter* untuk mengoptimalkan performa klasifikasi. Beberapa *hyperparameter* yang disesuaikan meliputi *batch size*, *learning rate*, dan *epoch*. pengaturan diterapkan secara konsisten pada semua model yang diuji.

3.2.2.5. Classification

Tahap klasifikasi dalam penelitian ini menggunakan pendekatan *multiclass*. Setiap gambar dikategorikan ke beberapa kelas, seperti Jerawat, Dark spot, Kulit berminyak, Kulit kering, Kemerahan, dan Kerutan. Proses ini menghasilkan model klasifikasi berdasarkan pola-pola yang dipelajari oleh model dari data inputan yang dimasukkan.

3.2.2.6. Performance Evaluation

Pada tahap ini, model yang telah dilatih akan dievaluasi performanya dalam melakukan klasifikasi gambar wajah ke dalam *multiclass* permasalahan kulit wajah. Metrik evaluasi seperti *Confusion matrix* yang menghitung, akurasi, resisi, *precision,* dan F1-score, digunakan untuk mengevaluasi model. Akurasi mengukur seberapa banyak model memprediksi dengan benar dibandingkan dengan total data yang diuji. Presisi menunjukkan seberapa banyak prediksi positif yang benar dibandingkan semua prediksi positif yang dibuat model. Recall mengukur seberapa banyak kasus positif yang benar terdeteksi oleh model. F1-score adalah rata-rata dari presisi dan recall.

$$\text{Accuracy} = \frac{True\ Positive + True\ Negative}{True\ Positive + False\ Positive + False\ Negative + True\ Negative}$$

$$\text{Recall} = \frac{True\ Positive}{True\ Positive + False\ Negative}$$

$$\text{Precision} = \frac{True\ Positive}{False\ Positive + True\ Positive}$$

$$\text{F1-Score} = \frac{2\ x\ Recall\ x\ Precision}{Recall + Precision}$$

3.2.2.7. Visual Interpretation

Pada tahap ini, visualisasi dari model menggunakan Grad-CAM dengan menampilkan area kulit wajah yang terdeteksi. Visualisasi ini memberi penjelasan bagaimana sehingga model mendapatkan output tersebut.

3.2.2.8. LLM

Hasil dari visualisasi Grad-CAM akan didukung dengan penjelasan dari LLM, khususnya model Gemini 2.5 Flash. Peneliti akan menggunakan API yang telah tersedia oleh Gemini dan merancang *prompt* khusus untuk penjelasan terkait

kondisi kulit wajah. Model ini akan secara otomatis menganalisis hasil Grad-CAM untuk menghasilkan deskripsi dalam bentuk teks, serta memberikan rekomendasi produk *skincare* yang sesuai dan personal pengguna. Hasil rekomendasi dari Gemini berupa kandungan skincare yang sesuai serta beberapa produk rekomendasi. Selain dari itu, Gemini memberikan rekomendasi produk yang beragam mulai dari serum, pelembab, sunscreen dan lainnya. Produk yang direkomendasi Gemini didasari oleh kandungan bahan aktif yang terbukti efektif, popularitas dan ulasan positif, rekomendasi dari ahli/platform terpercaya (Halodoc, Hello Sehat), dan ketersediaan di pasar.

3.2.3. Deployment

Pada tahap deployment, peneliti akan memilih salah satu model dengan untuk diimplementasikan ke aplikasi web. Model dengan hasil evaluasi terbaik akan dipilih. Peneliti mengembangkan aplikasi web menggunakan framework Flask, TensorFlow untuk komputasi, dan Keras untuk menyederhanakan pembuatan dan pelatihan model. Aplikasi web ini menerima inputan dari user yang berupa gambar area wajah. Setelah menerima inputan dari user, model akan melakukan proses klasifikasi gambar tersebut ke dalam enam kelas permasalahan kulit wajah yang sudah ditentukan. Aplikasi web akan menampilkan gambar yang telah diklasifikasi, hasil Grad-CAM dalam bentuk *heatmap* yang menunjukkan area yang terdeteksi serta deskripsi hasil dan rekomendasi skincare yang sesuai dari LLM.

Untuk mendukung fungsionalitas penyimpanan data, sistem ini akan mengintegrasikan MongoDB sebagai *database*. MongoDB dipilih karena fleksibilitasnya dalam menangani data non-relasional, yang digunakan dalam sistem ini untuk menyimpan data profil pengguna, riwayat gambar yang diunggah,

hasil klasifikasi, visualisasi Grad-CAM, serta teks rekomendasi. Penggunaan *database* ini memungkinkan implementasi fitur history, di mana pengguna dapat mengakses dan meninjau Kembali hasil analisis kulit mereka sebelumnya..

Selain itu, sistem juga akan diintegrasikan dengan Google Search API yang berfungsi sebagai jembatan pencarian produk secara real-time. Layanan ini digunakan untuk mencari dan menyediakan tautan produk skincare di e-commerce yang relevan berdasarkan rekomendasi bahan aktif dan produk yang dihasilkan oleh LLM. Integrasi ini memastikan bahwa rekomendasi yang diberikan kepada pengguna tidak hanya bersifat informatif tetapi juga dapat ditindaklanjuti dengan ketersediaan produk di pasar saat itu. Tahap terakhir adalah testing, di tahap ini peneliti memastikan model, *database*, API eksternal dan fitur yang ada berhasil terintegrasi ke sistem aplikasi web dan berjalan dengan baik.

3.3. Teknik Pengumpulan Data

Dalam penelitian ini, peneliti menggunakan salah satu teknik pengumpulan data yaitu teknik studi literatur sebagai teknik dalam penelitian ini untuk mengumpulkan informasi dan data yang akan digunakan. Peneliti mengumpulkan data lima tahun terakhir.

3.3.1. Studi Literatur

Peneliti mengumpulkan data dari sumber-sumber yang valid dan kredibel, seperti publikasi, jurnal, artikel, dan buku. Peneliti memperoleh data lima tahun terakhir yang relevan dengan penelitian ini, agar membantu dalam memahami perkembangan penelitian, masalah, teknologi yang digunakan serta metode yang menjadi solusi dari masalah yang ada. Dengan teknik ini, peneliti dapat memperoleh wawasan yang membantu penelitian ini berjalan.

3.4. Lingkungan Pengembangan

Dalam pengembangan sistem ini, peneliti menggunakan berbagai software dan hardware sebagai alat bantu untuk mengembangkan *Transfer Learning* dengan berbagai model *pre-trained* untuk identifikasi permasalahan pada kulit wajah.

3.4.1. Software

- Kaggle, sebagai platform yang menyediakan *dataset* dan sebagai tempat untuk peneliti melatih model.
- Python versi 3.12, sebagai bahasa pemrograman yang digunakan peneliti untuk mengolah data, membangun model, dan pengembangan aplikasi web.
- Flask versi 3.1, sebagai *framework* untuk peneliti membangun aplikasi web.
- TensorFlow 2.16, sebagai *library open source* untuk membangun model deep learning.
- Keras 3.5, digunakan sebagai antarmuka tingkat tinggi untuk memudahkan implementasi model.
- MongoDB, digunakan sebagai *database* untuk penyimpanan data penggunaan sistem.
- Google Search API, digunakan sebagai search engine untuk mencari tautan e-commerce.

3.4.2. Hardware

- Laptop 1

  1) *Processor: AMD Athlon(™) Silver 3050U CPU @ 2.3GHz*

  2) *Storage: SSD 477 GB*

  3) *Memory: 8GB DDR4*

  4) *Graphic Card: AMD Radeon(™) Graphics*

5) *Display: Generic PnP Monitor, 1366 x 768 (32 bit) (60Hz)*

- Laptop 2

  1) *Processor: AMD Ryzen 3 4300U CPU @ 2.70GHz*

  2) *Storage: SSD 477 GB*

  3) *Memory: 8GB DDR4*

  4) *Graphic Card: AMD Radeon(™) Graphics*

  5) *Display: Generic PnP Monitor 1366 x 768 (32 bit) (60hz)*

BAB 4

HASIL DAN PEMBAHASAN

Bab ini membahas hasil implementasi sistem identifikasi permasalahan kulit wajah menggunakan *transfer learning* dan LLM. Tahapan awal dimulai dengan pengumpulan data & pemahaman, di mana data wajah dengan 6 jenis permasalahan kulit wajah dikumpulkan dan disiapkan sebagai dasar Pembangunan model. Data yang telah terkumpul kemudian masuk pada tahap *preprocessing* untuk dilakukan *normalisation, resizing*, dan persiapan label agar siap diproses pada tahap berikutnya. Selanjutnya dilakukan tahap *modelling*, yaitu proses pembangunan model klasifikasi dengan pendekatan *transfer learning*. Pada tahap ini, model dilatih, divalidasi, serta dibandingkan performa setiap model, mengevaluasi model berdasarkan *accuracy, presicion, recall, F1-score, confusion matrix*. Setelah model terbentuk, peneliti menerapkan *Explainable AI* (XAI) dengan teknik *Grad-CAM* untuk menyoroti area wajah yang menjadi focus model dalam melakukan klasifikasi, sehingga hasil prediksi dapat lebih transparan dan mudah dipahami. Tahap berikutnya adalah tahap *deployment*, yaitu implementasi ke dalam aplikasi web. Terakhir dilakukan *testing*untuk memastikan fungsionalitas aplikasi berjalan sesuai rancangan, sehingga sistem dapat memberikan hasil analisis dan rekomendasi *skincare* dengan baik.

4.1. Pengumpulan Data & Pemahaman

Pada tahap ini, dataset gambar wajah digunakan sebagai dalam proses pelatihan dan pengujian model klasifikasi. Dataset terdiri dari 2.478 gambar yang telah dibagi ke dalam 6 kelas permasalahan kulit wajah, dan dibagi menjadi dua subset, yaitu training set (1.982 gambar) dan testing set (496 gambar).

4.2. Data Preprocessing

Pada tahap ini, peneliti mempersiapkan data gambar yang telah disusaikan sebagaimana dijelaskan pada Bab 3.



Gambar 4.1 Jenis-jenis permasalahan kulit wajah.

Sebelum masuk ke tahap pemodelan, gambar yang terkumpul melalui beberapa tahap preprocessing agar sesuai dengan kebutuhan arsitektur model dan siap digunakan dalam proses pelatihan. Tahap pertama Adalah normalisasi dataset, di mana setiap nilai piksel gambar dinormalisasi agar berada pada skala tertentu. Proses ini bertujuan untuk mempercepat konvergensi saat pelatihan sekaligus menjaga stabilitas kinerja model. Selanjutnya, dilakukan rezise gambar menjadi ukuran 224x224 piksel. Ukuran ini dipilih karena sesuai dengan standar input pada arsitektur CNN yang digunakan pada penelitian ini. Setelah itu, label kelas yang awalnya berbentuk integer dikonversi menjadi vector biner melalui teknik one-hot encoding. Konversi ini diperlukan agar model dapat mempelajari representasi kelas dengan baik dalam tugas klasifikasi multiclass. Dengan adanya tahapan preprocessing ini, data yang digunakan dalam penelitian berada dalam kondisi seragam, representative, dan siap untuk diproses pada tahap pemodelan.

4.3. Modeling

Tahap modelling pada penelitian ini dilakukan dengan memanfaatkan pendekatan *transfer learning* menggunakan beberapa Arsitektur CNN yang telah terlatih sebelumnya pada dataset ImageNet. Arsitektur yang digunakan meliputi ResNet50, EfficientNetB0, VGG16, dan MobileNetV3Small. Keempat model ini dipilih karena memiliki karakteristik yang berbeda dalam hal kedalaman jaringan, jumlah parameter, serta efisiensi komputasi, sehingga dapat memberikan variasi performa yang dapat dibandingkan.

Peneliti menambahkan beberapa layer tambahan pada baigan akhir model, dengan menambahkan beberapa komponen seperti *Global Average Pooling* (GAP), *Dense* dengan aktivasi ReLU, *Batch Normalization, Dropout*, dan lapisan output berupa *Dense* dengan aktivasi *Softmax* digunakan untuk menghasilkan probabilitas prediksi pada masing-masing kelas.

Proses pelatihan model dilakukan dengan pengaturan *hyperparameter* yang meliputi penggunaan tiga jenis *optimizer*, yaitu Adamax dengan *learning rate* 0.0001 , RMSprop dengan *learning rate* 0.0001, SGD menggunakan *learning rate* 0.001 karena *optimizer* ini cenderung membutuhkan nilai yang lebih besar untuk mencapai kovergensi yang baik. Pemilihan variasi *learning rate* ini bertujuan untuk mencari konfigurasi terbaik yang dapat menghasilkan performa optimal dari masing-masing arsitektur yang digunakan. Ada juga pengaturan *batch size* sebesar 32 dan epoch sebanyak 50. Untuk menjaga kualitas pelatihan, diterapkan pula mekanisme *early stopping* untuk menghentikan pelatihan ketika tidak terjadi perbaikan pada metrik validasi dalam beberapa epoch berturut-turut, serta *model checkpoint* yang berfungsi menyimpan bobot terbaik dari model.

Tabel 4.1 Best Result from Each Model.

Model	Optimizer	Loss Function	Accuracy
EfficientNetB0	SGD	Categorical	87.30%
VGG16	RMSprop	Categorical	84.07%
ResNet50	**RMSprop**	**Categorical**	**87.70%**
MobileNetV3Small	SGD	Categorical	85.28%

Hasil terbaik dari setiap arsitektur yang digunakan dalam penelitian ini ditampilkan pada Tabel 4.1. Berdasarkan tabel tersebut, model ResNet50 dengan *optimizer* RMSprop memberikan performa paling tinggi denga akurasi sebesar 87.70%. Model EfficientNetB0 yang dilatih dengan *optimizer* SGD juga menunjukan hasil yang cukup baik dengan akurasi sebesar 87.30%, hanya berbeda sedikit dengan ResNet50. Selanjutnya, MobileNetV3Small yang menggunakan *optimizer* SGD memperoleh akurasi sebesari 85.28%, sementara VGG16 dengan *optimizer* RMSprop menghasilkan akurasi terendah yaitu 84%.

Analisis lebih lanjut dari tabel 4.1 menunjukkan temuan penting yaitu pemilihan *optimizer* sangat mempengaruhi akurasi akhir. Tidak ada satu optimizer yang terbukti terbaik untuk semua model, sebaliknya, *optimizer* yang paling efektif sangat bergantung pada arsitektur model yang diuji. Model ResNet50 dan VGG16, mencapai performa terbaik saat dipasangkan dengan RMSprop. Meskipun dua model ini memiliki tantangan pelatihan yang berbeda, temuan ini mengindikasikan bahwa kedua arsitektur ini sama-sama mendapat manfaat dari *optimizer* adaptif RMSprop. RMSprop memiliki kemampuan menyesuaikan *learning rate* secara individual untuk setiap parameter, dan mampu menstabilkan proses pembaruan

bobot. Kemampuan ini kemungkinan besar membantu VGG16, yang dikenal sulit dilatih karena jumlah parameter sangat besar, untuk menyelesaikan proses pelatihannya secara lebih lancer dan andal. Pada saat yang sama, kemampuan adaptif ini juga membantu ResNet50 menemukan Solusi terbaik dengan lebih cepat dan efektif, karena arsitektur yang canggih, proses untuk menemukan nilai *loss* terendah pada ResNet50 sangatlah rumit.

Pola ini kontras dengan model yang dirancang untuk efisiensi komputasi. EfficientNet dan MobileNet justru berkinerja paling baik dengan *optimizer* SGD. Hal ini menunjukkan bahwa untuk arsitektur yang lebih ringan dan modern, *optimizer* SGD yang *learning rate*-nya telah diatur dengan cermat mampu memandu model menemukan solusi optimal. Temuan ini menegaskan bahwa keberhasilan tidak ditentukan oleh *optimizer* atau arsitektur saja, tetapi oleh kecocokan pasangan antara keduanya.

Pada model *deep learning*, parameter merupakan bobot dan bias yang digunakan jaringan saraf untuk mempelajari pola dari data. Dalam pendekatan *transfer learning*, parameter dibedakan menjadi dua, yaitu trainable parameters dan non-trainable parameters. Parameter trainable akan diperbarui selama proses pelatihan agar model dapat menyesuaikan diri dengan dataset baru, sedangkan parameter non-trainable dipertahankan dari hasil pelatihan sebelumnya untuk menjaga pengetahuan umum yang telah diperoleh dari dataset besar seperti ImageNet.

Pada model ResNet50 yang digunakan dalam penelitian ini, jumlah total parameter adalah 24.772.742, terdiri dari 1.183.494 parameter trainable dan 23.589.243 parameter non-trainable. Pengaturan ini dilakukan agar hanya lapisan

atas model yang dilatih ulang, sementara lapisan dasar tetap menggunakan bobot pre-trained. Pendekatan ini membantu mempercepat proses pelatihan serta mencegah *overfitting*, sekaligus mempertahankan kemampuan ResNet50 dalam mengekstraksi fitur visual umum dari gambar kulit wajah.

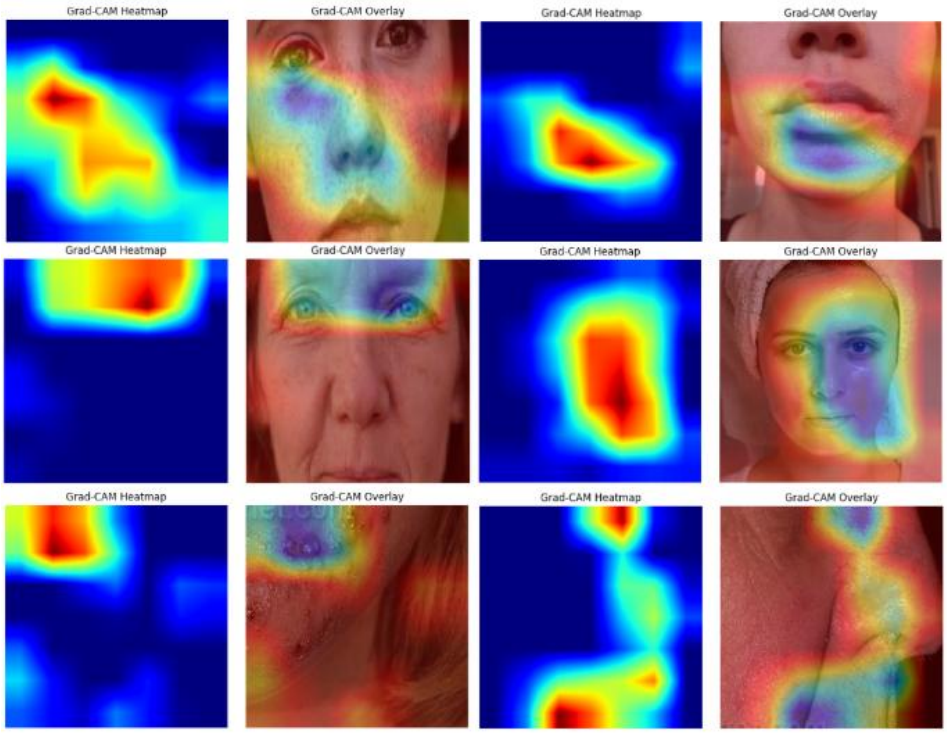
Dari hasil ini dapat dilihat bahwa setiap model memiliki karakteristik performa yang berbeda-beda, meskipun seluruhnya menggunakan loss function yang sama yaitu *categorical crossentropy*. Perbedaan performa ini dipengaruhi oleh kompleksitas arsitektur masing-masing model serta kesesuaian *optimizer* yang digunakan dalam proses pelatihan. Secara umum, ResNet50 dan EfficientNetB0 terbuktu lebih unggul dibandingkan VGG16 dan MobileNetV3Small pada dataset permasalahan kulit wajah yang digunakan dalam penelitian ini.

4.4. XAI menggunakan Grad-CAM

Selain menghasilkan output berupa label prediksi, penelitian ini juga menerapkan pendekatan *explainable AI* (XAI) dengan teknik Grad-CAM. Metode ini digunakan untuk memberikan visualisasi berupa heatmap yang menyoroti area pada gambar wajah yang paling berpengaruh terhadap keputusan model dalam melakukan klasifikasi. Pada proses implementasinya, Grad-CAM menghasilkan dua bentuk visualisasi yaitu:

1. Grad-CAM Heatmap, digunakan untuk menampilkan distribusi Tingkat perhatian model terhadap gambar dengan gradasi warna tertentu. Warna merah menunjukan area dengan tingkat perhatian tinggi, sedangkan warna biru menunjukan area dengan tingkat perhatian rendah. Visualisasi ini memberikan gambaran kasar mengenai focus model terhadap area tertentu pada wajah.

2. Grad-CAM Overlay, merupakan hasil gabungan antara heatmap dengan gambar asli. Dengan cara ini, area wajah yang menjadi focus perhatian model dapat terlihat jelas tanpa menghilangkan konteks dari gambar asli. Visualisasi overlay mempermudah interpretasi karena pengguna dapat langsung mengidentifikasi bagian wajah yang diprediksi bermasalah berdasarkan area yang disoroti oleh model.



Gambar 4.2 Visualisasi Grad-CAM pada gambar wajah.

Penerapan Grad-CAM pada penelitian ini menunjukan bahwa model mampu mengenali area yang relevan dengan permasalahn kulit wajah. Dengan adanya integrasi Grad-CAM, sistem yang dikembangkan dalam penelitian ini menjadi lebih mudah dipahami, sehingga meningkatkan kepercayaan pengguna terhadap hasil klasifikasi dan memberikan nilai tambah dalam konteks aplikasi nyata, terutama dibidang rekomendasi *skincare*.

4.5. Evaluasi

4.5.1. Perbandingan algoritma transfer learning

Peneliti akan membandingkan kinerja setiap model dengan menggunakan tiga jenis optimizer, yaitu Adamax, SGD, dan RMSprop, dengan *batch size* sebesar 32. Proses pelatihan dilakukan menggunakan *learning rate* 0.0001, tetapi khusus optimizer SGD menggunakan *learning rate* 0.001. Fungsi *loss* yaitu *categorical crossentropy*. Model dilatih selama 50 *epoch* untuk mengevaluasi performa setiap optimizer yang diuji.

Tabel 4.2 Hasil Evaluasi Model.

Optimizer	Accuracy	Precision	Recall	F1-Score
EfficientNetB0				
Adamax	83.87%	84.28%	83.87%	83.96%
SGD	**87.30%**	**87.79%**	**87.30%**	**87.47%**
RMSprop	86.69%	87.00%	86.69%	86.75%
VGG16				
Adamax	83.06%	83.86%	83.06%	83.29%
SGD	83.06%	83.52%	83.06%	83.18%
RMSprop	**84.07%**	**84.68%**	**84.07%**	**84.30%**

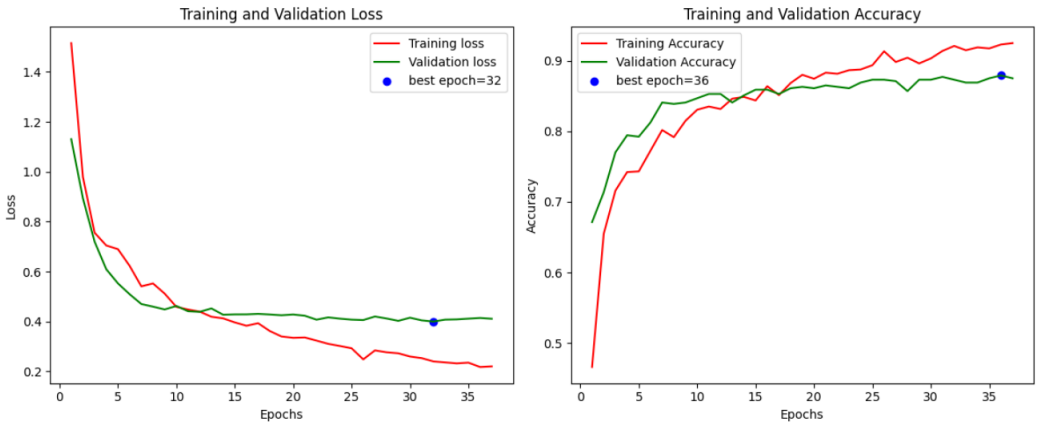
ResNet50				
Adamax	85.48%	85.68%	85.48%	85.54%
SGD	87.10%	87.63%	87.10%	87.24%
RMSprop	**87.70%**	**87.99%**	**87.70%**	**87.77%**
MobileNetV3 Small				
Adamax	82.86%	83.44%	82.86%	83.01%
SGD	**85.28%**	**85.83%**	**85.28%**	**85.48%**
RMSprop	84.27%	84.90%	84.27%	84.51%

Berdasarkan hasil perbandingan pada Tabel 4.2, dapat disimpulkan bahwa ResNet50 dengan *optimizer* RMSprop memberikan performa terbaik secara keseluruhan dengan akurasi 87.79%, sehingga menjadi model paling optimal dalam penelitian ini. Hasil ini menegaskan bawah arsitektur ResNet50 adalah pilihan yang lebih tepat untuk tugas klasifikasi permasalahan kulit wajah, karena mampu memberikan keseimbangan terbaik antara akurasi dengan metrik evaluasi lainnya.

4.5.2. Training and validation loss and accuracy

Salah satu cara untuk mengevaluasi performa model secara mendalam adalah dengan menganalisis training dan validation *loss* serta training dan validation *accuracy*. Training *loss* dan training *accuracy* menunjukkan performa model pada data train. Nilai training *loss* yang semakin menurun dan training

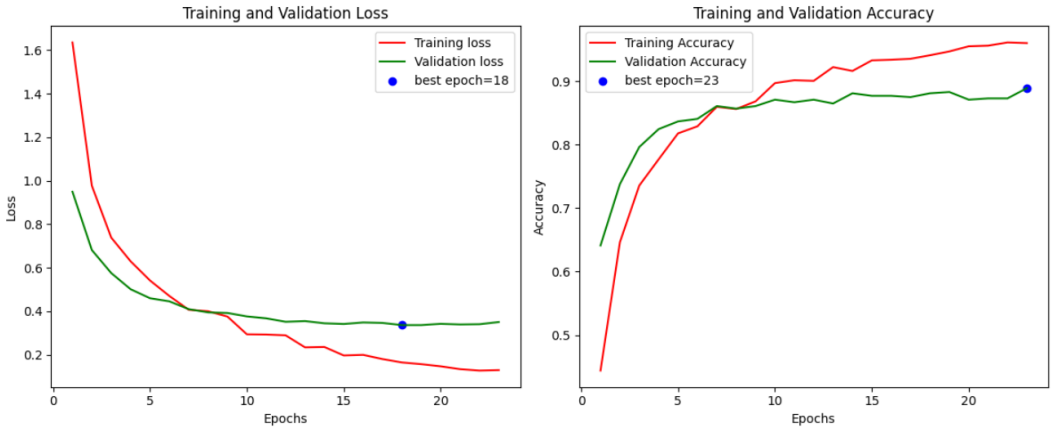
accuracy yang semakin emningkat menandakan bahwa model berhasil mempelajari pola pada data train. Validation *loss* and validation *accuracy* menggambarkan kemampuan model pada data yang tidak digunakan saat pelatihan. Nilai ini menjadi indicator utama dalam menilai generalisasi model terhadap data baru. Analisis terhadap grafik *loss* dan *accuracy* sangat penting untuk mendeteksi masalah seperti *overfitting* maupun *underfitting*. Pada penelitian ini dilakukan analisis grafik training dan validation *loss* serti *accuracy* dari empat model terbaik yang telah diuji, yaitu EfficientNetB0 dengan SGD, ResNet50 dengan RMSprop, VGG16 dengan RMSprop, dan MobileNetV3Small dengan SGD. Analisis ini bertujuan untuk membandingkan pola pembelajaran masing-masing model serta memastikan model yang dipilih memiliki performa paling stabil dan optimal.



Gambar 4.3 Graph Training dan Validation Loss/Accuracy EfficientNetB0.

Gambar 4.3 menunjukan kurva training dan validation dari model EfficientNetB0 dengan *optimizer* SGD, yang merupakan salah satu model dengan performa terbaik. Pada grafik *loss* (kiri) mengalami penurunan signifikan sejak awal pelatihan dan terus menurun hingga mencapai titik stabil mendekati 0.2 pada epoch ke-36. Sementara itu, nilai validation *loss* juga menurun secara konsisten hingga sekitar 0.4 pada epoch ke-32, menunjukan bahwa model mampu

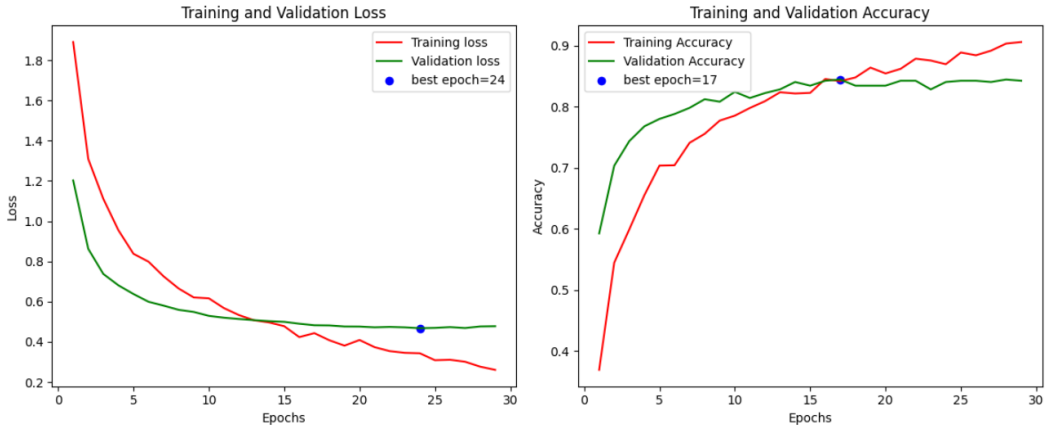
mempelajari pola data uji dengan baik. Pada grafik *accuracy* (kanan), terlihat bahwa nilai training *accuracy* meningkat pesat sejak awal pelatihan hingga mencapai lebih dari 0.9 pada epoch ke-36. Sementara itu, nilai validation *accuracy* juga meningkat hingga sekitar 0.85 dan relative stabil pada epoch ke-36. Pola ini menunjukan bahwa model tidak mengalami *overfitting* yang signifikan, karena selisih antara training *accuracy* dan validation *accuracy* tidak terlalu jauh. Secara keseluruhan, grafik pelatihan EfficientNetB0 dengan *optimizer* SGD menunjukan performa yang stabil dengan proses pembelajaran yang baik.



Gambar 4.4 Graph Training dan Validation Loss/Accuracy ResNet50.

Gambar 4.4 menunjukan grafik pelatihan model ResNet50 dengan *optimizer* RMSprop. Pada grafik *loss* (kiri), terlihat bahwa nilai training *loss* turun tajam sejak awal epoch dan terus menurun hingga mencapai sekitar 0.15 pada epoch ke-23. Sementara itu, validation *loss* juga mengalami penurunan siginifikan dari awal pelatihan dan kemudian stabil di sekitar 0.35 mulai dari epoch ke-18. Hal ini menandakan bahwa model dapat mempelajari pola data dengan baik serta mampu mempertahankan stabilitas pada data validasi. Pada grafik *accuracy* (kanan), nilai training *accuracy* meningkat secara konsisten dan mencapai lebih dari 0.95 pada epoch ke-23. Sementara itu, validation *accuracy* meningkat dengan cepat di awal

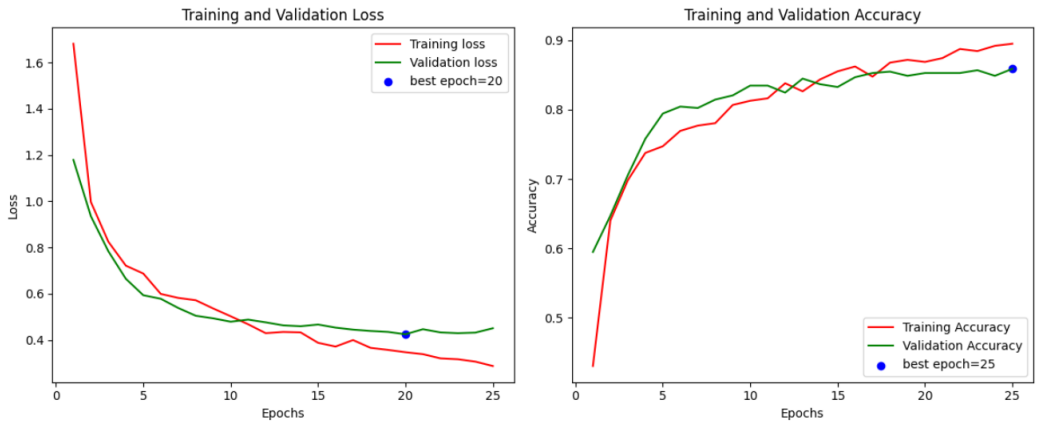
hingga mencapai sekitar 0.88, kemudian stabil mulai dari epoch ke-10 hingga akhir pelatihan. Perbedaan antara training *accuracy* dan validation *accuracy* memang terlihat cukup besar, tetapi selisih ini masih dapat diterima mengingat kompleksitas arsitektur ResNet50 yang cenderung lebih dalam dibandingkan model lainnya. Secara keseluruhan, ResNet50 dengan RMSprop menunjukkan performa yang sangat baik, dengan tingkat pembelajaran yang cepat dan hasil validasi yang stabil. Hal ini sejalan dengan hasil evaluasi akurasi pada tabel sebelumnya, di mana model ini menjadi salah satu yang terbaik dengan capaian 87.70%.



Gambar 4.5 Graph Training dan Validation Loss/Accuracy VGG16.

Gambar 4.5 memperlihatkan kurva training dan validation dari model VGG16 dengan *optimizer* RMSprop. Pada grafik *loss* (kiri), terlihat bahwa nilai training *loss* menurun secara konsisten dari awal epoch hingga akhir, mencapai sekitar 0.25 pada epoch ke-29. Sementara itu, validation *loss* juga mengalami penurunan yang cukup baik hingga stabil di sekitar 0.45 pada epoch ke-24. Hal ini menunjukan bahwa model mampu mempelajarai pola data dengan baik tanpa terjadi peningkatan signifikan pada validaton *loss*, sehingga tidak ada indikasi *overfitting* yang parah. Pada grafik *accuracy* (kanan), training *accuracy* terus meningkat hingga lebih dari 0.9 pada epoch ke-29. Sementara itu, validation

accuracy stabil di kisaran 0.83-0.85 sejak epoch ke-17. Selisih antara training *accuracy* dan validation *accuracy* memang terlihat cukup jelas. Hal ini menunjukan bahwa mode VGG16 mampu mencapai generalisasi yang baik meskipun tidak seoptimal model dengan arsitektur yang lebih modern seperti ResNet50 dan EfficientNetB0.



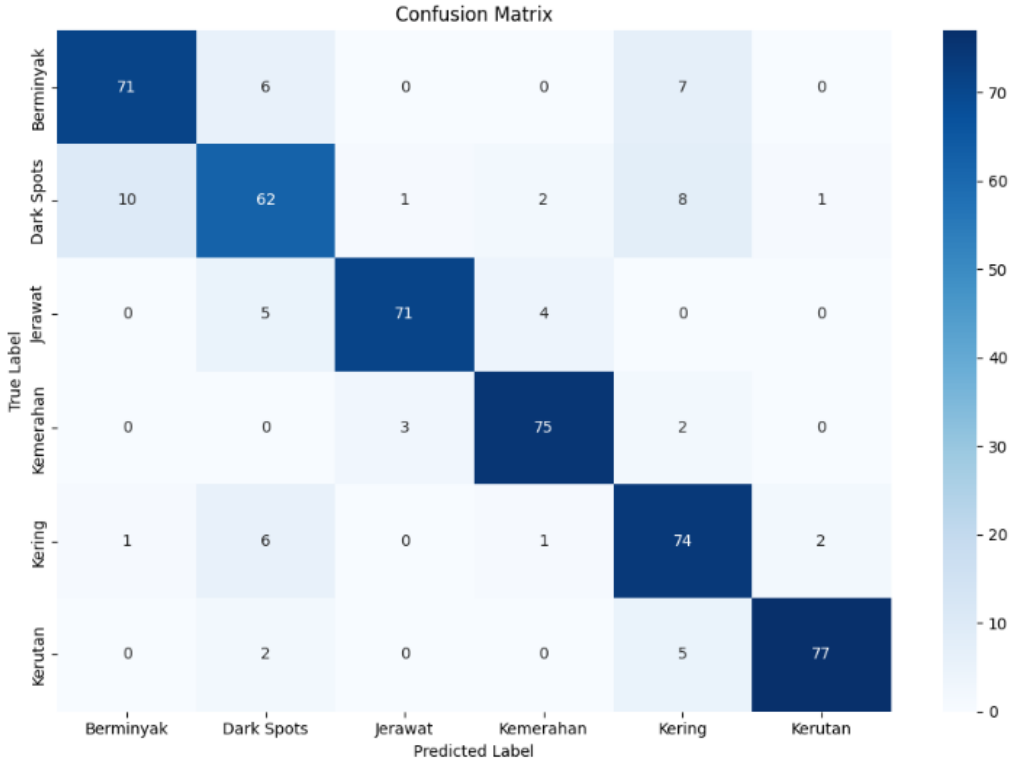
Gambar 4.6 Graph Training dan Validation Loss/AccuracyMobileNetV3Small.

Gambar 4.6 menampilkan kurva hasil pelatihan model MobileNetV3Small dengan *optimizer* SGD. Pada grafik *loss* (kiri), terlihat bahwa nilai training *loss* mengalami penurunan tajam sejak awal epoch hingga stabil di sekitar 0.3 pada epoch ke-25. Validation *loss* juga menurun dengan pola yang hampir sama, kemudian stabil di kisaran 0.4 mulai epoch ke-20. Hal ini menunjukan bahwa model mampu belajar secara konsisten dan tidak menunjukan tanda-tanda *overfitting* yang serius. Pada grafik *accuracy* (kanan), nilai training *accuracy* meningkat secara bertahap hingga mencapai hamper 0.9 pada epoch terakhir. Sementara itu, validation *accuracy* naik dengan cepat pada awal pelatihan, kemudian stabil di kisaran 0.85 sejak epoch ke-15 hingga akhir. Pola ini menunjukan bahwa model ini memiliki kemampuan generalisasi yang cukup baik, meskipun akurasinya sedikit lebih rendah dibandingkan dengan ResNet50 maupun EfficientNetB0. Secara

keseluruhan, model ini dapat menghasilkan performa yang stabil denga proses pembelajaran yang ringan.

4.5.3. Confusion Matrix

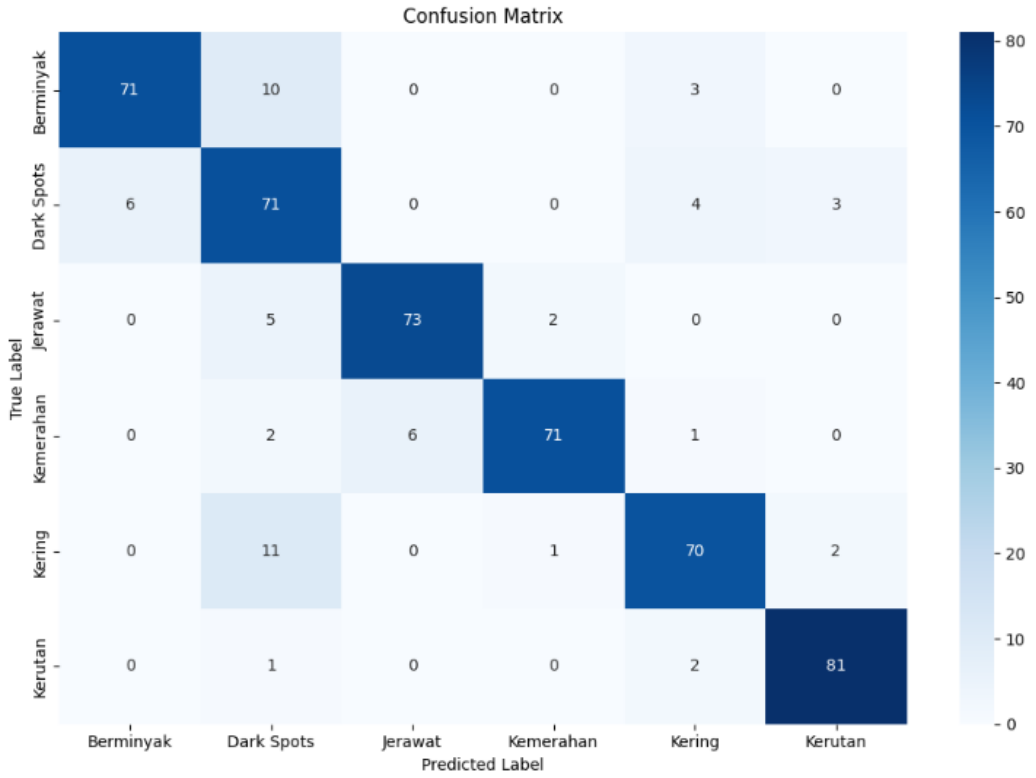
Confusion matrix adalah salah satu metode evaluasi yang umum digunakan dalam sistem klasifikasi. Matrix ini menyajikan perbandingan antara label sebenarnya (true label) dengan label yang diprediksi oleh model (predicted label) dalam bentuk tabel dua dimensi. Dengan confusion matrix, dapat diketahui jumlah data yang diprediksi benar maupun salah untuk setiap kelas. Kegunaan utama confusion matrix adalah memberikan gambaran detail mengenai perfoma model dalam mengenali masing-masing kelas, bukan hanya berdasarkan akurasi keseluruhan. Dari matrix ini dapat dilihat kelas mana yang paling sering dinelai dengan benar, serta kelas mana yang masih sering keliru diprediksi sebagai kelas lain.



Gambar 4.7 Confusion Matrix EfficientNetB0.

Gambar 4.7 memperlihatkan confusion matrix dari model EfficientNetB0 menggunakan SGD. Hasilnya menunjukan bahwa Sebagian besar data pada setiap kelas berhasil diklasifikasi dengan benar, seperti kelas Jerawat (71 benar) dan Kerutan (77 benar) yang memiliki prediksi tinggi di diagonal utama. Namun, masih terdapat beberapa kesalahan klasifikasi, kesalahan prediksi paling menonjol terjadi antara kelas Berminyak, Dark Spots, dan Kering. Terlihat bahwa 10 kasus Dark Spots salah diprediksi sebagai Berminyak, dan 8 kasus Dark Spots salah diprediksi sebagai Kering. Kebingungan ini juga bersifat dua arah, yaitu 7 kasus Berminyak salah diprediksi sebagai Kering, dan 6 kasus Kering salah diprediksi sebagai Dark Spots. Hal ini mengindikasikan bahwa model masih kesulitan membedakan fitur visual yang tumpeng tindih antara kilau minyak, bercak gelap, dan tekstur kulit kering. Meskipun secara keseluruhan, confusion matrix ini menunjukan bahwa model EfficientNetB0 menggunakan SGD mampu mengenali enam kelas

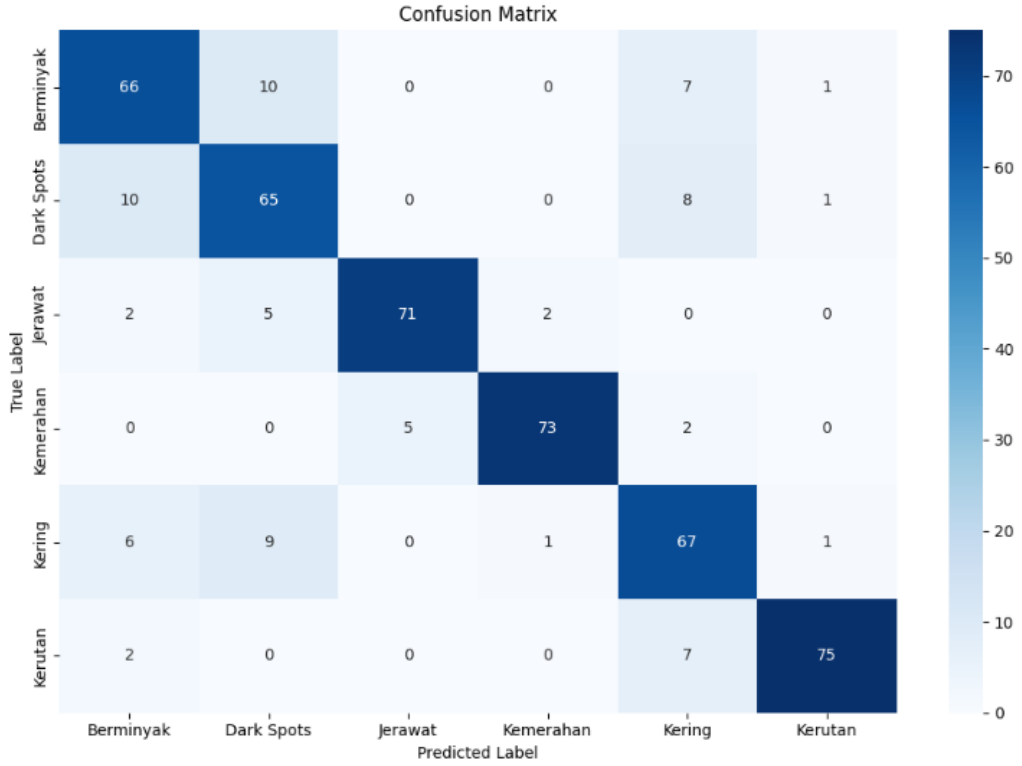
permasalahan kulit wajah dengan cukup baik. Tingginya nilai diagonal utama dibandingkan dengan kesalahan prediksi pada sel lain memperlihatkan bahwa model memiliki tingkat akurasi dan konsistensi yang baik dalam klasifikasi multikelas.



Gambar 4.8 Confusion Matrix ResNet50.

Gambar 4.8 menunjukkan confusion matrix dari model ResNet50 dengan *optimizer* RMSprop. Hasil klasifikasi memperlihatkan bahwa sebagian besar data berhasil diprediksi dengan benar, ditunjukan oleh nilai diagonal utama yang tinggi pada masing-masing kelas. Misalnya, kelas Jerawat memiliki 73 prediksi benar, kelas kemerahan dengan 71 benar, serta kelas Kerutan dengan prediksi benar tertinggi yaitu 81. Hal ini menegaskan bahwa ResNet50 mampu mengenali pola pada beberapa kelas dengan sangat baik. Meskipun demikian, masih terdapat beberapa kesalahan klasifikasi. Kelas Berminyak terkadang diprediksi Dark Spots

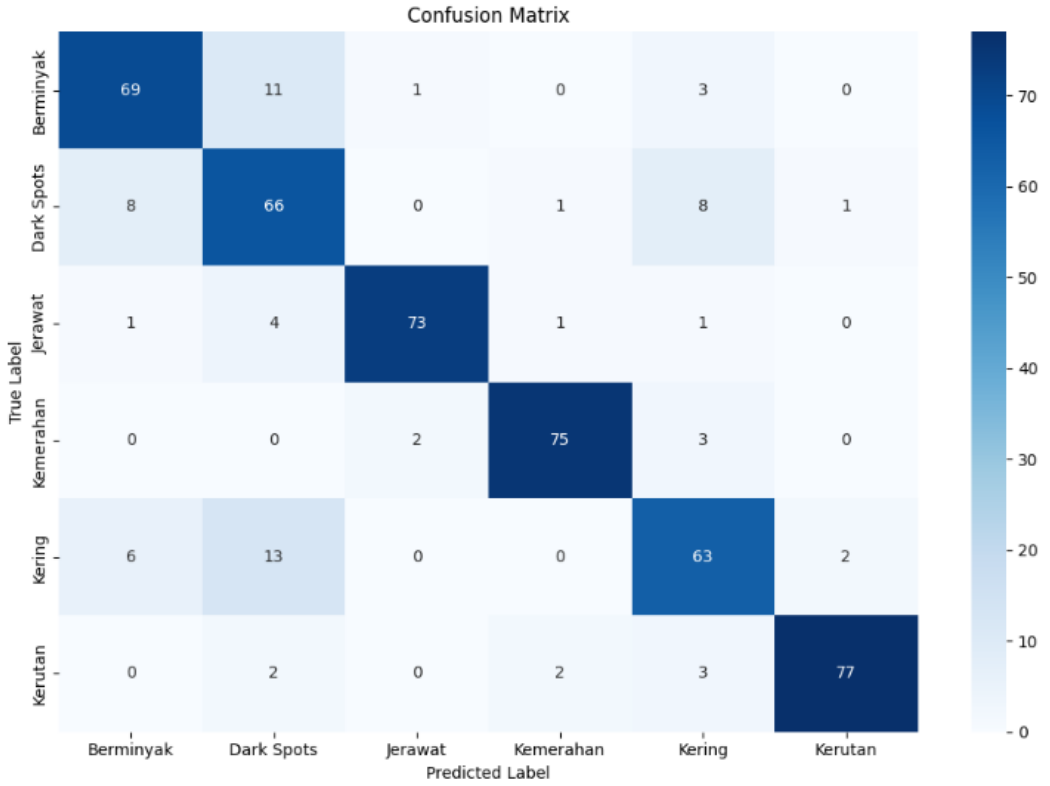
(10 kasus), sedangkan kelas Kering juga cukup sering salah dikenali sebagai Dark Spots (11 kasus). Kebingungan ini bersifat dua arah, meskipun tidak seimbang, dimana 6 kasus Dark Spots juga salah diprediksi sebagai Berminyak. Selain itu, terdapat kesalahan kecil pada kelas Kemerahan yang sesekali diprediksi sebagai Jerawat. Secara keseluruhan, confusion matrix ini menunjukkan bahwa ResNet50 dengan RMSprop mampu melakukan klasifikasi dengan cukup stabil, meskipun terdapat sedikit *overlap* antar kelas. Hasil ini juga konsisten dengan akurasi yang dicapai model, yaitu 87.70%, yang merupakan salah satu hasil terbaik dalam penelitian ini.



Gambar 4.9 Confusion Matrix VGG16.

Gambar 4.9 menampilkan confusion matrix dari model VGG16 dengan RMSprop. Secara umum, model ini mampu mengklasifikasikan sebagian besar data dengan benar, yang ditunjukkan oleh tingginya nilai diagonal utama. Kelas Jerawat

memiliki 71 prediksi benar, kelas Kemerahan sebanyak 73 benar, serta kelas Kerutan sebanyak 75. Hal ini menunjukkan bahwa VGG16 cukup baik dalam mengenali pola visual pada kelas-kelas tersebut. Namun, masih terdapat beberapa kesalahan yang cukup menonjol. Misalnya, kelas Berminyak beberapa kali diprediksi sebagai Dark Spots (10 kasus) dan Kering (7 kasus). Hal ini yang sama juga terlihat pada kelas Dark Spots, yang sering keliru diprediksi sebagai Berminyak (10 kasus) maupun Kering (8 Kasus). Kesalahan ini mengindikasikan adanya kemiripan fitur antar kelas, terutama antara Berminyak, Dark Spots, dan Kering, yang masih sulit dibedakan oleh VGG16. Secara keseluruhan, meskipun VGG16 mampu mengenali sebagian besar kelas dengan cukup baik, model ini masih menghasilkan kesalahan klasifikasi lebih tinggi dibandingkan EfficientNetB0 dan ResNet50.



Gambar 4.10 Confusion Matrix MobileNetV3Small.

Gambar 4.10 memperlihatkan confusion matrix dari model MobileNetV3Small dengan SGD. Model ini mampu mengklasifikasikan sebagian besar data dengan benar, terlihat dari nilai diagonal utama yang cukup tinggi pada semua kelas. Kelas Jerawat memiliki 73 prediksi benar, kelas Kemerahan dengan 75, dan kelas Kerutan dengan 77 prediksi benar. Hal ini menunjukkan bahwa model MobileNetV3Small cukup baik dalam membedakan pola visual pada beberapa permasalahan kulit tertentu. Namun, masih terdapat beberapa kesalahan klasifikasi yang perlu diperhatikan. Kelas Berminyak terkadang diprediksi sebagai Dark Spots (11 kasus), sementara kelas Kering cukup sering keliru diprediksi sebagai Dark Spots (13 kasus). Selain itu, kelas Dark Spots juga mengalami beberapa kesalahan, misalnya diprediksi sebagai Kering (8 kasus). Pola kesalahan ini mirip dengan yang terjadi pada model-model yang lain, di mana terdapat tumpeng tindih fitur antar kelas yang memiliki karakteristik visual serupa. Secara keseluruhan, meskipun MobileNetV3Small memiliki akurasi yang lebih rendah dibandingkan EfficientNetB0 dan ResNet50, confusion matrix ini memperlihatkan bahwa model tetap dapat menghasilkan prediksi yang stabil.

4.5.4. Perbandingan model dengan penelitian terkait

Bagian ini membahas perbandingan antara hasil penelitian yang dilakukan dengan beberapa penelitian terdahulu yang relevan di bidang klasifikasi gambar kulit wajah menggunakan CNN dan arsitektur *transfer learning*. Tujuan dari perbandingan ini adalah untuk mengetahui posisi hasil penelitian ini terhadap penelitian sebelumnya serta menilai kinerja metode yang diterapkan dalam peningkatan perfoma model.

Tabel 4.3 berikut menampilkan perbandingan antara penelitian ini dengan lima penelitian terdahulu berdasarkan model, jumlah data, jumlah kelas, serta tingkat akurasi yang diperoleh.

Tabel 4.3 Perbandingan Model dengan Penelitian Terkait.

Peneliti & Tahun	Model	Dataset & Jumlah Data	Jumlah Kelas	Akurasi
Nukhasanah & Murinto (2023) [17]	VGG16, MobileNetV2, ResNet50	Dataset penyakit kulit wajah (500 gambar)	5 kelas	90% (VGG16)
Saiwaeo dkk (2023) [18]	MobileNetV2, EfficientNetV2, InceptionV2, ResNetV1	Dataset jenis kulit wajah (329 gambar)	3 kelas	91.55% (EfficientNetV2)
Sundari dkk (2024) [19]	EfficientNetB0 (dengan Adam, SGD, RMSprop)	Dataset jenis kulit wajah (1.550 gambar)	4 kelas	100% (Adam)
Futri dkk (2023) [21]	MobileNet	Dataset jenis kulit wajah (450 gambar)	3 kelas	99% (MobileNet)
Wiguna dkk (2023) [20]	MobileNet, VGG16, ResNet50	Dataset masalah kulit wajah (225 gambar)	3 kelas	76% (MobileNet)
Grace Bindosano & Faithza Mandolang	EfficientNetB0, ResNet50, VGG16, MobileNetV3Small (SGD, Adamax, RMSprop)	Dataset masalah kulit wajah (2.478 gambar)	6 kelas	87.70% (ResNet50 + RMSprop)

Berdasarkan Tabel 4.3, penelitian ini menghasilkan akurasi 87.70% menggunakan model ResNet50 dengan optimizer RMSprop, yang menunjukan performa tinggi dan stabil dibandingkan penelitian terdahulu. Penelitian yang dilakukan oleh Sundari dan tim dimana akurasi mencapai 100%, tapi hanya mencakup empat kelas dengan jumlah dataset 1,550 gambar. Dibandingkan dengan penelitian-penelitian terdahulu, penelitian ini lebih memiliki tingkat kompleksitas yang lebih tinggi. Maka dari itu, akurasi 87.79% berarti model memiliki performa yang cukup baik dan stabil serta mampu melakukan generalisasi yang baik terhadap variasi gambar.

Selain itu, penelitian ini menonjol dalam penerapan data preprocessing yang lengkap, meliputi normalisasi gambar, *resize*, dan konversi label ke bentuk one-hot encoding, yang membantu meningkatkan kemampuan model dalam mengenali pola data secara konsisten. Pemilihan *optimizer* RMSprop dengan *learning rate* kecil juga membantu menjaga stabilitas selama proses pelatihan dan mencegah *overfitting*.

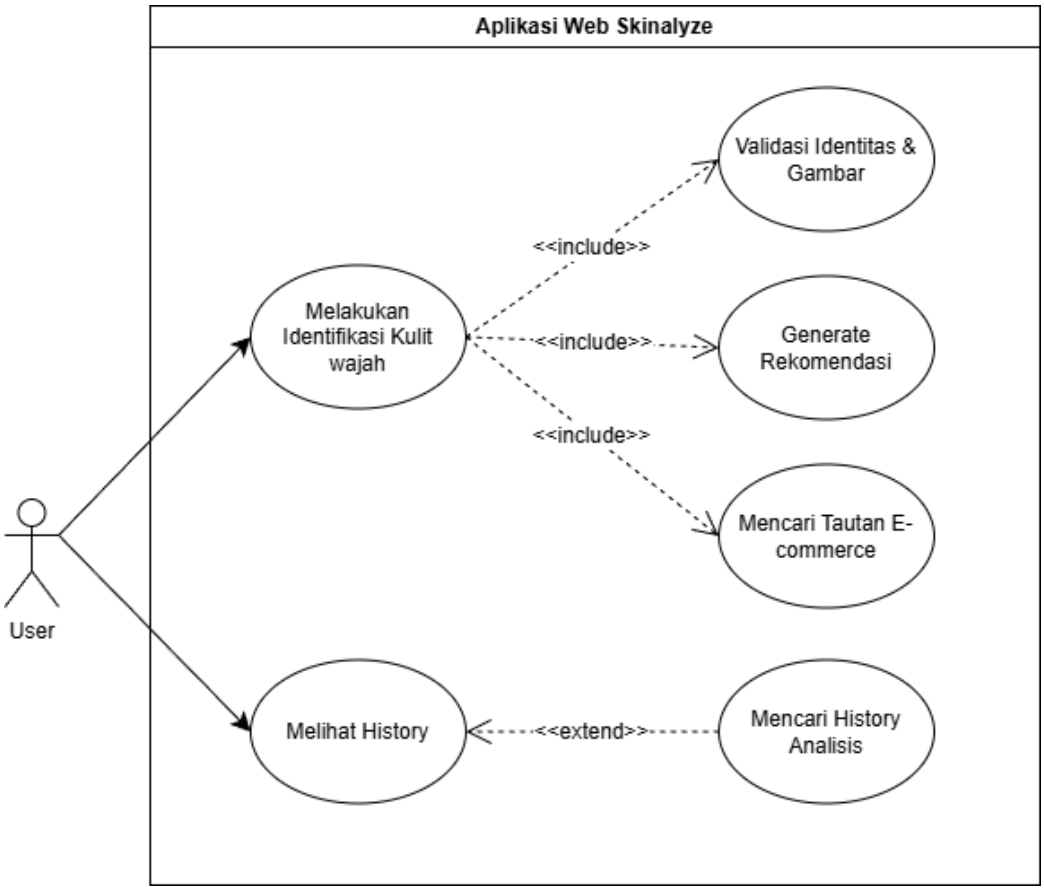
Dengan demikian, dapat disimpulkan bahwa ResNet50 dengan RMSprop merupakan model paling optimal untuk penelitian ini. Model ini tidak hanya menghasilkan akurasi yang cukup tinggi tetapi juga menunjukan kemampuan generalisasi yang baik terhadap variasi gambar kulit wajah. Hasil ini membuktikan bahwa penerapan *transfer learning* pada model ResNet50 dapat memberikan performa yang kompetitif dibandingkan penelitian terdahulu di bidang klasifikasi gambar kulit wajah.

4.6. Analisis dan Desain

Pada tahap ini mencakup identifikasi fitur-fitur utama yang dibutuhkan oleh pengguna, perancangan alur kerja sistem, serta definisi interaksi antara pengguna dan aplikasi. Tahap ini bertujuan untuk menciptakan struktur perangkat lunak yang sistematis, dan mudah dikembangkan.

4.6.1. Use Case Diagram

Langkah awal dalam pemodelan fungsional sistem, dibuatkan Use Case Diagram sebagai visualisasi ruang lingkup sistem dan interaksi yang terjadi antara actor dengan fitur-fitur yang ada.



Gambar 4.11 Use Case Diagram

Gambar 4.11 menunjukkan Use Case Diagram yang dibuat untuk memvisualisasikan interaksi antara pengguna dan sistem. Dalam perancangan ini,

aktor didefinisikan sebagai pengguna (User) yang memiliki akses penuh terhadap 2 fitur utama sistem, yaitu melakukan identifikasi kulit wajah dan melihat history.

1. Use Case Melakukan Identifikasi Kulit Wajah

Tabel 4.4 Deskripsi Use Case Melakukan identifikasi kulit wajah.

Use Case	Melakukan Identifikasi Kulit Wajah
Aktor	Pengguna (Users)
Deskripsi	Pengguna melakukan identifikasi permasalahan kulit wajah mulai dari input data diri, upload gambar, hingga menerima hasil analisis dan rekomendasi.
Trigger	Pengguna ingin mengetahui kulit kondisi kulit wajah dan mengakses menu identifikasi di halaman utama.
Kondisi awal	Pengguna berada pada halaman utama (home page) sistem.
Main flow	1. Pengguna mengisi Nama Lengkap dan membuat Username 2. Pengguna menekan tombol “Pilih foto” dan mengunggah gambar wajah (format JPEG/JPG, maks. 10MB) 3. Pengguna menekan tombol “Upload & Analisis”. 4. Sistem menjalankan use case “Validasi identitas & gambar” (include) 5. Jika validasi sukses, sistem melakukan proses klasifikasi menggunakan model ResNet50 6. Sistem menghasilkan visualisasi Grad-CAM 7. Sistem menjalankan use case “Generate rekomendasi & penjelasan” (include) 8. Sistem menjalankan use case “Mencari Tautan E-commerce” (include) 9. Sistem menyimpan seluruh data riwayat ke database MongoDB 10. Sistem menampilkan Halaman Hasil Analisis kepada pengguna

Alternative flow	3a. Format salah: jika format gambar bukan JPEG/JPG atau ukuran lebih dari 10MB, sistem menampilkan pesan peringatan dan tidak melanjutkan proses berikutnya 4a. Validasi gagal: jika use case validasi mengembalikan status gagal (identitas tidak valid atau bukan wajah manusia), sistem menghentikan proses dan menampilkan pesan peringatan.
Kondisi akhir	Pengguna berpindah ke page hasil, terdapat hasil klasifikasi, penjelasan, dan rekomendasi produk dan data tersimpan ke database

Tabel 4.4 menunjukkan proses ketika pengguna masuk ke halaman utama (home page) dan melakukan identifikasi masalah kulit wajah.

2. Use Case Validasi Identitas & Gambar (Include)

Tabel 4.5 Deskripsi Use Case Validasi identitas & gambar.

Use Case	Validasi identitas & gambar
Aktor	Sistem (otomatis)
Deskripsi	Sistem memverifikasi data pengguna di database MongoDB dan memastikan kualitas input gambar menggunakan LLM sebelum diproses lebih lanjut.
Trigger	Dipanggil secara otomatis oleh use case “Melakukan identifikasi kulit wajah” setelah tombol “Upload & Analisis” ditekan.
Kondisi awal	Data nama, username, dan file gambar telah diterima oleh server
Main flow	1. Sistem melakukan query ke database untuk mengecek ketersediaan username 2. Username baru: jika tidak ditemukan sistem menandai data untuk disimpan baru

	3. Username lama: jika ditemukan, sistem membandingkan input Nama Lengkap dengan nama yang tersimpan di database 4. Sistem mengirim file gambar ke LLM untuk verifikasi objek 5. LLM mengonfirmasi bahwa objek dalam gambar adalah wajah manusia
Alternative flow	3a. Konflik data: jika username sudah ada tetapi Nama Lengkap tidak cocok, sistem mengembalikan status gagal (Akses ditolak) 5a. Gambar invalid: jika LLM mendeteksi objek bukan wajah manusia, sistem mengembalikan status gagal
Kondisi akhir	Status validasi (Berhasil/Gagal) dikembalikan ke proses utama

Tabel 4.5 menunjukkan proses saat sistem melakukan validasi identitas dan gambar yang diinput oleh pengguna.

3. Use Case Generate Rekomendasi & Penjelasan (Include)

Tabel 4.6 Deskripsi Use Case Generate rekomendasi & penjelasan.

Use Case	Generate rekomendasi & penjelasan
Aktor	Sistem (Otomatis)
Deskripsi	Sistem menghubungi API LLM untuk mendapatkan analisis tekstual mendalam dan saran produk berdasarkan hasil klasifikasi visual.
Trigger	Dipanggil secara otomatis setelah model berhasil memprediksi label permasalahan dan Grad-CAM terbentuk.
Kondisi awal	Label klasifikasi dan gambar Grad-CAM tersedia di memori sistem

Main flow	1. Sistem mengirim prompt yang berisi label klasifikasi dan gambar Grad-CAM ke API Gemini 2.5 Flash 2. LLM menganalisis area focus pada gambar dan menghasilkan teks penjelasan penyebab masalah 3. LLM menghasilkan daftar bahan aktif yang dibutuhkan dan nama produk skincare yang direkomendasikan 4. Sistem menerima respons dari API dan memformatnya
Alternative flow	1a. API Error: jika API gemini tidak merespons atau timeout, sistem akan menghentikan proses dan menampilkan pesan error timeout
Kondisi akhir	Data teks penjelasan dan nama produk rekomendasi siap digunakan

Tabel 4.6 menunjukkan alur bagaimana sistem generate penjelasan dan rekomendasi yang akan diberikan kepada pengguna.

4. Use Case Mencari Tautan E-commerce (Include)

Tabel 4.7 Deskripsi Use Case Mencari tautan E-commerce.

Use Case	Mencari tautan E-commerce
Aktor	Sistem (otomatis)
Deskripsi	Sistem mencari URL produk asli di platform e-commerce menggunakan Google Search API agar pengguna dapat langsung membeli produk.
Trigger	Dipanggil secara otomatis setelah nama produk rekomendasi didapatkan dari LLM.
Kondisi awal	Nama produk rekomendasi tersedia.
Main flow	1. Sistem mengambil nama produk dari hasil output LLM 2. Sistem membuat query pencarian spesifik yang memfilter 6 domain e-commerce target

	3. Sistem memanggil Google Search API dengan query tersebut 4. Sistem menerima daftar hasil pencarian
Alternative flow	3a. Hasil kosong: jika google API tidak membalikan hasil dari domain target, sistem tidak menampilkan tombol tautan
Kondisi akhir	Tautan URL produk siap ditampilkan pada nama produk (hover)

Tabel 4.7 menggambarkan alur sistem melakukan pencarian tautan e-commerce dari produk yang direkomendasikan.

5. Use Case Melihat History

Tabel 4.8 Deskripsi Use Case Melihat history.

Use Case	Melihat history
Aktor	Pengguna (Users)
Deskripsi	Pengguna melihat daftar Riwayat analisis yang tersimpan di database dan melihat detailnya
Trigger	Pengguna menekan menu “History” pada navigasi
Kondisi awal	Pengguna berada pada halaman utama (home page) sistem.
Main flow	1. Sistem mengambil seluruh data riwayat public 2. Sistem menampilkan daftar kartu riwayat secara kronologis 3. Pengguna memilih dan mengklik salah satu kartu riwayat 4. Sistem mengambil data detail berdasarkan ID riwayat tersebut 5. Sistem menampilkan halaman detail history

Alternative flow	1a. Data kosong: jika database kosong, sistem menampilkan pesan “belum ada riwayat” 3a. Pencarian: pengguna melakukan pencarian spesifik (use case extend)
Kondisi akhir	Informasi detail riwayat ditampilkan kepada pengguna

Tabel 4.8 menunjukkan alur ketika pengguna mengakses fitur history untuk melihat kembali data hasil identifikasi yang telah dilakukan sebelumnya.

6. Use Case Mencari History Analisis (Extend)

Tabel 4.9 Deskripsi Use Case Mencari history analisis.

Use Case	Mencari history analisis
Aktor	Pengguna (Users)
Deskripsi	Fitur tambahan untuk menyaring daftar riwayat berdasarkan kata kunci tertentu.
Trigger	Pengguna mengetik kata kunci di kolom pencarian dan menekan tombol “cari”
Kondisi awal	Pengguna berada di halaman history dengan daftar riwayat yang tampil
Main flow	1. Pengguna memasukkan kata kunci (Nama Lengkap, username, label permasalahan) 2. Sistem melakukan query pencarian spesifik ke mongodb 3. Sistem memperbarui tampilan daftar riwayat hanya dengan item yang cocok
Alternative flow	2a. Tidak ditemukan: jika hasil pencarian tidak ditemukan, tidak ada data yang ditampilkan pada halaman history

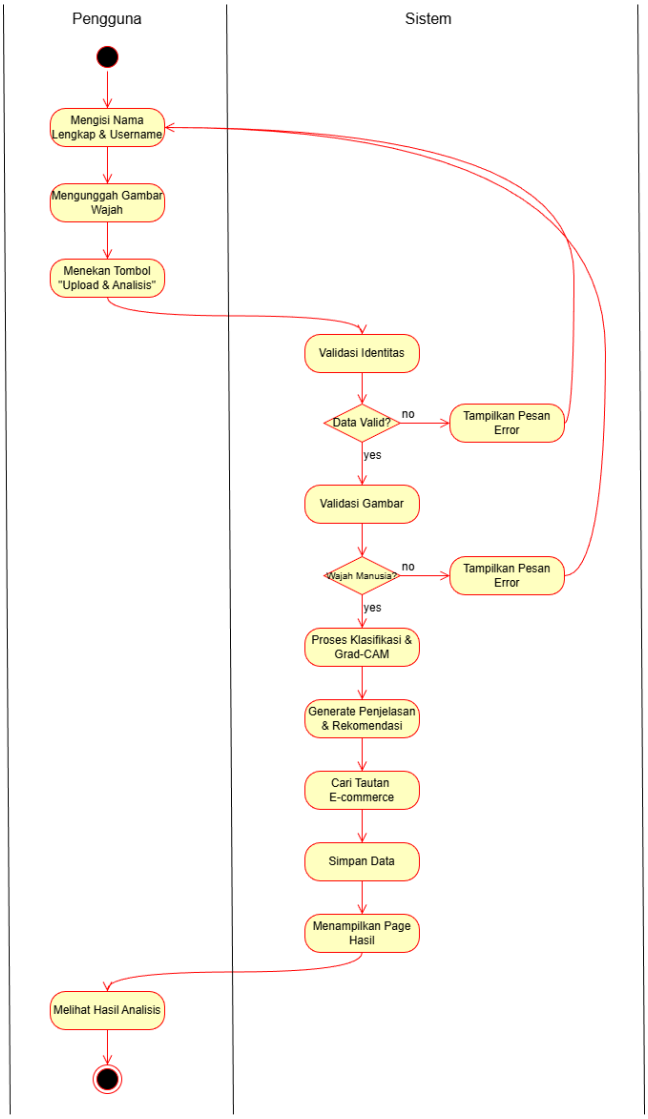
Kondisi akhir	Daftar riwayat terfilter ditampilkan

Tabel 4.9 adalah alur ketika pengguna ingin mencari data riwayat yang spesifik.

4.6.2. Activity Diagram

Setelah mendefinisikan fungsionalitas sistem dengan Use Case Diagram, tahap berikutnya adalalah membuat Activity Diagram. Activity Diagram digunakan untuk memodelkan alur kerja (workflow) procedural dari sistem, menggambarkan urutan aktivitas dari awal hingga akhir serta Keputusan yang terjadi di dalamnya.

1. Activity Diagram Melakukan Identifikasi Kulit Wajah

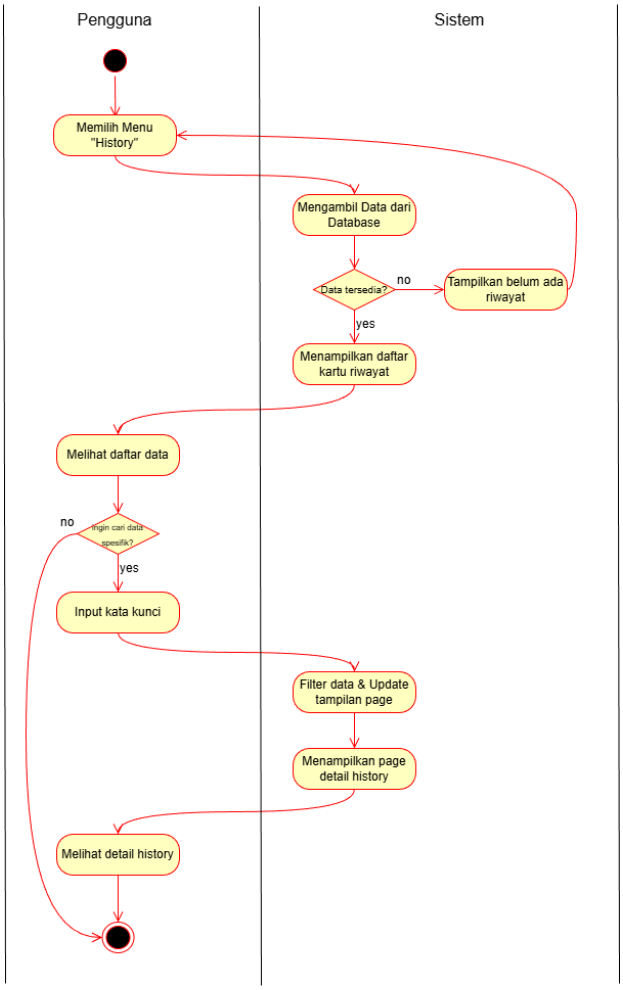


Gambar 4.12 Activity Diagram Melakukan Identifikasi Kulit Wajah.

Gambar 4.12 mengilustrasikan alur aktivitas pada fitur utama identifikasi. Proses dimulai ketika pengguna memasukkan data identitas dan mengunggah gambar wajah. Setelah tombol “Upload & Analisis” ditekan, sistem melakukan validasi berlapis, pertama memverifikasi identitas pengguna, dan kedua memvalidasi objek gambar. Jika tidak valid, sistem akan menampilkan pesan kesalahan dan mengembalikan pengguna ke tahap awal. Jika valid, sistem melanjutkan ke proses klasifikasi menggunakan model ResNet50, menghasilkan

visualisasi Grad-CAM, serta secara otomatis menghasilkan penjelasan melalui LLM dan mencari tautan produk relevan melalui Google Search API. Seluruh hasil analisis kemudian disimpan ke database dan ditampilkan pada halaman hasil untuk dilihat oleh pengguna.

2. Activity Diagram Melihat History



Gambar 4.13 Activity Diagram Melihat History.

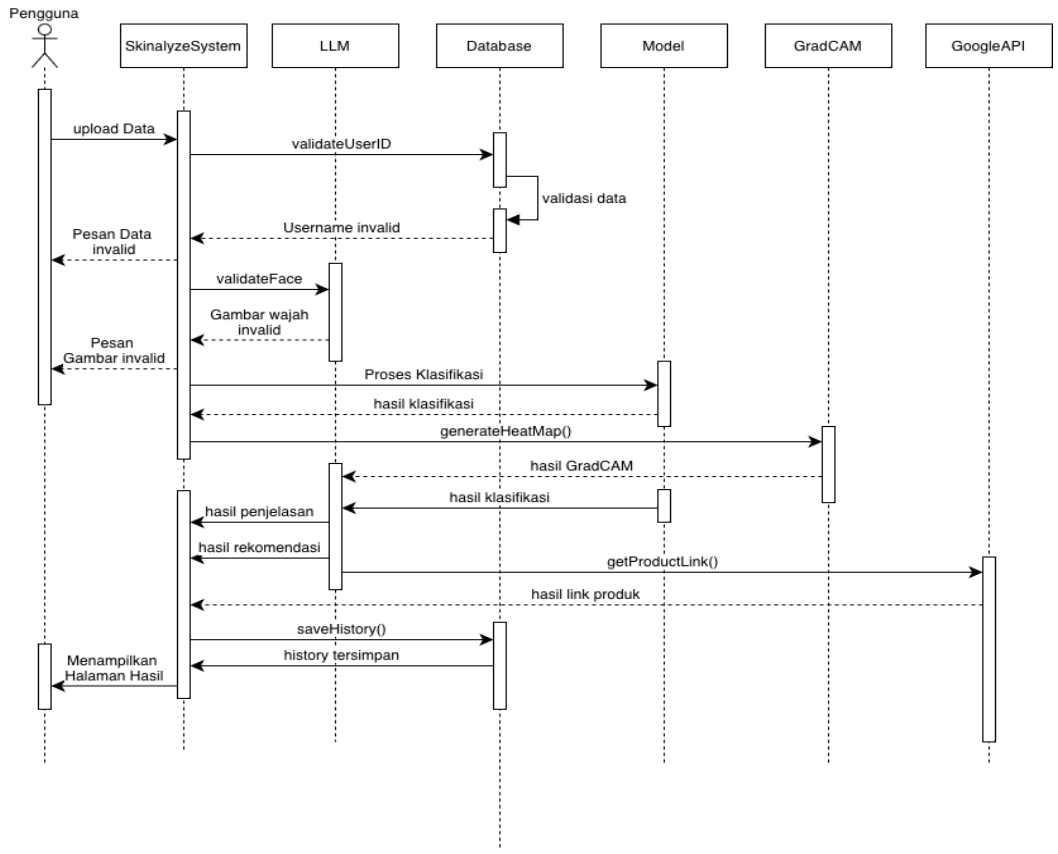
Gambar 4.13 menggambarkan alur kerja pada halaman history. Saat pengguna memilih menu “History”, sistem secara otomatis mengambil data riwayat dari database. Jika data tidak tersedia, sistem menampilkan pesan “Belum ada riwayat”. Jika data tesedia, terdapat percabangan aktivitas di mana pengguna dapat memilih untuk mencari data spesifik dengan memasukkan kata kunci, yang akan

memicu sistem untuk memfilter data dan memperbarui tampilan halaman. Alternatifnya, pengguna dapat langsung memilih salah satu kartu riwayat untuk melihat detail lengkap analisis yang tersimpan. Alur berakhir ketika pengguna melihat halaman detail riwayat tersebut.

4.6.3. Sequence Diagram

Setelah memodelkan alur kerja sistem menggunakan Activity Diagram, tahap selanjutnya adalah menjabarkan interaksi antar objek secara lebih detail dengan menggunakan Sequence Diagram. Berbeda dengan Activity Diagram yang berfokus pada aliran aktivitas, Sequence Diagram berfokus pada objek-objek yang ada dalam sistem dan bagaimana interaksi antar objek yang ada.

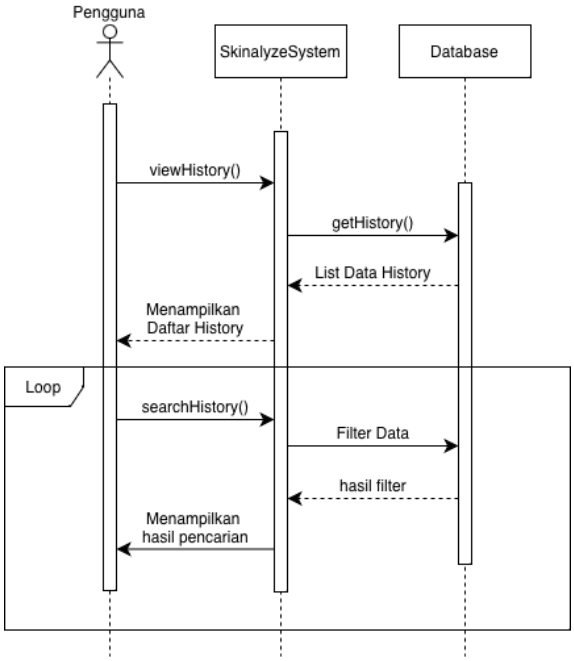
1. Sequence Diagram melakukan Identifikasi Permasalahan Kulit Wajah



Gambar 4.14 Sequence Diagram melakukan Identifikasi Permasalahan Kulit Wajah.

Gambar 4.14 menggambarkan interaksi sekuensial antara Pengguna dan berbagai komponen sistem dalam proses identifikasi kulit wajah. Alur dimulai ketika Pengguna mengunggah data identitas dan gambar wajah ke Aplikasi Web. Sistem terlebih dahulu memvalidasi data pengguna ke database dan memastikan validitas gambar wajah menggunakan LLM. Setelah validasi berhasil, model melakukan proses klasifikasi permasalahan kulit wajah, sementara GradCAM menghasilkan visualisasi heatmap untuk area yang terdeteksi. Hasil klasifikasi tersebut kemudian diteruskan kembali ke LLM untuk menghasilkan penjelasan serta rekomendasi produk. Berdasarkan rekomendasi tekstual dari LLM, sistem melakukan permintaan ke GoogleAPI untuk mendapatkan tautan produk e-commerce yang relevan. Seluruh hasil analisis, visualisasi, dan rekomendasi kemudian disimpan ke dalam database sebelum akhirnya ditampilkan pada halaman hasil kepada Pengguna.

2. Sequence Diagram melihat History

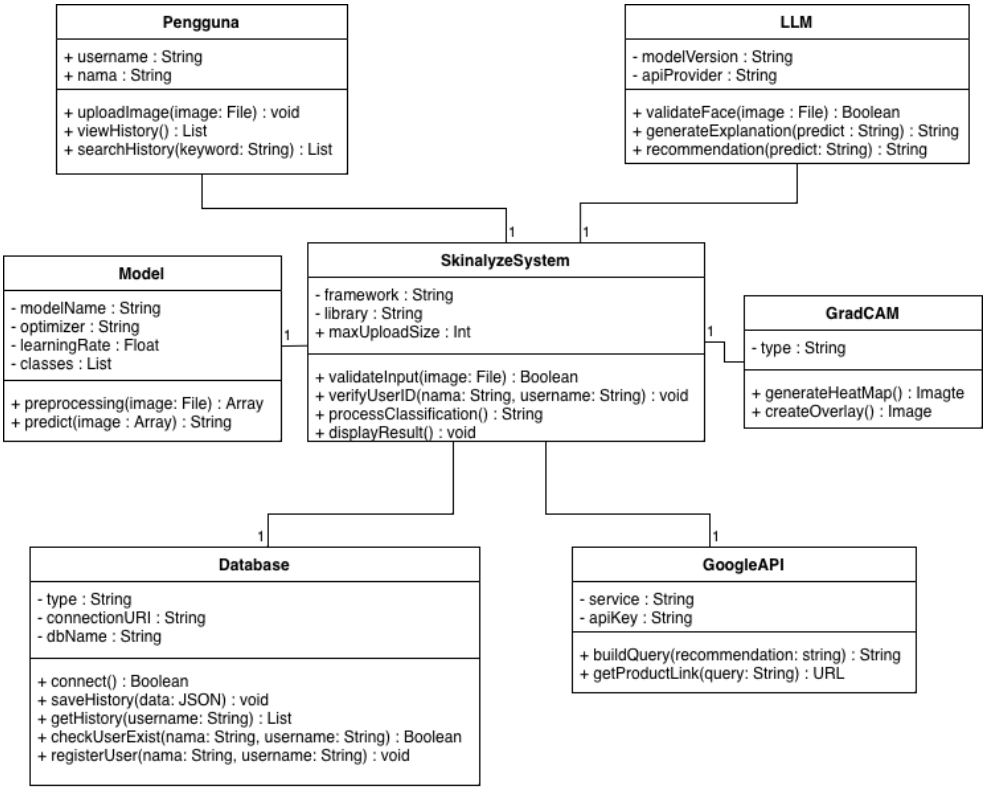


Gambar 4.15 Sequence Diagram melihat History.

Gambar 4.15 menggambarkan alur interaksi pada fitur History. Proses dimulai ketika Pengguna mengakses menu riwayat, yang kemudian direspons oleh sistem dengan mengambil seluruh data riwayat pengguna dari database. Setelah data diterima, sistem menampilkannya dalam bentuk daftar riwayat. Diagram ini juga menyertakan blok loop yang merepresentasikan fitur pencarian berulang, di mana Pengguna dapat memasukkan kata kunci seperti nama pengguna, username, ataupun hasil klasifikasi. Sistem kemudian meminta database untuk melakukan filter terhadap data berdasarkan kata kunci tersebut dan memperbarui tampilan antarmuka dengan hasil pencarian yang spesifik, memungkinkan pengguna untuk menemukan history pengguna dengan lebih efisien.

4.6.4. Class Diagram

Setelah memodelkan interkasi antar objek dengan menggunakan Sequence Diagram, tahap selanjutnya adalah mendefinisikan struktur perangkat lunak menggunakan Class Diagram. Diagram ini berfungsi sebagai gambaran bagaimana setiap komponen sistem saling terhubung, berbagi tugas, dan bekerja sama membentuk fungsionalitas sistem secara utuh.



Gambar 4.16 Class Diagram.

Gambar 4.16 merupakan arsitektur sistem Skinalyze dirancang dengan pola terpusat di mana kelas SkinalyzeSystem bertindak sebagai pengontrol utama. Kelas ini menjadi jembatan tunggal yang mengatur seluruh lalu lintas data dari kelas Pengguna menuju berbagai pemrosesan. Untuk menjalankan fungsi utamanya, sistem memanggil kelas Model yang berisi logika kecerdasan buatan untuk klasifikasi citra, serta kelas GradCAM yang bertugas memvisualisasikan hasil analisis tersebut agar lebih transparan. Manajemen data ditangani secara khusus oleh kelas Database, yang tidak hanya menyimpan riwayat analisis tetapi juga memverifikasi validitas pengguna baru maupun lama. Selain itu, sistem diperkaya dengan integrasi layanan eksternal melalui kelas LLM yang memberikan interpretasi cerdas, dan kelas GoogleAPI yang memfasilitasi pencarian tautan produk secara real-time sesuai rekomendasi yang diberikan.

BAB 5

IMPLEMENTASI

Pada bab ini membahas tentang hasil dari aplikasi web yang dikembangkan dan fungsi-fungsi sistem yang sudah terintegrasi.

5.1. Implementasi Aplikasi Web

Tahap terakhir dalam penelitian ini adalah tahap implementasi. Pada tahap ini, model yang telah dilatih dan dievaluasi akan diimplementasikan kepada sistem yang telah dikembangkan. Peneliti menggunakan framework flask untuk membangun aplikasi web serta mengintegrasikan model ke aplikasi web. Model yang telah dilatih disimpan dalam format .h5 menggunakan Keras dan TensorFlow dapat diintegrasikan ke dalam sistem. EfficientNetB0, ResNet50, MobileNetV3 merupakan model-model yang dilatih serta menggunakan optimizer seperti Adamax, RMSprop, dan SGD. Model terbaik dari hasil evaluasi adalah ResNet50 dengan akurasi 87.70% dengan optimizer RMSprop. Model dilatih dengan mengunakan loss categorical_crossentropy.

Aplikasi web yang dikembangkan memungkinkan penggun untuk mengunggah gambar wajah dan menerima hasil klasifikasi permasalahan kulit wajah ke dalam enam kelas berbeda yaitu Kerutan, Kulit Kering, Kulit Berminyak, *Dark-spot*, Kemerahan, dan Jerawat. Untuk mengvisualisasikan hasil klasifikasi dari model, Grad-CAM digunakan untuk menunjukan bagian wajah yang berkontribusi terhadap hasil klasifikasi. Selain itu, sistem diintegrasikan dengan *Large Language Model* (LLM) untuk menghasilkan penjelasan terhadap hasil klasifikasi dan Grad-CAM, bahan aktif yang dibutuhkan, serta rekomendasi skincare yang disesuaikan dengan hasil klasifikasi. Dengan begitu, pengguna dapat

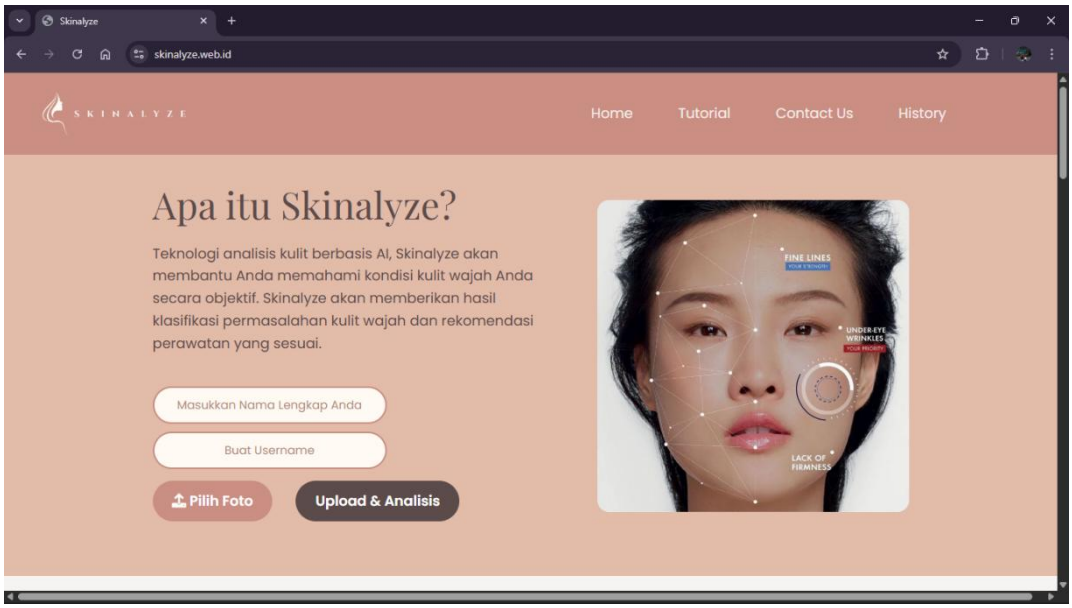
mengerti permasalahan kulit wajah, mengetahui bahan aktif yang dibutuhkan dan rekomendasi *skincare.*

Untuk melengkapi rekomendasi tersebut dengan tautan produk, sistem memanfaatkan Google Search API. Mekanisme ini tidak tehubung langsung ke API internal dari enam platform e-commerce yang telah ditentukan, melainkan melakukan pencarian produk secara dinamis. Proses ini dimulai secara otomatis setelah LLM memberikan rekomendasi nama produk atau kandungan. Sistem kemudian merumuskan sebuah kueri pencarian yang spesifik. Kueri ini dirancang khusus untuk membatasi pencarian hanya pada domain dari enam platform e-commerce yang telah ditetapkan. Dari daftar hasil yang dikembalikan oleh Google Search API, sistem akan mengambil satu tautan, yaitu hasil pencarian dengan peringkat teratas. Dengan demikian, tautan yang diberikan kepada pengguna dipilih berdasarkan relevansi tertinggi yang ditentukan oleh algoritma Google Search pada saat itu. Sistem mengandalkan Google untuk menentukan satu tautan yang tidak hanya paling sesuai dengan rekomendasi LLM, tetapi juga berasal dari sumber yang paling terpercaya di antara enam platform yang ditargetkan. Semua langkah yang dilakukan untuk pencarian tautan sepenuhnya dilakukan oleh algoritma internal Google Search yang sangat kompleks. Penting untuk dicatat bahwa sistem ini tidak melakukan pemeringkatan ulang berdasarkan rating produk, jumlah penjualan, atau harga terendah, namun mengandalkan Google API untuk menyediakan tautan yang paling relevan dari salah satu platform target.

Aplikasi web dapat diakses secara publik melalui link skinalyze.web.id Pengguna dapat menggunakan fitur klasifikasi dengan mengunggah gambar wajah. Selain itu, aplikasi web ini menyediakan fitur *history*, dimana pengguna dapat

melihat riwayat hasil klasifikasi dari pengguna lain. Pengguna dapat mencari dari nama pengguna lain ataupun hasil klasifikasi.

Dengan adanya tahap implementasi, diharapkan sistem dapat menjadi solusi lain apabila pengguna tidak memiliki akses terhadap dermatolog, serta menjadi langka awal dalam mengindentifikasi permasalahan kulit wajah.



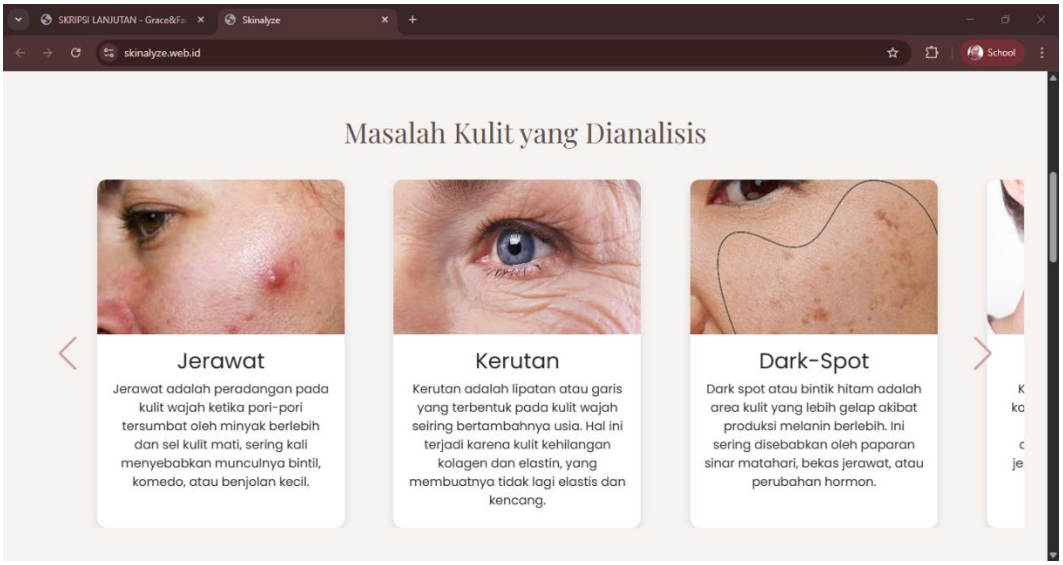
Gambar 5.1 Tampilan Home Page bagian Upload Gambar.

Gambar 5.1 menampilkan antarmuka bagian atas dari home page. Halaman ini berisi judul dan deskripsi singkat tentang Skinalyze. Pada bagian ini tersedia fitur upload gambar wajah. Pengguna dapat memilih foto yang ingin diunggah dan diklasifikasi. Gambar yang diunggah dibatasi dengan tipe file PNG dan JPEG serta, ukuran gambar maksimal 10MB. Terdapat juga menu navigasi pada bagian atas halaman yang terdiri dari "*Home*", "*Tutorial*", "*Contact Us*", dan "*History*". Tampilan dirancang untuk menarik perhatian pengguna agar mereka dapat memahami fungsi utama aplikasi web dan mencoba fitur klasifikasi. Tampilan dirancang untuk menarik perhatian pengguna agar mereka dapat memahami fungsi utama aplikasi dan menggunakan fitur klasifikasi permasalahan kulit wajah.

Sebelum melakukan proses klasifikasi, pengguna diwajibkan untuk mengisi kolom identitas yang terdiri dari Nama Lengkap dan membuat *Username*. Ini berfungsi sebagai mekanisme identifikasi unik untuk pencatatan Riwayat (history) analisis pengguna. Mekanisme validasi identitas berjalan secara otomatis saat pengguna menekan tombol "Upload & Analisis". Sistem akan terlebih dahulu memeriksa ketersediaan *username* di dalam *database*. Jika *username* belum pernah terdaftar, sistem akan menyimpan data username dan nama lengkap sebagai data baru ke *database*, lalu melanjutkan ke proses klasifikasi. Namun, jika *username* sudah terdaftar, sistem akan memvalidasi kepemilikan dengan mencocokkan nama lengkap yang diinput dengan data nama yang tersimpan pada *username* tersebut. Jika data cocok, sistem akan mengizinkan proses berlanjut, sebaliknya jika nama lengkap tidak sesuai, sistem akan menolak input tersebut dan menghentikan proses. Mekanisme ini memastikan bahwa *username* bersifat unik dan menjaga konsistensi data Riwayat pengguna

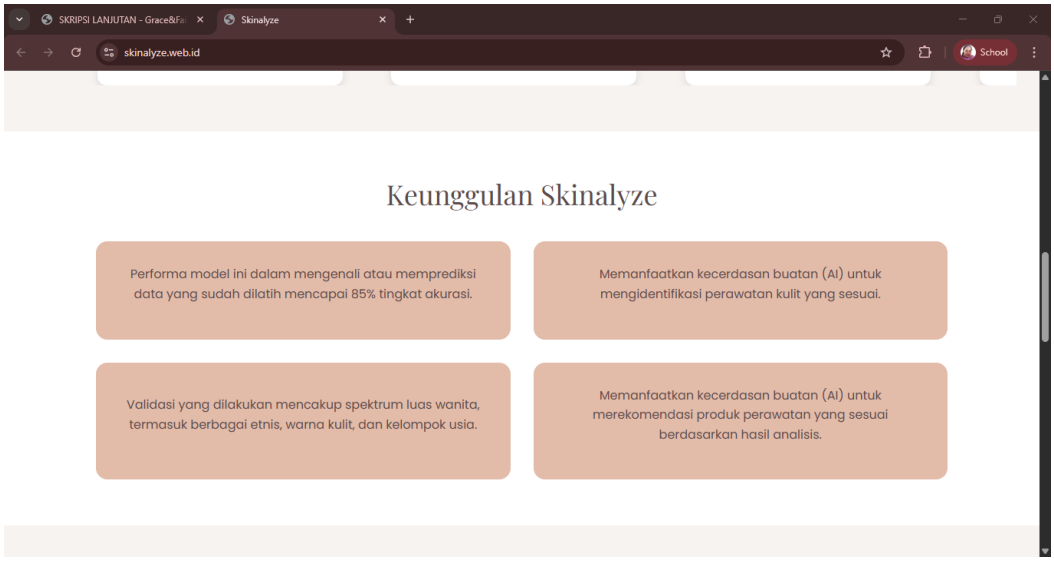
Untuk kasus dimana gambar yang diunggah oleh pengguna bukan merupakan gambar wajah manusia, maka sistem tidak akan lanjut ke proses klasifikasi. Sistem akan menampilkan pesan bahwa gambar tidak sesuai. Jika gambar yang diunggah divalidasi benar benar gambar wajah manusia, maka sistem melanjutkan proses klasifikasi. Tetapi jika gambar tidak termasuk dalam enam kelas yang dilatih, maka model dipaksa untuk tetap melakukan klasifikasi dengan melihat fitur yang ada pada gambar tersebut dan mencocokkannya dengan fitur yang ada pada enam kelas yang telah dipelajari. Jadi model akan mengklasifikasi sesuai dengan kemiripan fitur yang ada pada gambar.

Adapun untuk kasus satu gambar memiliki dua wajah manusia, hal ini tidak bisa dikarenakan model dilatih dengan dataset gambar satu wajah dan jika dimasukkan gambar dua wajah model kemungkinan besar akan bingung. Jika begitu, model tidak bisa melakukan klasifikasi dengan benar karena gambar yang dimasukkan memiliki fitur yang berbeda dari data pelatihan yang digunakan. Model tidak dilatih untuk memproses dua wajah pada satu gambar. Dengan begitu, hasil klasifikasi yang diberikan sangat tidak dapat diandalkan.



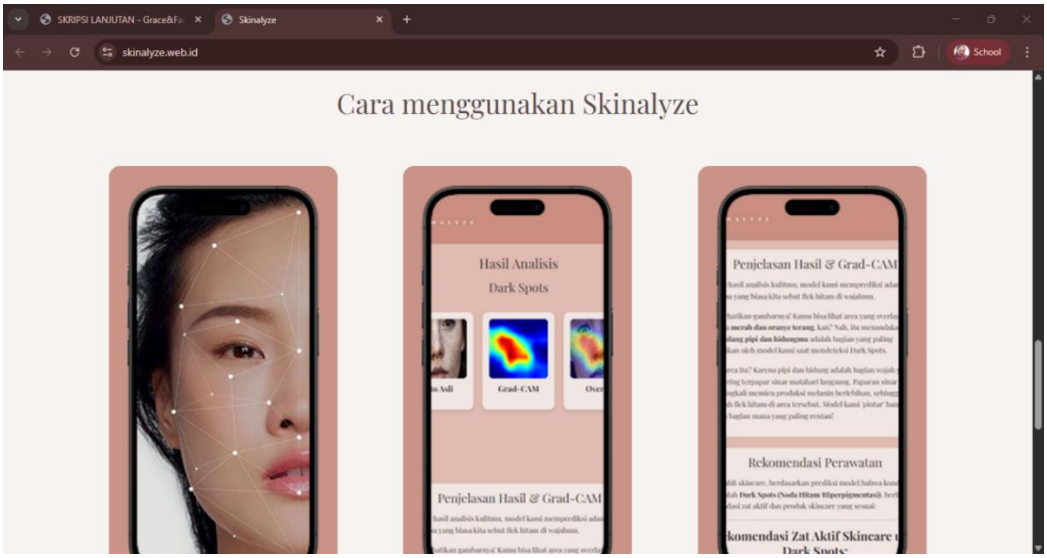
Gambar 5.2 Tampilan Home Page bagian Jenis permasalahan kulit wajah.

Gambbar 5.2 menampilkan jenis-jenis permasalahan kulit yang model pelajari. Ada 6 jenis permasalah kulit yang dipelajari model yaitu Jerawat, Kerutan, Dark-Spot, Kemerahan, Kulit Berminyak, dan Kulit Kering. Setiap jenis permasalahan kulit dilengkapi dengan gambar ilustrasi dan penjelasan singkat. Tampilan ini dirancang dengan format kartu yang visual dan informatif agar pengguna dapat mengetahui jenis permasalahan kulit wajah serta kapabilitas dan batasan dari sistem.

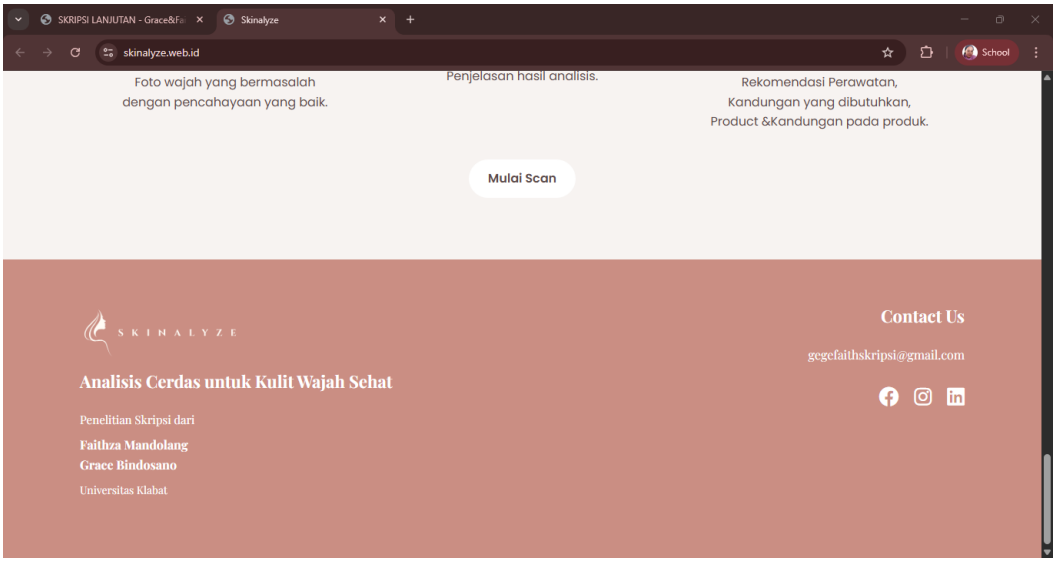


Gambar 5.3 Tampilan Home Page bagian Keunggulan.

Gambar 5.3 menampilkan bagian keunggulan dari Skinalyze. Bagian ini menyoroti kelebihan dari sistem. Kelebihan tersebut mencakup akurasi model, pemanfaatan teknologi AI, validasi dataset, dan hasil yang bersifat personalisasi. Model telah dilatih sehingga mendapatkan akurasi sebesar 85%. Pemanfaatan teknologi AI yang digunakan untuk mengidentifikasi perawatan yang sesuai dengan masalah kulit yang terdeteksi. Dataset yang digunakan telah divalidasi oleh dermatolog dan mencakup etnis, warna kulit, dan usia yang beragam. AI juga digunakan untuk menghasilkan rekomendasi produk perawatan yang sesuai.Tampilkan dirancang untuk membangun kepercayaan pengguna.

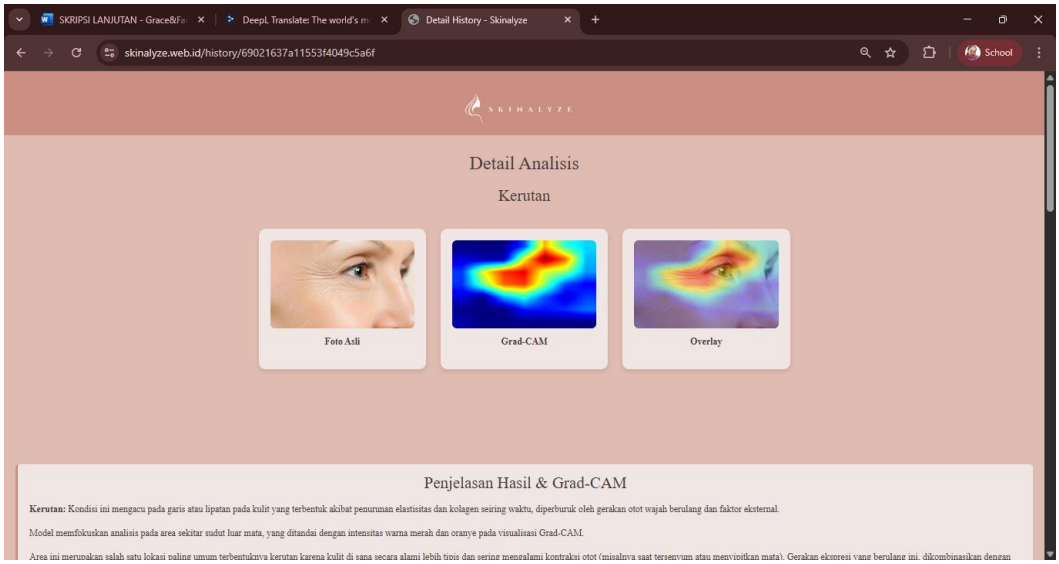


Gambar 5.4 Tampilan Home Page bagian Tutorial.



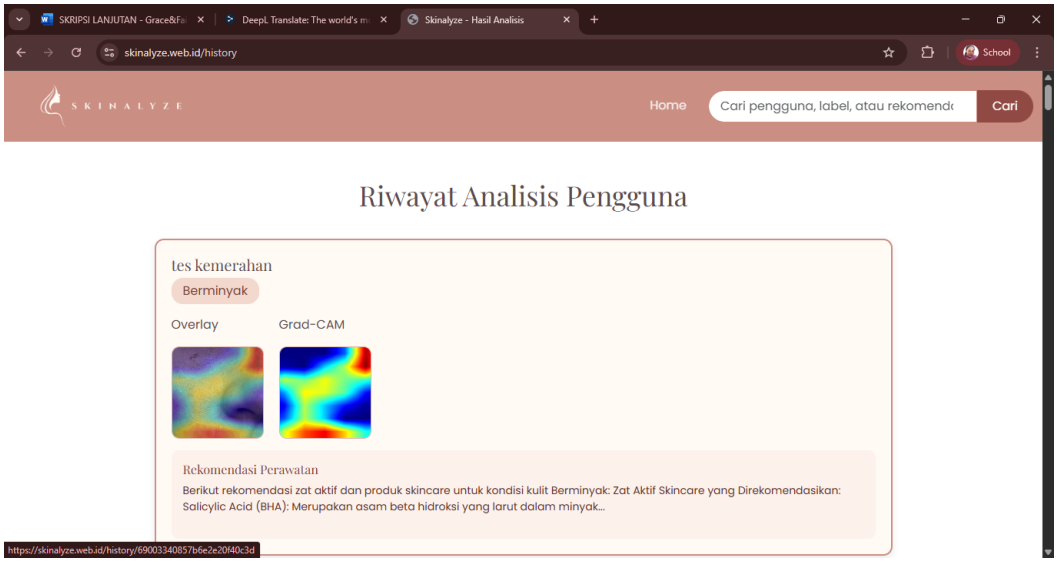
Gambar 5.5 Tampilan Home Page bagian Footer.

Gambar 5.4 menampilkan bagian cara menggunakan Skinalyze. Bagian ini berfungsi sebagai tutorial visual yang menunjukkan langkah penggunaan aplikasi web. Desain tampilan ini bertujuan untuk mengurangi kebingungan pengguna dan menunjukkan cara menggunakan aplikasi web ini. Gambar 5.5 menampilkan bagian footer home page yang menampilkan informasi tentang peneliti sepert nama, universitas, dan informasi contact us. Tampilan didisain dengan sederhana agar dapat memeberikan informasi yang jelas kepada pengguna.

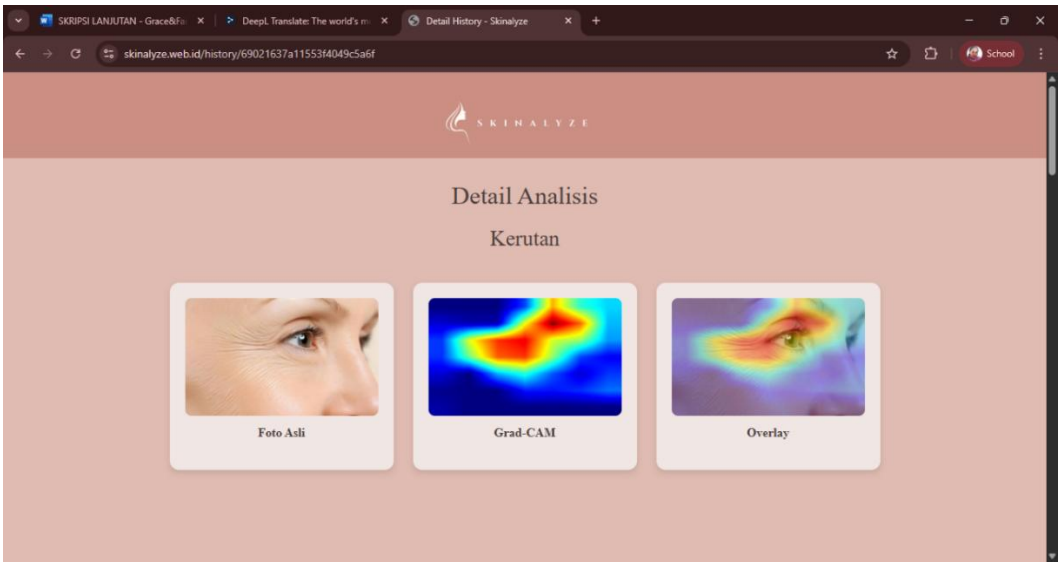


Gambar 5.6 Tampilan Halaman Hasil.

Gambar 5.6 menampilkan antarmuka sistem setelah pengguna mengunggah gambar dan mendapatkan hasil klasifikasi permasalahan kulit wajah serta hasil Grad-CAM. Pada halaman hasil, terdapat hasil klasifikasi berupa text, gambar wajah original, gambar hasil Grad-CAM, dan gambar wajah *overlay* dengan Grad-CAM. Terdapat juga penjelasan textual dari hasil klasifikasi dan rekomendasi produk *skincare* yang sesuai dari pasar lokal maupun global. Pejelasan hasil klasifikasi, bahan aktif yang dibutuhkan, dan rekomendasi merupakan hasil dari *Large Language Model*(LLM). Selain itu, LLM juga digunakan untuk validasi input gambar, dimana jika terdeteksi gambar bukan wajah manusia maka sistem tidak akan lanjut ke tahap klasifikasi. Jika hasil validasi benar gambar wajah maka sistem akan lanjut ke tahap klasifikasi dan LLM akan menghasilkan penjelasan dan rekomendasi *skincare*.



Gambar 5.7 Tampilan Halaman History.



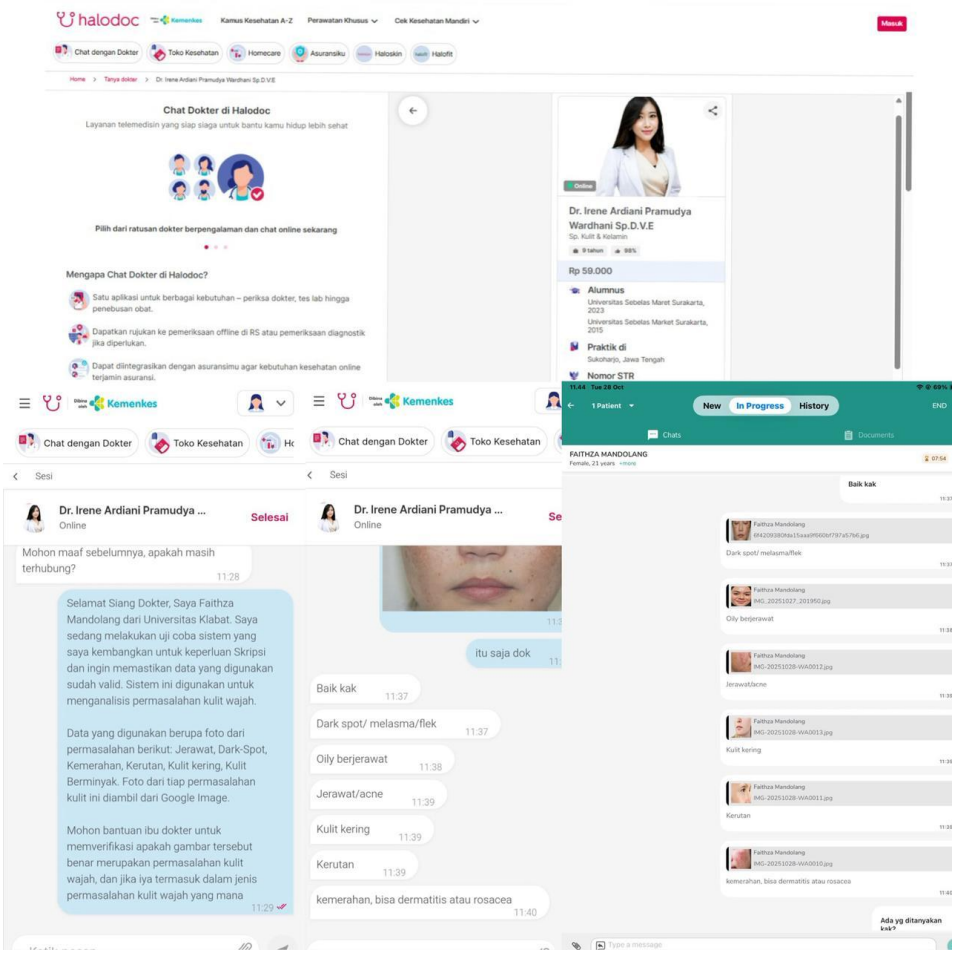
Gambar 5. 8 Tampilan Halaman History Detail.

Gambar 5.7 dan Gambar 4.18 menampilkan antarmuka sistem pada bagian *history* yang dapat diakses oleh pengguna. Data yang diunggah oleh pengguna seperti data nama dan gambar permasalahan kulit wajah akan disimpan. Selain itu, hasil klasifikasi, Grad-CAM, overlay Grad-CAM, serta penjelesan dan rekomendasi juga disimpan oleh sistem menggunakan database MongoDB. Penggunaan MongoDB memungkinkan sistem untuk menyimpan data dari pengguna dan pengguna dapat melihat kembali riwayat klasifikasi mereka sendiri

ataupun pengguna lain. Pada halaman *history*, pengguna dapat mencari riwayat hasil klasifikasi mereka sendiri dan pengguna lain. Pencarian dapat dilakukan dari nama pengguna ataupun hasil klasifikasi. Gambar 5.8 menampilkan isi dari *history* pengguna. Pengguna dapat membuka hasil klasifikasi dari pengguna lain dan melihat penjelasan dan rekomendasi *skincare*. Tampilan dibuat dengan sederhana agar pengguna dapat mengakses history dengan mudah.

5.2. Pengujian Fungsionalitas Aplikasi Web

Pada tahap pengujian sistem, dua pengujian dilakukan oleh peneliti yaitu validasi data gambar permasalahan kulit wajah oleh dokter spesialis dan pengujian fungsionalitas sistem aplikasi web. Pengujian dilakukan untuk memastikan sistem berjalan sesuai dengan harapan.



Gambar 5.9 Validasi input data dengan Dokter Kulit.

Gambar 5.9 menampilkan proses validasi data, berupa gambar, yang diambil dari internet. Gambar yang diambil dari internet akan divalidasi oleh dokter. Validasi data dilakukan untuk memastikan bahwa label dari data yang digunakan sesuai dengan masalah nyata. Proses validasi dilakukan dengan menghubungi salah satu dokter spesialis kulit, yaitu Dr. Irene Ardiani Pramudya Wardhani Sp.D.V.E, seorang spesialis Kulit dan Kelamin.

Komunikasi dengan Dr. Irene berawal dengan perkenalan singkat tentang sistem yang sementara dikembangkan. Setelah itu, kami mengirimkan beberapa gambar permasalahan kulit wajah yang telah dipelajari sistem kami yaitu Jerawat, Dark-spot, Kemerahan, Kerutan, Kulit kering, dan Kulit berminyak. Dokter

kemudian memvalidasi dengan menyatakan bahwa label data sudah sesuai dengan gambar yang dikirim. Hasil prediksi menunjukan hasil yang sama dengan validasi dokter. Bukti validasi berupa tangkapan layar percakapan dengan nama dan gambar profil dokter.

Selain validasi data, pengujian dilakukan terhadap seluruh fitur dalam aplikasi web. Pengujian dilakukan dengan tujuan untuk memastikan fitur berfungsi dan sesuai dengan spesifikasi. Selain dari itu, pengujian dapat digunakan untuk menemukan bug, agar dapat dilakukan perbaikan.

Hasil klasifikasi yang benar berarti model sudah mempelajari fitur tiap kelas dari dataset. Dimana tiap label memiliki fitur yang berbeda dan model sudah dapat membedakannya. Tetapi model bisa saja salah melakukan klasifikasi. Ada beberapa kemungkinan model salah klasifikasi seperti kemiripan fitur antar-kelas, kualitas gambar, atau gejala tumpang tindih. Dikarenakan sistem yang dikembangkan berupa *multiclass*, proses klasifikasi didasarkan pada penentuan kelas yang memiliki bobot fitur paling signifikan dan berkontribusi paling besar. Selain itu, pengujian fungsionalitas sistem secara keseluruhan dibutuhkan. Dengan begitu dapat dipastikan semua fitur berjalan sesuai dengan spesifikasinya.

Tabel 5.1 Pengujian Fungsionalitas Aplikasi Web.

No	Fitur	Output	Hasil
1	*Upload* Gambar dan Nama Pengguna	Gambar dan Nama diunggah ke sistem	Berhasil
2	Menampilkan Hasil Klasifikasi	Ditampilkan Hasil klasifikasi, Gambar asli, Hasil Grad-CAM, dan Overlay Grad-CAM	Berhasil
3	Penjelasan Hasil Grad-CAM dengan Gemini	Ditampilkan penjelasan tekstual hasil klasifikasi, bahan aktif yang dibutuhkan,	Berhasil

		dan rekomendasi produk *skincare*	
4	*History* Klasifikasi Pengguna	Hasil klasifikasi, Gambar asli, Hasil Grad-CAM, dan *Overlay* Grad-CAM disimpan ke sistem	Berhasil
5	Melihat *History* Hasil Klasifikasi Semua Pengguna	Ditampilkan Nama, hasil klasifikasi, hasil Grad-CAM dan *Overlay* Grad-CAM dari pengguna	Berhasil
6	Fitur Pencarian *History* Pengguna	Data *History* pengguna dapat dicari lewat Hasil klasifikasi ataupun Nama	Berhasil

BAB 6

KESIMPULAN DAN SARAN

Bab 6 ini berisi kesimpulan dari penelitian ini beserta saran-saran untuk penelitian kedepannya.

6.1. Kesimpulan

Penelitian ini berhasil mengembangkan sistem klasifikasi permasalahan kulit wajah dengan memanfaatkan metode *transfer learning* menggunakan arsitektur *deep learning*, yaitu VGG16, EfficientNetB0, MobileNetV3Small, dan ResNet50. Keempat model diuji dengan variasi *hyperparameter* seperti *optimizer, batch size, epoch, dan learning rate* untuk menentukan arsitektur yang memberikan hasil terbaik. Berdasarkan hasil training, ResNet50 dengan *optimizer* RMSprop menunjukan performa tertingi dengan akurasi mencapai 87.70%. Hasil tersebut menunjukan bahwa ResNet50 lebih unggul dalam mengekstraksi fitur-fitur penting pada gambar wajah dibandingkan model lainnya, sehingga model ini dipilih untuk digunakan dalam sistem utama.

Pendekatan *transer learning* cukup mampu mengatasi keterbatasan dataset yang relative kecil karena model memanfaatkan bobot hasil pelatihan dari dataset besar seperti ImageNet. Dengan adaptasi bobot pre-trained tersebut, model dapat mengenali pola visual umum wajah dan menyesuaikannya terhadap karakteristik spesifik dari berbagai permasalan kulit seperti jerawat, dark spots, kulit kering, kulit berminyak, kemerahan, dan kerutan. Hasil eksperimen menunjukan ResNet50 mampu melakukan klasifikasi dengan tingkat akurasi yang cukup tinggi dan stabilitas performa yang baik dari model yang lain.

Untuk meningkatkan transparansi sistem, penelitian ini menerapkan Grad-CAM yang menghasilkan visualisasi area wajah yang menjadi focus perhatian model. Visualisasi ini membantu pengguna memahami dasar keputusan model dan meningkatkan kepercayaan terhadap hasil klasifikasi. Selain itu, sistem juga mengintegrasikan LLM Gemini 2.5 Flash untuk menghasilkan deskripsi hasil analisis dan rekomendasi *skincare* yang bersifat personal, seperti menyarankan serum yang cocok dengan dark spots, atau moisturizer yang cocok untuk kulit kering. Pengguna juga bisa langsung melihat produk yang direkomendasikan melalui tautan e-commerce yang disediakan dalam sistem. Tautan ini diperoleh secara otomatis melalui pencarian produk menggunakan Google Search API, sehingga rekomendasi yang diberikan bersifat dinamis dan relevan dengan ketersediaan produk di pasaran.

Aplikasi web yang dikembangkan menggunakan *framework* Flask mampu berjalan stabil. Sistem dapat memproses gambar wajah secara *real-time* dan menampilkan hasil klasifikasi, visualisasi Grad-CAM, serta rekomendasi *skincare*. Hal ini menunjukkan bahwa integrasi antara model *deep learning*, visualisasi, dan LLM telah berjalan dengan baik.

Dataset yang digunakan dalam penelitian ini masih terbatas pada enam kategori permasalahan kulit wajah. Oleh karena itu, sistem perlu dikembangkan lebih lanjut dengan data yang lebih bervariasi agar hasil klasifikasi semakin akurat. Sistem ini juga bersifat non-medis, sehingga hasil yang diberikan sebaiknya digunakan sebagai referensi awal, bukan sebagai pengganti konsultasi dengan dermatolog, karena sistem ini merupakan alat bantu berbasis kecerdasan buatan yang bekerja berdasarkan pola data. Perlu dicatat bahwa validasi klinis bersama

pakar dermatologi masih diperlukan untuk memastikan keandalan sistem dalam konteks penggunaan nyata.

Secara keseluruhan, penelitian ini menunjukkan bahwa penerapan *transfer learning* dengan empat model *deep learning*, khususnya ResNet50, dan integrasi LLM, memiliki potensi dalam pengembangan sistem klasifikasi dan rekomendasi *skincare* berbasis kecerdasan buatan.

6.2. Saran

Penelitian ini masih memiliki beberapa keterbatasan yang dapat diperbaiki pada penelitian selanjutnya. Perlu dilakukan perluasan dataset dengan berbagai variasi kondisi wajah agar model dapat beradaptasi lebih baik terhadap situasi nyata. Penambahan kategori permasalahan kulit wajah juga disarankan untuk meningkatkan ketepatan klasifikasi yang lebih detail dan relevan dengan kebutuhan pengguna. Selain itu, eksplorasi terhadap model *deep learning* lainnya serta pengujian berbagai variasi *hyperparameter* pelatihan.

Untuk meningkatkan keandalan sistem, validasi klinis bersama pakar dermatologi perlu dilakukan guna memastikan bahwa hasil klasifikasi dan rekomendasi *skincare* memiliki dasar ilmiah yang dapat dipertanggungjawabkan. Kolaborasi ini akan membantu sistem berkembang menjadi alat bantu konsultasi awal yang lebih akurat, aman, dan bermanfaat bagi pengguna di bidang perawatan kulit wajah berbasis kecerdasan buatan. Selain itu, penelitian selanjutnya juga dapat menambahkan fitur *chatbot* berbasis kecerdasan buatan agar pengguna dapat melakukan konsultasi interaktif secara langsung. Fitur ini diharapkan dapat memberikan pengalaman penggunaan yang lebih komunikatif, informatif, dan

personal dalam memahami hasil analisis kulit wajah serta rekomendasi *skincare* yang diberikan oleh sistem.

DAFTAR PUSTAKA

[1] Abolhasani, Ruhollah, Farnaz Araghi, Mohammadreza Tabary, Armin Aryannejad, Baharnaz Mashinchi, and Reza M. Robati. "The Impact of Air Pollution on Skin and Related Disorders: A Comprehensive Review." *Dermatologic Therapy* 34, no. 2 (March 2021). https://doi.org/10.1111/dth.14840.

[2] Jiao, Qian, Leilei Zhi, Bing You, Gaixiang Wang, Nan Wu, and Yan Jia. "Skin Homeostasis: Mechanism and Influencing Factors." *Journal of Cosmetic Dermatology* 23, no. 5 (May 2024): 1518–26. https://doi.org/10.1111/jocd.16155.

[3] Huynh, Pauline P., Masaru Ishii, Michelle Juarez, David Liao, Halley M. Darrach, Nicholas Fung, Jason C. Nellis, et al. "Normal Gaze Patterns of the Face in Lateral View." *Facial Plastic Surgery & Aesthetic Medicine* 22, no. 2 (April 1, 2020): 80–85. https://doi.org/10.1089/fpsam.2019.29019.huy.

[4] Rubo, Marius, Ivo Käthner, and Simone Munsch. "Attention to Faces in Images Is Associated with Personality and Psychopathology." Edited by Antoine Coutrot. *PLOS ONE* 18, no. 2 (February 15, 2023): e0280427. https://doi.org/10.1371/journal.pone.0280427.

[5] Cortés, Hernán, Martín Rojas-Márquez, María L. Del Prado-Audelo, Octavio D. Reyes-Hernández, Manuel González-Del Carmen, and Gerardo Leyva-Gómez. "Alterations in Mental Health and Quality of Life in Patients with Skin Disorders: A Narrative Review." *International Journal of Dermatology* 61, no. 7 (July 2022): 783–91. https://doi.org/10.1111/ijd.15852.

[6] Mustafidah, Zahrotul, and Annisaa Utami. “Sistem Pakar Identifikasi Masalah Kulit Wajah Menggunakan Metode Case Based Reasoning.” *Jurnal Komtika (Komputasi Dan Informatika)* 8, no. 2 (November 28, 2024): 190–99. https://doi.org/10.31603/komtika.v8i2.11614.

[7] Febrianto, Mohamad Raka. “PEMANFAATAN ARTIFICIAL INTELLIGENCE UNTUK MENGIDENTIFIKASI DAN MENGATASI MASALAH KESEHATAN KULIT WAJAH” 2, no. 1 (2025).

[8] Sinaulan, Cynthia Diana, and Angga Hantara. “Model Klasifikasi Permasalahan Kulit Wajah Menggunakan Metode Support Vector Machine.” Jurnal Pendidikan Dan Kewirausahaan 9, no. 1 (October 8, 2021): 297–308. https://doi.org/10.47668/pkwu.v9i1.246.

[9] Saiwaeo, Sirawit, Sujitra Arwatchananukul, Lapatrada Mungmai, Weeraya Preedalikit, and Nattapol Aunsri. “Human Skin Type Classification Using Image Processing and Deep Learning Approaches.” *Heliyon* 9, no. 11 (November 2023): e21176. https://doi.org/10.1016/j.heliyon.2023.e21176.

[10] Pyingkodi, M, Gokul Chandrasekaran, Suresh Palarimath, Vijayakumar P, R. Rahul, and V. Vibin. “Exploring Deep Learning Algorithms for Skin Disease Classification Using Skin Lesion Images.” *SSRN Electronic Journal*, 2025. https://doi.org/10.2139/ssrn.5109725.

[11] Obuchowicz, Rafał, Michał Strzelecki, and Adam Piórkowski. “Clinical Applications of Artificial Intelligence in Medical Imaging and Image Processing—A Review.” *Cancers* 16, no. 10 (May 14, 2024): 1870. https://doi.org/10.3390/cancers16101870.

[12] Mputu, Hassan Shabani, Ahmed Abdel-Mawgood, Atsushi Shimada, and Mohammed S. Sayed. “Tomato Quality Classification Based on Transfer Learning Feature Extraction and Machine Learning Algorithm Classifiers.” *IEEE Access* 12 (2024): 8283–95. https://doi.org/10.1109/ACCESS.2024.3352745.

[13] Chen, Junde, Jinxiu Chen, Defu Zhang, Yuandong Sun, and Y.A. Nanehkaran. “Using Deep Transfer Learning for Image-Based Plant Disease Identification.” *Computers and Electronics in Agriculture* 173 (June 2020): 105393. https://doi.org/10.1016/j.compag.2020.105393.

[14] Akhand, M. A. H., Shuvendu Roy, Nazmul Siddique, Md Abdus Samad Kamal, and Tetsuya Shimamura. “Facial Emotion Recognition Using Transfer Learning in the Deep CNN.” *Electronics* 10, no. 9 (April 27, 2021): 1036. https://doi.org/10.3390/electronics10091036.

[15] Sandag, Green Arther, Eleonora Djamal, George Morris William Tangka, and Semmy Wellem Taju. “MRI Image Analysis for Alzheimer’s Disease Detection Using Transfer Learning: VGGNet vs. EfficientNet.” *CogITo Smart Journal* 10, no. 2 (December 31, 2024): 580–92. https://doi.org/10.31154/cogito.v10i2.836.580-592.

[16] Li, Lei, Yongfeng Zhang, and Li Chen. “Prompt Distillation for Efficient LLM-Based Recommendation.” In Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, 1348–57. Birmingham United Kingdom: ACM, 2023. https://doi.org/10.1145/3583780.3615017.

[17] Nurkhasanah, Nurkhasanah, and Murinto Murinto. “Klasifikasi Penyakit Kulit Wajah Menggunakan Metode Convolutional Neural Network.” *Sainteks* 18, no. 2 (February 12, 2022): 183. https://doi.org/10.30595/sainteks.v18i2.13188.

[18] Ismayanti Afrina Putri. “Cara Mengetahui Jenis Kulit Wajah dan Ciri-Cirinya!.” iaputrii.id. https://www.iaputri.id/2024/06/jenis-kulit.html. diakses: 11 Juni 2025.

[19] Sundari, Nabila Asryani, Rita Magladena, and Sofia Saidah. “Klasifikasi Jenis Kulit Wajah Menggunakan Metode Covolutional Neural Network (CNN) Efficientnet-B0 Skin Classification System Using Convolutional Neural Network (CNN) EfficientNet-B0,” n.d.

[20] Wiguna, Lalu Habib Satya, Fitri Bimantoro, and Gibran Satya Nugraha. “KLASIFIKASI MASALAH PADA KULIT WAJAH MENGGUNAKAN METODE CNN,” n.d.

[21] Dila Aura Futri, Alun Sujjada, and Ivana Lucia Kharisma. “Implementasi MobileNet Dalam Klasifikasi Jenis Kulit Wajah Untuk Penentuan Kandungan Skincare.” *Jurnal RESTIKOM : Riset Teknik Informatika Dan Komputer* 7, no. 1 (May 2, 2025): 17–24. https://doi.org/10.52005/restikom.v7i1.406.

[22] Sifatullah, Nur. “Jerawat (Acne vulgaris): Review Penyakit Infeksi Pada Kulit”, *PROSIDING BIOLOGI ACHIEVING THE SUSTAINABLE DEVELOPMENT GOALS WITH BIODIVERSITY IN CONFRONTING CLIMATE CHANGE,* vol. 7, no. 1, Nov. 2021, Accessed: Jun. 8, 2025.

[Online]. Available: https://journal3.uin-alauddin.ac.id/index.php/psb/article/view/22212

[23] Nautiyal, Avni, and Sarika Wairkar. "Management of Hyperpigmentation: Current Treatments and Emerging Therapies." Pigment Cell & Melanoma Research 34, no. 6 (November 2021): 1000–1014. https://doi.org/10.1111/pcmr.12986.

[24] Amin, Ruhul, Anna Lechner, Annika Vogt, Ulrike Blume-Peytavi, and Jan Kottner. "Molecular Characterization of Xerosis Cutis: A Systematic Review." Edited by Michel Simon. PLOS ONE 16, no. 12 (December 16, 2021): e0261253. https://doi.org/10.1371/journal.pone.0261253.

[25] Kirsten, Natalia, Nicole Mohr, Aminah Alhumam, and Matthias Augustin. "Prevalence and Associated Diseases of Seborrheic Skin in Adults." Clinical Epidemiology Volume 13 (September 2021): 845–51. https://doi.org/10.2147/CLEP.S323744.

[26] Abdlaty, Ramy, Joseph Hayward, Thomas Farrell, and Qiyin Fang. "Skin Erythema and Pigmentation: A Review of Optical Assessment Techniques." Photodiagnosis and Photodynamic Therapy 33 (March 2021): 102127. https://doi.org/10.1016/j.pdpdt.2020.102127.

[27] Yoelin, Steve, Jeremy B Green, Sunil S Dhawan, Fauad Hasan, Brom Mahbod, Bashir Khan, and Akash S Dhawan. "The Use of a Novel Artificial Intelligence Platform for the Evaluation of Rhytids." Aesthetic Surgery Journal 42, no. 11 (October 13, 2022): NP688–94. https://doi.org/10.1093/asj/sjac200.

[28] Akib, Nul Illiyyin, Nurull Hikmah, and Restu Nur. “SOSIALISASI PENGGUNAAN SKINCARE DAN KOSMETIK YANG AMAN DAN TEPAT BAGI REMAJA DI PONDOK TAHFIDZ ABDURRAHMAN BIN AUF KENDARI” 1, no. 3 (2023).

[29] Hilmi, Indah Laily, Nalisha Putri Rianoor, and Vesara Ardhe Gatera. “Hubungan Pengetahuan dan Sikap Terhadap Perilaku Pemilihan Skincare Wajah melalui Media Sosial pada salah satu Universitas Di Karawang Jawa Barat.” *Pharmacon: Jurnal Farmasi Indonesia* 19, no. 2 (December 31, 2022): 203–12. https://doi.org/10.23917/pharmacon.v19i2.19261.

[30] Widjaja, Herman. “WORKSHOP PEMBUATAN FORMULA SKINCARE BERBASIS HERBAL ”KONSEP DASAR APLIKASI FORMULASI KOSMETIK HERBAL DALAM PRODUK SKIN CARE”.” *Pharmacy Action Journal* 1, no. 2 (April 23, 2022): 34–36. https://doi.org/10.52447/paj.v1i2.5683.

[31] Marcelino, João, and Ana M. Giménez-Arnau. “Impact of Cosmetics and Cleansers in Atopic Dermatitis—How to Advise Patients.” *Current Treatment Options in Allergy* 11, no. 2 (April 8, 2024): 62–76. https://doi.org/10.1007/s40521-024-00360-1.

[32] Goh, Chee-Leok, Yan Wu, Belinda Welsh, Ma Flordeliz Abad-Casintahan, Chung-Jen Tseng, Jaishree Sharad, SungKyu Jung, Jinda Rojanamatin, Irma Bernadette S. Sitohang, and Hau Ngai Kingsley Chan. “Expert Consensus on Holistic Skin Care Routine: Focus on Acne, Rosacea, Atopic Dermatitis, and Sensitive Skin Syndrome.” *Journal of Cosmetic Dermatology* 22, no. 1 (January 2023): 45–54. https://doi.org/10.1111/jocd.15519.

[33] Attard, Tamara, Lilian Azzopardi, and Everaldo Attard. “Daily Facial Skin Care Formulations: Benefits and Risks.” *Acta Poloniae Pharmaceutica - Drug Research* 79, no. 1 (May 10, 2022): 49–61. https://doi.org/10.32383/appdr/147222.

[34] Arfa Fairuziyah Firdausy Divinda Haya *et al.* ‘Characterization and application of moisturizer in skin treatment: A review’, *Journal of Pakistan Association of Dermatologists*, vol. 33. no. 4 2023, [Online]. Available: https://www.jpad.com.pk/index.php/jpad/article/view/2320.

[35] Thorat, Prajakta S, Hrushikesh B Bhadane, Suyog S Wagh, Manisha S Gaikwad, and Dr Santosh S Chhajed. “GENERAL REVIEW ON FACE SERUM,” n.d.

[36] Sulistiyowati, Ayu, Yushardi Yushardi, and Sudarti Sudarti. “Potensi Keberagaman SPF (Sun Protection Factor) Sunscreen Terhadap Perlindungan Paparan Sinar Ultraviolet Berdasarkan Iklim Di Indonesia.” *Jurnal Bidang Ilmu Kesehatan* 12, no. 3 (September 30, 2022): 261–69. https://doi.org/10.52643/jbik.v12i3.2196.

[37] Sari, Nurmala, Bakhtiar Bakhtiar, and Nikman Azmin. “Pemanfaatan Rumput Laut (Eucheuma Cottonii) Sebagai Bahan Dasar Masker Wajah Alami.” *JUSTER : Jurnal Sains Dan Terapan* 1, no. 1 (January 3, 2022): 28–35. https://doi.org/10.55784/juster.Vol1.Iss1.15.

[38] Yuniarsih, Nia, Aeni Indriyati, and Ani Munjiani. “REVIEW : MASKER WAJAH HERBAL DI INDONESIA.” *Jurnal Buana Farma* 1, no. 1 (March 31, 2021): 17–21. https://doi.org/10.36805/jbf.v1i1.43.

[39] Pradana, David, Muhammad Luthfi Alghifari, Muhammad Farhan Juna, and Dwisiwi Palaguna. “Klasifikasi Penyakit Jantung Menggunakan Metode Artificial Neural Network.” Indonesian Journal of Data and Science 3, no. 2 (July 31, 2022): 55–60. https://doi.org/10.56705/ijodas.v3i2.35.

[40] Sharifani, Koosha, and Mahyar Amini. “Machine Learning and Deep Learning: A Review of Methods and Applications” 10, no. 07, 2023. [Online]. Available: https://ssrn.com/abstract=4458723

[41] Taye, Mohammad Mustafa. “Understanding of Machine Learning with Deep Learning: Architectures, Workflow, Applications and Future Directions.” *Computers* 12, no. 5 (April 25, 2023): 91. https://doi.org/10.3390/computers12050091.

[42] Janiesch, Christian, Patrick Zschech, and Kai Heinrich. “Machine Learning and Deep Learning.” *Electronic Markets* 31, no. 3 (September 2021): 685–95. https://doi.org/10.1007/s12525-021-00475-2.

[43] Khan, Protima, Md. Fazlul Kader, S. M. Riazul Islam, Aisha B. Rahman, Md. Shahriar Kamal, Masbah Uddin Toha, and Kyung-Sup Kwak. “Machine Learning and Deep Learning Approaches for Brain Disease Diagnosis: Principles and Recent Advances.” *IEEE Access* 9 (2021): 37622–55. https://doi.org/10.1109/ACCESS.2021.3062484.

[44] Mohammed, Ammar, and Rania Kora. “A Comprehensive Review on Ensemble Deep Learning: Opportunities and Challenges.” *Journal of King Saud University - Computer and Information Sciences* 35, no. 2 (February 2023): 757–74. https://doi.org/10.1016/j.jksuci.2023.01.014.

[45] Purwono, Purwono, Alfian Ma'arif, Wahyu Rahmaniar, Haris Imam Karim Fathurrahman, Aufaclav Zatu Kusuma Frisky, and Qazi Mazhar Ul Haq. "Understanding of Convolutional Neural Network (CNN): A Review." International Journal of Robotics and Control Systems 2, no. 4 (January 15, 2023): 739–48. https://doi.org/10.31763/ijrcs.v2i4.888.

[46] Bhatt, Dulari, Chirag Patel, Hardik Talsania, Jigar Patel, Rasmika Vaghela, Sharnil Pandya, Kirit Modi, and Hemant Ghayvat. "CNN Variants for Computer Vision: History, Architecture, Application, Challenges and Future Scope." Electronics 10, no. 20 (October 11, 2021): 2470. https://doi.org/10.3390/electronics10202470.

[47] Salehi, Ahmad Waleed, Shakir Khan, Gaurav Gupta, Bayan Ibrahimm Alabduallah, Abrar Almjally, Hadeel Alsolai, Tamanna Siddiqui, and Adel Mellit. "A Study of CNN and Transfer Learning in Medical Imaging: Advantages, Challenges, Future Scope." Sustainability 15, no. 7 (March 29, 2023): 5930. https://doi.org/10.3390/su15075930.

[48] Shiri, Farhad Mortezapour, Thinagaran Perumal, Norwati Mustapha, and Raihani Mohamed. "A Comprehensive Overview and Comparative Analysis on Deep Learning Models: CNN, RNN, LSTM, GRU," 2023. https://doi.org/10.48550/ARXIV.2305.17473.

[49] Krichen, Moez. "Convolutional Neural Networks: A Survey." Computers 12, no. 8 (July 28, 2023): 151. https://doi.org/10.3390/computers12080151.

[50] Wang, Meiqi, Siyuan Lu, Danyang Zhu, Jun Lin, and Zhongfeng Wang. "A High-Speed and Low-Complexity Architecture for Softmax Function in Deep Learning." In *2018 IEEE Asia Pacific Conference on Circuits and*

Systems (APCCAS), 223–26. Chengdu: IEEE, 2018. https://doi.org/10.1109/APCCAS.2018.8605654.

[51] Kim, Hee E., Alejandro Cosa-Linan, Nandhini Santhanam, Mahboubeh Jannesari, Mate E. Maros, and Thomas Ganslandt. "Transfer Learning for Medical Image Classification: A Literature Review." BMC Medical Imaging 22, no. 1 (December 2022): 69. https://doi.org/10.1186/s12880-022-00793-7.

[52] Romero, Miguel, Yannet Interian, Timothy Solberg, and Gilmer Valdes. "Targeted Transfer Learning to Improve Performance in Small Medical Physics Datasets." Medical Physics 47, no. 12 (December 2020): 6246–56. https://doi.org/10.1002/mp.14507.

[53] Alzubaidi, Laith, Jinshuai Bai, Aiman Al-Sabaawi, Jose Santamaría, A. S. Albahri, Bashar Sami Nayyef Al-dabbagh, Mohammed A. Fadhel, et al. "A Survey on Deep Learning Tools Dealing with Data Scarcity: Definitions, Challenges, Solutions, Tips, and Applications." Journal of Big Data 10, no. 1 (April 14, 2023): 46. https://doi.org/10.1186/s40537-023-00727-2.

[54] Hosna, Asmaul, Ethel Merry, Jigmey Gyalmo, Zulfikar Alom, Zeyar Aung, and Mohammad Abdul Azim. "Transfer Learning: A Friendly Introduction." Journal of Big Data 9, no. 1 (October 22, 2022): 102. https://doi.org/10.1186/s40537-022-00652-w.

[55] Iman, Mohammadreza, Hamid Reza Arabnia, and Khaled Rasheed. "A Review of Deep Transfer Learning and Recent Advancements." Technologies 11, no. 2 (March 14, 2023): 40. https://doi.org/10.3390/technologies11020040.

[56] Shibu George, Gerosh, Pratyush Raj Mishra, Panav Sinha, and Manas Ranjan Prusty. “COVID-19 Detection on Chest X-Ray Images Using Homomorphic Transformation and VGG Inspired Deep Convolutional Neural Network.” Biocybernetics and Biomedical Engineering 43, no. 1 (January 2023): 1–16. https://doi.org/10.1016/j.bbe.2022.11.003.

[57] Thanzeem Mohamed Sheriff, S, J Venkat Kumar, S Vigneshwaran, Aida Jones, and Jose Anand. “Lung Cancer Detection Using VGG NET 16 Architecture.” Journal of Physics: Conference Series 2040, no. 1 (October 1, 2021): 012001. https://doi.org/10.1088/1742-6596/2040/1/012001.

[58] Xu, Wanni, You-Lei Fu, and Dongmei Zhu. “ResNet and Its Application to Medical Image Processing: Research Progress and Challenges.” Computer Methods and Programs in Biomedicine 240 (October 2023): 107660. https://doi.org/10.1016/j.cmpb.2023.107660.

[59] Mandal, Bishwas, Adaeze Okeukwu, and Yihong Theis. “Masked Face Recognition Using ResNet-50.” arXiv, 2021. https://doi.org/10.48550/ARXIV.2104.08997.

[60] Marques, Gonçalo, Deevyankar Agarwal, and Isabel De La Torre Díez. “Automated Medical Diagnosis of COVID-19 through EfficientNet Convolutional Neural Network.” Applied Soft Computing 96 (November 2020): 106691. https://doi.org/10.1016/j.asoc.2020.106691.

[61] Harahap, Mawaddah, Amir Mahmud Husein, Shane Christian Kwok, Vincent Wizley, Jocelyn Leonardi, Derrick Kenji Ong, Deskianta Ginting, and Benny Art Silitonga. “Skin Cancer Classification Using EfficientNet

Architecture." Bulletin of Electrical Engineering and Informatics 13, no. 4 (August 1, 2024): 2716–28. https://doi.org/10.11591/eei.v13i4.7159.

[62] Nan, Yahui, Jianguo Ju, Qingyi Hua, Haoming Zhang, and Bo Wang. "A-MobileNet: An Approach of Facial Expression Recognition." Alexandria Engineering Journal 61, no. 6 (June 2022): 4435–44. https://doi.org/10.1016/j.aej.2021.09.066.

[63] Srinivasu, Parvathaneni Naga, Jalluri Gnana SivaSai, Muhammad Fazal Ijaz, Akash Kumar Bhoi, Wonjoon Kim, and James Jin Kang. "Classification of Skin Disease Using Deep Learning Neural Networks with MobileNet V2 and LSTM." Sensors 21, no. 8 (April 18, 2021): 2852. https://doi.org/10.3390/s21082852.

[64] Elshamy, Reham, Osama Abu-Elnasr, Mohamed Elhoseny, and Samir Elmougy. "Improving the Efficiency of RMSProp Optimizer by Utilizing Nestrove in Deep Learning." *Scientific Reports* 13, no. 1 (May 31, 2023): 8814. https://doi.org/10.1038/s41598-023-35663-x.

[65] Xu, Dongpo, Shengdong Zhang, Huisheng Zhang, and Danilo P. Mandic. "Convergence of the RMSProp Deep Learning Method with Penalty for Nonconvex Optimization." Neural Networks 139 (July 2021): 17–23. https://doi.org/10.1016/j.neunet.2021.02.011.

[66] Tian, Yingjie, Yuqi Zhang, and Haibin Zhang. "Recent Advances in Stochastic Gradient Descent in Deep Learning." Mathematics 11, no. 3 (January 29, 2023): 682. https://doi.org/10.3390/math11030682.

[67] Admojo, Fadhila Tangguh, and Yudha Islami Sulistya. "Analisis Performa Algoritma Stochastic Gradient Descent (SGD) Dalam Mengklasifikasi Tahu

Berformalin." *Indonesian Journal of Data and Science* 3, no. 1 (March 31, 2022): 1–8. https://doi.org/10.56705/ijodas.v3i1.42.

[68] Khozaimi, Ach, and Wayan Firdaus Mahmudy. "New Insight in Cervical Cancer Diagnosis Using Convolution Neural Network Architecture." *IAES International Journal of Artificial Intelligence (IJ-AI)* 13, no. 3 (September 1, 2024): 3092. https://doi.org/10.11591/ijai.v13.i3.pp3092-3100.

[69] A., Saranya, and Subhashini R. "A Systematic Review of Explainable Artificial Intelligence Models and Applications: Recent Developments and Future Trends." Decision Analytics Journal 7 (June 2023): 100230. https://doi.org/10.1016/j.dajour.2023.100230.

[70] Ali, Sajid, Tamer Abuhmed, Shaker El-Sappagh, Khan Muhammad, Jose M. Alonso-Moral, Roberto Confalonieri, Riccardo Guidotti, Javier Del Ser, Natalia Díaz-Rodríguez, and Francisco Herrera. "Explainable Artificial Intelligence (XAI): What We Know and What Is Left to Attain Trustworthy Artificial Intelligence." Information Fusion 99 (November 2023): 101805. https://doi.org/10.1016/j.inffus.2023.101805.

[71] Wang, Shuihua, and Yudong Zhang. "Grad-CAM: Understanding AI Models." Computers, Materials & Continua 76, no. 2 (2023): 1321–24. https://doi.org/10.32604/cmc.2023.041419.

[72] Naveed, Humza, Asad Ullah Khan, Shi Qiu, Muhammad Saqib, Saeed Anwar, Muhammad Usman, Naveed Akhtar, Nick Barnes, and Ajmal Mian. "A Comprehensive Overview of Large Language Models." arXiv, 2023. https://doi.org/10.48550/ARXIV.2307.06435.

[73] Chang, Yupeng, Xu Wang, Jindong Wang, Yuan Wu, Linyi Yang, Kaijie Zhu, Hao Chen, et al. “A Survey on Evaluation of Large Language Models.” *ACM Transactions on Intelligent Systems and Technology* 15, no. 3 (June 30, 2024): 1–45. https://doi.org/10.1145/3641289.

[74] Xu, Frank F., Uri Alon, Graham Neubig, and Vincent Josua Hellendoorn. “A Systematic Evaluation of Large Language Models of Code.” In *Proceedings of the 6th ACM SIGPLAN International Symposium on Machine Programming*, 1–10. San Diego CA USA: ACM, 2022. https://doi.org/10.1145/3520312.3534862.

[75] Imran, Muhammad, and Norah Almusharraf. “Google Gemini as a next Generation AI Educational Tool: A Review of Emerging Educational Technology.” *Smart Learning Environments* 11, no. 1 (May 23, 2024): 22. https://doi.org/10.1186/s40561-024-00310-z.

[76] Schröer, Christoph, Felix Kruse, and Jorge Marx Gómez. “A Systematic Literature Review on Applying CRISP-DM Process Model.” Procedia Computer Science 181 (2021): 526–34. https://doi.org/10.1016/j.procs.2021.01.199.

[77] Raschka, Sebastian, Joshua Patterson, and Corey Nolet. “Machine Learning in Python: Main Developments and Technology Trends in Data Science, Machine Learning, and Artificial Intelligence.” Information 11, no. 4 (April 4, 2020): 193. https://doi.org/10.3390/info11040193.

[78] Jain, Mr Pankaj, Hemant Soni, Aditya Pratap Singh, and Puneet Mehta. “Comparative Review of Python and C: Choosing the Right Language for Beginners,” *ijeta,* vol. 11, pp.148-156, Jun.2024, Accessed: Jun. 11, 2025.

[Online]. Available: https://www.ijetajournal.org/volume-11/issue-3/IJETA-V11I3P28.pdf

[79] Quaranta, Luigi, Fabio Calefato, and Filippo Lanubile. "KGTorrent: A Dataset of Python Jupyter Notebooks from Kaggle." In *2021 IEEE/ACM 18th International Conference on Mining Software Repositories (MSR)*, 550–54. Madrid, Spain: IEEE, 2021. https://doi.org/10.1109/MSR52588.2021.00072.

[80] Mostafavi Ghahfarokhi, Mojtaba, Arash Asgari, Mohammad Abolnejadian, and Abbas Heydarnoori. "DistilKaggle: A Distilled Dataset of Kaggle Jupyter Notebooks." In *Proceedings of the 21st International Conference on Mining Software Repositories*, 647–51. Lisbon Portugal: ACM, 2024. https://doi.org/10.1145/3643991.3644882.

[81] Kornienko, D V, S V Mishina, S V Shcherbatykh, and M O Melnikov. "Principles of Securing RESTful API Web Services Developed with Python Frameworks." Journal of Physics: Conference Series 2094, no. 3 (November 1, 2021): 032016. https://doi.org/10.1088/1742-6596/2094/3/032016.

[82] Albesher, Luluh, and Reem Alfayez. "An Observational Study on Flask Web Framework Questions on Stack Overflow (SO)." Edited by Alessandro Marchetto. IET Software 2024, no. 1 (January 2024): 1905538. https://doi.org/10.1049/sfw2/1905538.

[83] Novac, Ovidiu-Constantin, Mihai Cristian Chirodea, Cornelia Mihaela Novac, Nicu Bizon, Mihai Oproescu, Ovidiu Petru Stan, and Cornelia Emilia Gordan. "Analysis of the Application Efficiency of TensorFlow and

PyTorch in Convolutional Neural Network." *Sensors* 22, no. 22 (November 16, 2022): 8872. https://doi.org/10.3390/s22228872.

[84] B. T. Chicho and A. . Bibo Sallow, "A Comprehensive Survey of Deep Learning Models Based on Keras Framework", jscdm, vol. 2, no. 2, pp. 49–62, Oct. 2021, Accessed: Jun. 19, 2025. [Online]. Available: https://publisher.uthm.edu.my/ojs/index.php/jscdm/article/view/8732

[85] Joanne. "Pigmentation and Dark Spots…." Beautorium Training Academy. https://images.app.goo.gl/UaL7cNPZbJfbuF4K7. diakses: 9 Juni 2025.

[86] dr. Fadhli Rizal Makarim. "Ampuh, Ini 5 Cara Menghilangkan Kemerahan di Wajah Secara Alami." halodoc. https://images.app.goo.gl/WWovq8Dfnrt8vqiB8. diakses: 9 Juni 2025.

[87] Dr. Sunil Kumar Prabhu. "A brief on oily skin management." Aster. https://www.asterhospitals.in/blogs-events-news/aster-rv-bangalore/brief-oily-skin-management. diakses: 9 Juni 2025.

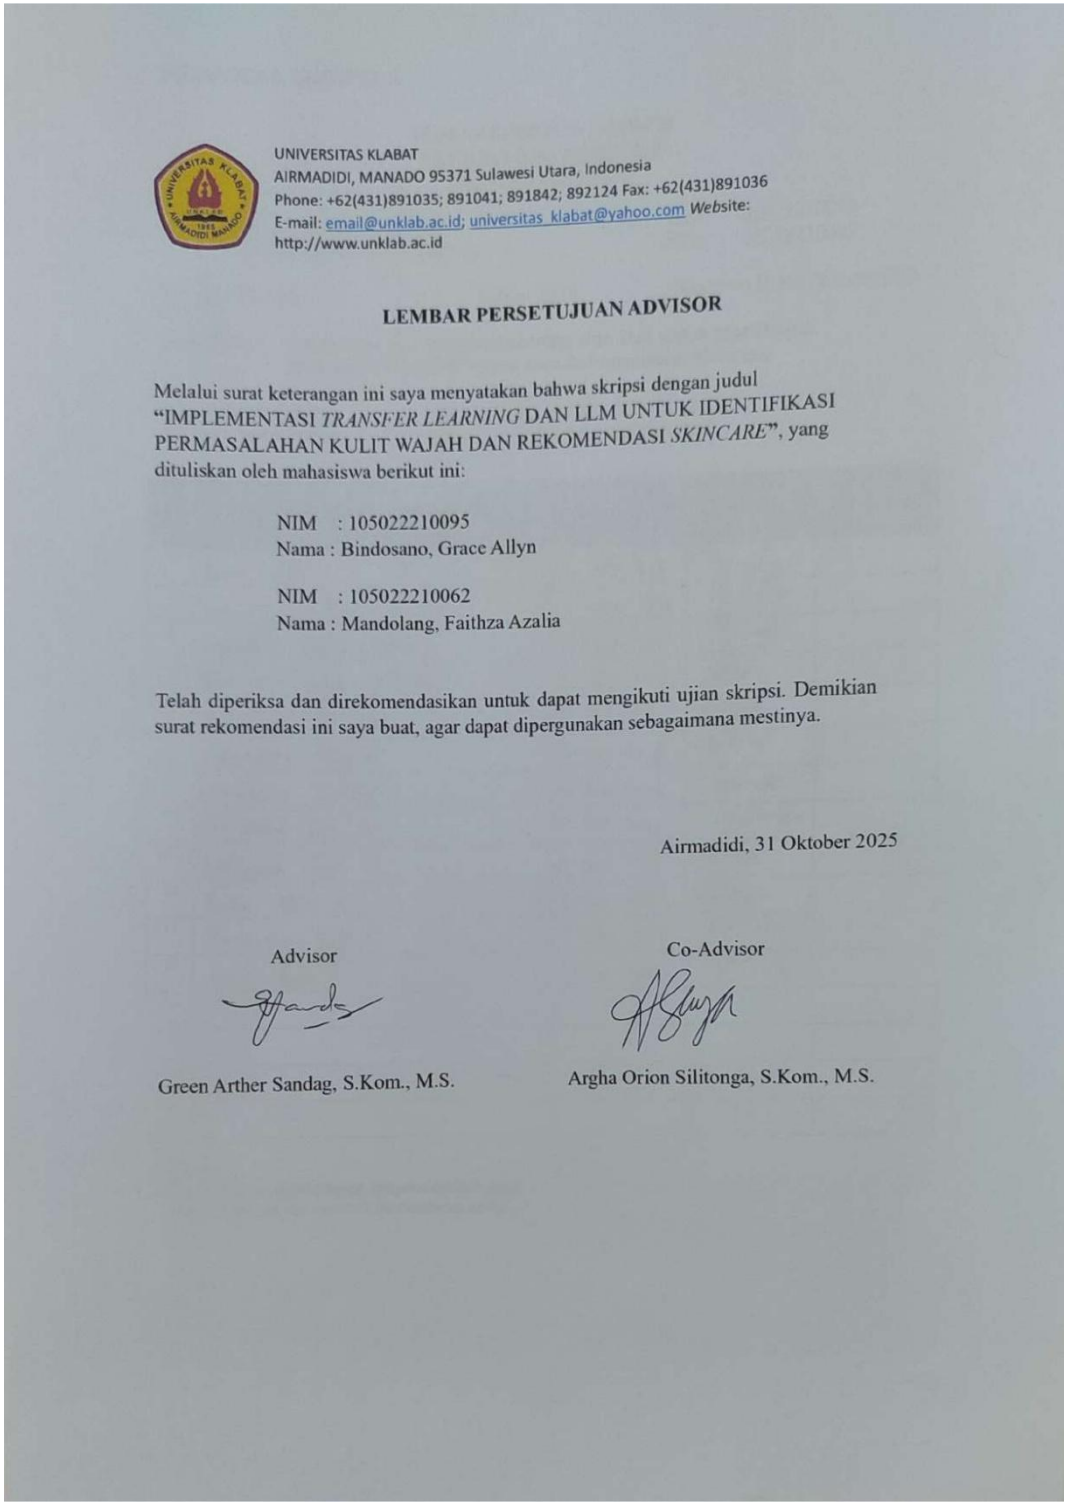
[88] Anjar Saputra. "Jerawat Batu Muncul Karena Infeksi, Ini Pengobatan Untuk Mengatasinya." Grid Health. https://images.app.goo.gl/o7kVc7b3bF5Uahmw6. diakses: 9 Juni 2025.

[89] priveeclinicadmin. "Tips Mencegah dan Menghilangkan Kerutan di Wajah." Privee Clinic. https://images.app.goo.gl/hhXgyWVCeQbB978J7. diakses: 9 Juni 2025.

[90] BAMED. "10 Cara Mengatasi Kulit Kering agar Kembali Halus dan Lembab." Klinik Bamed. https://images.app.goo.gl/nYXtxSWM1aF2Lzfb6. diakses: 9 Juni 2025.

DAFTAR LAMPIRAN

LEMBAR PERSETUJUAN ADVISOR



UNIVERSITAS KLABAT
AIRMADIDI, MANADO 95371 Sulawesi Utara, Indonesia
Phone: +62(431)891035; 891041; 891842; 892124 Fax: +62(431)891036
E-mail: email@unklab.ac.id; universitas_klabat@yahoo.com Website:
http://www.unklab.ac.id

LEMBAR PERSETUJUAN ADVISOR

Melalui surat keterangan ini saya menyatakan bahwa skripsi dengan judul "IMPLEMENTASI *TRANSFER LEARNING* DAN LLM UNTUK IDENTIFIKASI PERMASALAHAN KULIT WAJAH DAN REKOMENDASI *SKINCARE*", yang dituliskan oleh mahasiswa berikut ini:

NIM : 105022210095
Nama : Bindosano, Grace Allyn

NIM : 105022210062
Nama : Mandolang, Faithza Azalia

Telah diperiksa dan direkomendasikan untuk dapat mengikuti ujian skripsi. Demikian surat rekomendasi ini saya buat, agar dapat dipergunakan sebagaimana mestinya.

Airmadidi, 31 Oktober 2025

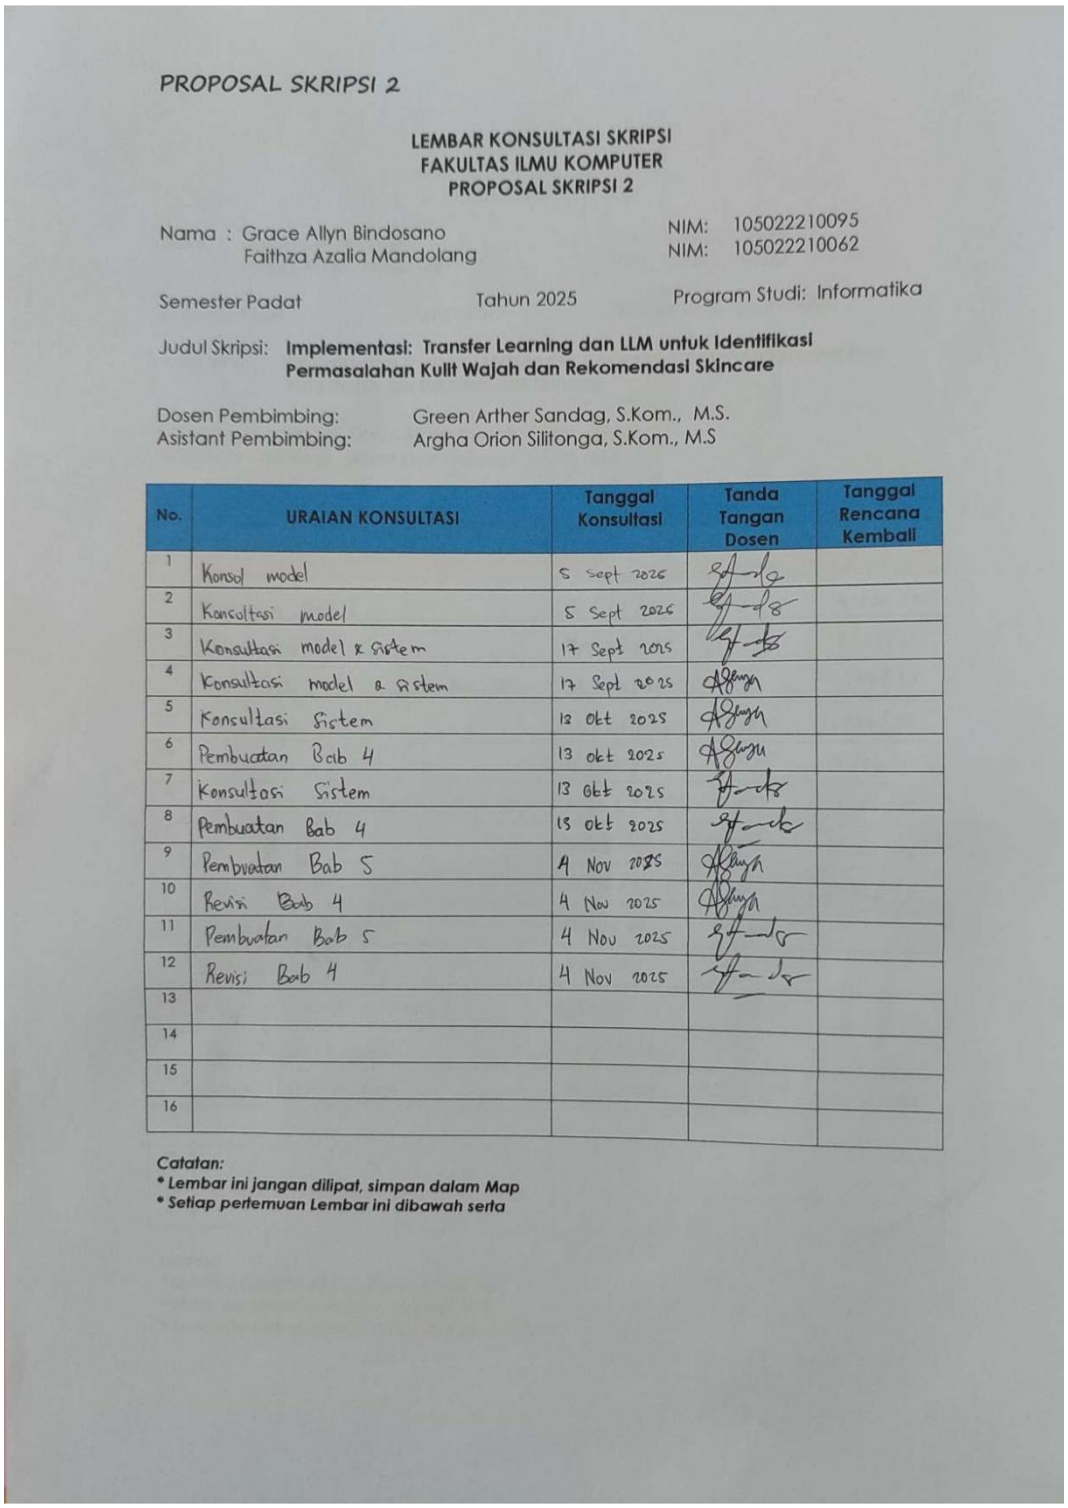
Advisor

Green Arther Sandag, S.Kom., M.S.

Co-Advisor

Argha Orion Silitonga, S.Kom., M.S.

LEMBAR KONSULTASI



PROPOSAL SKRIPSI 2

LEMBAR KONSULTASI SKRIPSI
FAKULTAS ILMU KOMPUTER
PROPOSAL SKRIPSI 2

Nama : Grace Allyn Bindosano — NIM: 105022210095
Faithza Azalia Mandolang — NIM: 105022210062

Semester Padat — Tahun 2025 — Program Studi: Informatika

Judul Skripsi: **Implementasi: Transfer Learning dan LLM untuk Identifikasi Permasalahan Kulit Wajah dan Rekomendasi Skincare**

Dosen Pembimbing: Green Arther Sandag, S.Kom., M.S.
Asistant Pembimbing: Argha Orion Silitonga, S.Kom., M.S

No.	URAIAN KONSULTASI	Tanggal Konsultasi	Tanda Tangan Dosen	Tanggal Rencana Kembali
1	Konsul model	5 Sept 2025		
2	Konsultasi model	5 Sept 2025		
3	Konsultasi model & sistem	17 Sept 2025		
4	Konsultasi model & sistem	17 Sept 2025		
5	Konsultasi sistem	12 Okt 2025		
6	Pembuatan Bab 4	13 okt 2025		
7	Konsultasi Sistem	13 Okt 2025		
8	Pembuatan Bab 4	13 okt 2025		
9	Pembuatan Bab 5	4 Nov 2025		
10	Revisi Bab 4	4 Nov 2025		
11	Pembuatan Bab 5	4 Nov 2025		
12	Revisi Bab 4	4 Nov 2025		
13				
14				
15				
16				

Catatan:
- *Lembar ini jangan dilipat, simpan dalam Map*
- *Setiap pertemuan Lembar ini dibawah serta*

ASSET CODING

Program Web Aplikasi:

https://github.com/gracealynn/SKRIPSI

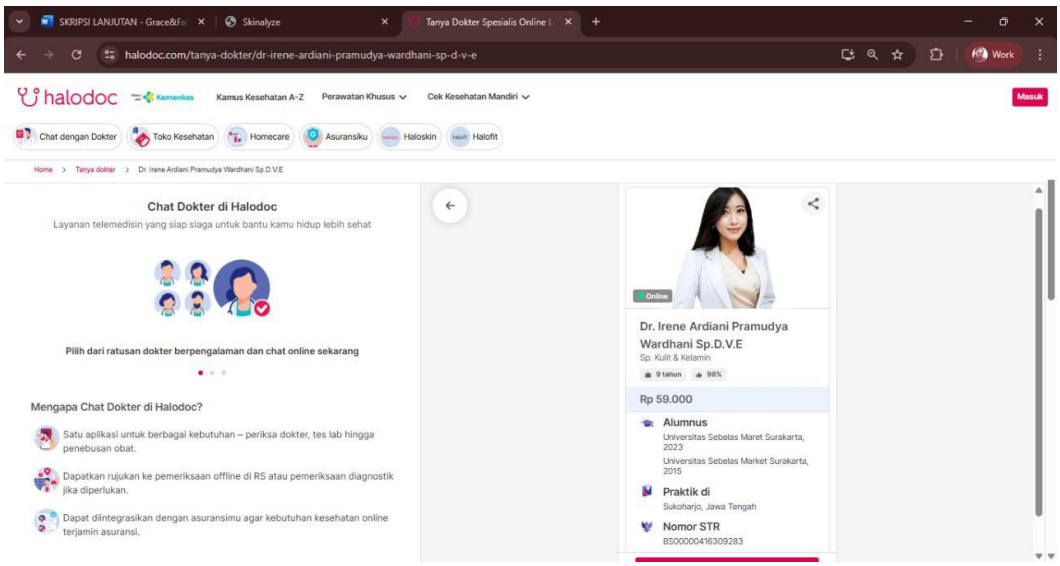
Notebook Kaggle ResNet50 Training:

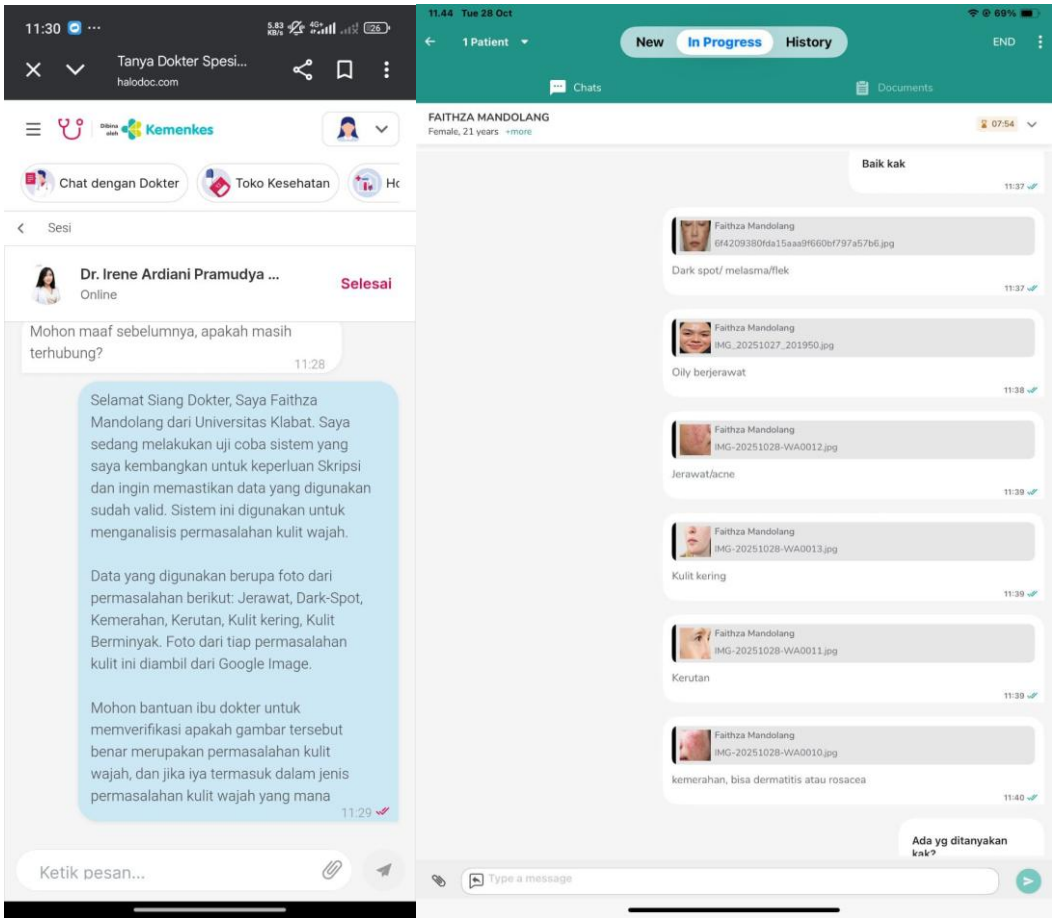
https://www.kaggle.com/code/gegefaithskripsi/resnet50

Notebook Kaggle ResNet50 Training:

https://www.kaggle.com/code/gegefaithskripsi/resnet50-prediksi

Bukti validasi gambar dengan Dokter





BIODATA PENULIS I

Nama	: Grace Allyn Bindosano
NIM	: 105022210095
Jenis Kelamin	: Perempuan
Agama	: Kristen Advent
Fakultas	: Ilmu Komputer
Jurusan	: Informatika
Alamat	: Perumahan GRITMA
Telpon	: 082192393103
E-mail	: gabindosano@gmail.com

Pendidikan Formal

(2022 – Sekarang)	: Universitas Klabat
(2019 – 2022)	: Manado Independent School
(2016 – 2019)	: Manado Independent School
(2011 – 2016)	: Manado Independent School

BIODATA PENULIS II

Nama	: Faithza Azalia Mandolang
NIM	: 105022210062
Jenis Kelamin	: Perempuan
Agama	: Kristen Advent
Fakultas	: Ilmu Komputer
Jurusan	: Informatika
Alamat	: Tomohon
Telpon	: 085339017033
E-mail	: faithzaazalia@gmail.com

Pendidikan Formal

(2022 – Sekarang)	: Universitas Klabat
(2019 – 2022)	: SMA SLA Tompaso
(2016 – 2019)	: SMP Negeri 1 Kakas
(2011 – 2016)	:SD Advent Tomohon